



南京工業職業技術大學

NANJING VOCATIONAL UNIVERSITY OF INDUSTRY TECHNOLOGY

毕业设计

题目 基于机器学习的入侵检测系统设计与实现

学生姓名：	平晓霜
学 号：	210501120204
学 院：	计算机与软件学院
专 业：	网络工程技术
班 级：	网络 2124
指导教师：	余久方

二〇二五 年 五 月

南京工业职业技术大学
毕业论文（设计）诚信承诺书

本人郑重声明：所呈交的毕业论文（设计）是本人在指导教师的指导下独立开展工作所取得的成果。尽我所知，除了文中特别加以标注和致谢的内容外，本设计（论文）不包含任何其他个人或集体已经发表或撰写的成果作品。对本设计（论文）所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

作者签名：

平晓霜

日 期： 2025 年 5 月 25 日

摘 要

随着网络攻击手段的复杂化，传统入侵检测系统在时序数据分析与深层特征提取上的局限性日益显著。本文针对这一问题，设计并实现了一种基于长短期记忆网络（LSTM）与自编码器（Autoencoder）融合的入侵检测模型。通过结合LSTM的时序依赖捕捉能力与自编码器的无监督特征学习优势，构建双向特征学习框架，实现网络流量时序模式与高维特征的双向建模。模型采用共享编码器参数与多任务学习策略，优化分类性能并提升训练效率。

实验基于NSL-KDD数据集，通过特征筛选、标准化预处理及分批次训练，采用Adam优化器与交叉熵损失函数优化模型参数。测试结果表明，该模型在二分类任务中准确率达到与多分类任务较传统方法与单一深度学习模型具有显著优势，尤其在异常流量检测中展现出更高的鲁棒性与泛化能力。此外，模型通过自动特征提取减少了对人工特征工程的依赖，验证了机器学习学习在入侵检测中的有效性。

本文提出的方法为智能化入侵检测提供了新思路，但实际部署中仍需进一步优化硬件适配性及实时响应效率。

关键词：入侵检测系统，LSTM；自编码器；NSL-KDD 数据集；机器学习

ABSTRACT

With the increasing complexity of cyberattack techniques, traditional intrusion detection systems face significant limitations in time-series data analysis and deep feature extraction. This paper addresses this issue by designing and implementing an intrusion detection model based on the fusion of Long Short-Term Memory (LSTM) networks and Autoencoders. By combining the time-series dependency capturing capability of LSTM with the unsupervised feature learning advantage of Autoencoders, a bidirectional feature learning framework is constructed to model both network traffic time-series patterns and high-dimensional features. The model adopts shared encoder parameters and a multi-task learning strategy to optimize classification performance and improve training efficiency.

The experiment is based on the NSL-KDD dataset, where feature selection, normalization preprocessing, and batch training are conducted. The Adam optimizer and cross-entropy loss function are used to optimize model parameters. Test results show that the model achieves higher accuracy in binary classification tasks compared to traditional methods and single deep learning models in multi-classification tasks, particularly demonstrating higher robustness and generalization ability in detecting anomalous traffic. Moreover, the model reduces dependence on manual feature engineering through automatic feature extraction, verifying the effectiveness of machine learning in intrusion detection.

The proposed method provides a new approach for intelligent intrusion detection, although further optimization is needed in terms of hardware adaptability and real-time response efficiency for practical deployment.

KEY WORDS: Intrusion Detection, LSTM, Autoencoder, NSL-KDD Dataset, Machine Learning

目 录

第一章 绪论	1
1.1 背景和意义	1
1.2 国内外研究现状	1
1.3 本课题主要工作	2
1.4 论文组织结构	3
第二章 相关理论与技术基础	4
2.1 入侵检测系统	4
2.1.1 入侵检测原理	4
2.1.2 入侵监测系统分类	4
2.2 入侵检测系统架构	4
2.2.1 入侵检测系统组成	4
2.2.2 入侵检测系统流程	5
2.3 入侵检测系统需求分析	6
2.3.1 现有入侵检测系统的局限性	6
2.3.2 引入机器学习算法的可行性分析	6
2.4 相关算法理论	6
2.4.1 MLP 算法	6
2.4.2 L-SVM 算法	8
2.4.3 Q-SVM 算法	8
2.4.4 LDA 算法	9
2.4.5 QDA 算法	10
2.4.6 AE 算法	11
2.4.7 LSTM 算法	12
2.5 模型评估	14
2.5.1 评估指标	14
2.5.2 损失值	15
第三章 基于机器学习的入侵检测的设计	17
3.1 数据集介绍	17
3.2 数据预处理	20

3.3 特征工程.....	20
3.3.1 特征分析.....	20
3.3.2 独热编码.....	21
3.3.3 数据划分.....	22
3.4 模型构建.....	22
3.4.1 模型对比.....	22
3.4.2 基于自编码器的 LSTM 模型	25
3.4.3 知识蒸馏架构.....	26
3.5 模型训练过程.....	27
第四章 系统设计与实现.....	28
4.1 入侵检测系统的数据表设计.....	28
4.2 入侵检测系统的 Web 服务系统设计	29
4.3 入侵检测系统的模块实现.....	30
4.3.1 用户登录模块.....	30
4.3.2 数据集分析模块.....	31
4.3.3 模型测试模块.....	33
4.3.4 模型预览图.....	35
4.3.5 模型调优.....	36
第五章 总结与展望.....	39
5.1 系统成果总结.....	39
5.2 未来工作展望.....	39
参考文献.....	41
致谢.....	42

图表清单

图 2.1	MLP 结构示意图.....	7
图 2.2	经典 AE 自编码模型.....	12
图 2.3	标准 LSTM 架构	13
图 3.1	LSTM 和自编码器的融合模型结构	25
图 3.2	师生模型架构.....	26
图 4.1	前后端通信示意图.....	30
图 4.2	用户登录界面.....	30
图 4.3	测试集攻击类型分布	31
图 4.4	协议类型统计	31
图 4.5	服务类型 TOP10 统计	32
图 4.6	连接时长分布统计	33
图 4.7	模型测试界面	34
图 4.8	测试集二分类检测报告	34
图 4.9	测试集多分类检测报告	35
图 4.10	模型分析结果.....	35
图 4.11	参数配置图.....	37
图 4.12	后端训练过程.....	38
图 4.13	二分类训练准确率.....	38
表 2.1	入侵检测系统的模块组成.....	4
表 2.2	混淆矩阵元素.....	14
表 3.1	NSL-KDD 的 41 个有效特征	17
表 3.2	NSL-KDD 中的攻击类型	20
表 3.3	部分特征的均值与标准差.....	21
表 3.4	数据集中协议类型的分布情况.....	21
表 3.5	flag 的独热编码.....	21
表 3.6	二分类精确度报告	23
表 3.7	二分类召回率报告	23
表 3.8	二分类 F1 Score 报告.....	23

表 3.9	多分类准确率报告.....	24
表 3.10	多分类准确率报告.....	24
表 3.11	多分类准确率报告.....	24
表 4.1	用户表.....	28
表 4.2	任务表.....	28
表 4.3	模型调优表.....	29
表 4.4	服务类型 TOP10 说明	32

第一章 绪论

1.1 背景和意义

近年来,互联网连接服务迅速增加。据估计,到 2020 年,将有 500 亿台设备连接到互联网。在数字化转型浪潮下,信息通信技术体系虽显著提升了社会运行效率,却也催生出日益严峻的网络威胁生态。当前网络攻击手段正经历智能化演变,新型恶意代码采用多态变形、零日漏洞利用等高级技术,使得传统防御体系面临严峻挑战。据统计,全球每年因 IT 系统缺陷导致的经济损失已达百亿级规模,且呈现加速上升趋势,预计未来几年这一数字还会增长。因此,网络安全已成为当代社会面临的首要挑战。为此,监控和分析网络流量数据对于检测潜在攻击模式至关重要。在此背景下,为了开发更智能的入侵检测系统 (IDS, Intrusion Detection System),以防止恶意威胁并确保更好的网络安全,全球科技企业正加大数据科学投入,推动入侵检测系统向智能化演进。这个概念包括一组源自计算、统计和信息技术的技术,包括众所周知的机器学习 (ML, Machine Learning) 方法。然而,不同来源生成的大量异构大数据使得传统数据分析和浅层机器学习方法无法有效且不足以直接应对此类安全挑战。值得注意的是,传统机器学习技术存在延迟和计算复杂性问题,并且无法有效学习大数据集中存在的复杂且随时间变化的非线性关系。为了克服这些限制,从而提高入侵检测性能,我们将传统数据分析和机器学习相结合。具体而言,我们结合深度学习(DL, Deep Learning) 技术,开发出一种更有效的入侵检测系统 (IDS)。众所周知,DL 算法能够通过分层学习过程自动从输入表示中提取高层次的抽象。深度学习在现实世界的各个研究领域都取得了有趣的成果,如生物工程情绪分析图像识别和显著性检测。最近,它也被用于开发入侵检测系统。

1.2 国内外研究现状

近年来,有许多入侵检测系统使用基准 KDD99 和 NSL-KDD 数据集来评估 IDS 模型的性能和有效性。例如,Ingre 和 Yadav [1]开发了一个 3 层 MLP,使用 NSL-KDD 数据集检测攻击,多分类准确率达到 79.9%,二分类准确率达到 81.2%。Ibrahim 等人^[2]提出了一种基于自组织映射 (SOM) 的二分类新方法,并在 NSL-KDD 测试数据集上报告了 75.49% 的检测准确率。Mohamed 等人^[3]应用MLP等传统学习技术,通过将数据集分成 10 折,二分类准确率达到 95.7%。高等人^[4]开发了一种基于模糊和集成学习理论的半监督学习方法,使用 NSL-KDD 数据集,在 KDD 测试集上的准确率为 84.54%。Alrawashdeh 等人^[5]实现了一个基于限制玻尔兹曼机(RBM) 的深度信念网络

(DBN)，带有一个 softmax 输出层，用于多分类目的。然而，所提出的系统在 10% 的 KDD99 测试样本上进行了测试，分别实现了 98% 的准确率和 2.47% 的误报率。杨等人^[6]使用软件定义网络(SDN) 环境并提出了一种用于异常检测的深度神经网络(DNN)。具体而言，在 NSL-KDD 数据集上训练了一个三隐藏层神经网络。然而，仅使用了 6 个特征，并且只进行了双向判别（正常与异常）。实验结果报告了 75.75% 的性能准确率。Kim 等人^[7]还提出了一个在 KDD99 数据集上训练的深度神经网络(DNN)。DNN^[8]包含四个隐藏层，100 个隐藏神经元，并使用自适应矩估计 (Adam) 方法进行训练。Kim 等人声称性能非常好，但使用了原始KDD99 数据集的不同子集。Yan 和 Han^[9]提出了一种堆叠稀疏自动编码器(SSAE) 来检测 NSL-KDD 数据集的攻击类别，声称准确率为 98.63%，但通过将原始数据混洗和重新组装成几个独立的数据集简化了实验过程。同样，Xu 等人^[10]开发了一种基于 DNN 的 IDS对 NSL-KDD 数据集的样本进行分类，并取得了良好的效果，然而，他们通过对原始 NSL-KDD 数据执行 10 倍交叉验证法来评估所提模型的有效性。Imamverdiyev 等人^[11]开发了三种深度学习方法，具体是深度玻尔兹曼机、伯努利-伯努利受限玻尔兹曼机 (RBM) 和高斯-伯努利 RBM，以及基于 SVM（径向基）、SVM（epsilon 支持向量回归）和决策树架构的三种标准机器学习方法。实验结果表明，伯努利-伯努利 RBM 优于所有其他方法，准确率达到 73.23%。Javaid 等人^[12]使用稀疏 AE 架构和自学 (STL) 来检测NSL-KDD 数据集中的异常。Yousefi-Azar 等人^[13]开发了一种基于循环神经网络(RNN) 的入侵检测系统。作者使用 NSL-KDD 数据集作为基准，并执行二分类和多分类，分别实现了 83.3% 和 81.3% 的准确率。最近，Shone 等人^[14]实现了一个堆叠式非对称深度自动编码器(SNDAE) 架构来检测网络攻击。

1.3 本课题主要工作

传统 LSTM 网络虽能有效捕捉网络流量数据的时序依赖特性（如 TCP 连接状态的连续性变化），但对高维特征的空间相关性建模能力有限。本课题通过引入自编码器（Autoencoder）结构，构建了双向特征学习框架。

本课题将 LSTM 模型和自编码器功能相结合，LSTM 处理时序信息，自编码器进行特征提取，共享编码器输出，实现多任务学习。

本课题的优势分析：

- （1）特征提取优势：自动学习特征表示、捕捉时序依赖、提取深层特征；
- （2）分类性能优势：提高分类准确率、增强模型鲁棒性、改善泛化能力；
- （3）模型效率优势：共享特征表示、减少参数量、提高训练效率。

应用场景适配：网络流量分析、时序异常检测、特征自动提取、实时分类预测。

这种 LSTM 和自编码器的结合方式，既保留了 LSTM 处理时序数据的优势，又利用了自编码器进行特征提取的能力，同时提高了模型的泛化能力。

1.4 论文组织结构

本论文的组织结构如下：

第一章 阐述课题的背景和意义，分析了传统入侵检测系统在应对网络攻击时的局限性，综述国内外在入侵检测领域的研究进展，简述本论文所做的主要工作。

第二章 介绍了入侵检测的原理和分类，详细阐述基于异常检测、误用检测和混合检测的入侵检测系统分类方法，以及各自的优缺点和适用场景。同时，介绍入侵检测系统架构，包括其组成和架构，并分析现有入侵检测系统的局限性和入侵检测系统的意义。最后，阐述相关算法理论，包括 MLP 算法、L-SVM 算法、Q-SVM 算法、LDA 算法、QDA 算法，以及深层网络算法中的 AE 算法和 LSTM 算法，并介绍模型评估指标和损失值。

第三章 描述所设计的入侵检测系统的整体架构，包括数据集介绍、数据预处理、特征工程、模型构建和模型训练过程等主要环节。

第四章 描述入侵检测系统的各个功能模块的实现细节，包括用户登录模块、数据集分析、模型测试模块、模型预览图和模型调优等。

第五章 总结本课题的研究成果，客观分析系统在实际网络环境中的局限性。针对系统的不足之处，提出未来的研究方向和改进计划。

第二章 相关理论与技术基础

2.1 入侵检测系统

2.1.1 入侵检测原理

入侵检测系统（IDS，Intrusion Detection System）一种通过收集和分析被保护系统信息,从而发现入侵的技术系统^[15]。其核心目标是识别未经授权的访问、恶意行为或违反安全策略的活动，并发出警报，帮助管理员及时响应。

入侵检测可以根据检测原理分为三种类型：异常检测、误用检测和混合检测。

异常检测是把当前网络的行为和系统正常的行为做对比。如果在对比过程中，发现两者之间的差距大于设定的阈值，就说明系统出现异常或被入侵。异常检测可以识别未知的攻击，但问题在于如何准确区分正常流量和异常行为，以及如何设置合适的阈值。目前还没有统一的标准，这导致该方法的误报率较高。

误用检测是根据已知的攻击特征，将异常流量和正常流量区分开来。误用检测能够明确标识入侵类型，具有较高的准确性和较低的误报率。然而，这种方法对于未知攻击的识别能力较差。

混合入侵检测是结合了异常检测和误用检测的优点。它不仅能够识别未知的攻击，还能提高准确性并减少误报。因此，混合入侵检测是目前比较常用的方法。

2.1.2 入侵监测系统分类

根据数据来源，入侵检测系统可以分为两种：基于主机的 IDS 和基于网络的 IDS^{错误！未找到引用源。}。基于主机的 IDS 监控主机或服务器上的活动，来检测潜在的攻击。它可以发现内部的问题，误报率较低，但无法检测网络攻击，覆盖范围有限，配置也较为复杂。相比之下，基于网络的 IDS 监控网络上的数据流量来检测潜在的攻击，通常部署在网络的入口点。因此，选择适合的 IDS 需要根据具体的网络环境 and 安全需求来决定^[16]。

总结来说，本课题中提到的入侵检测方法，若根据数据来源来划分，是基于网络的入侵检测；如果按检测方法来分类，则是基于异常的入侵检测。

2.2 入侵检测系统架构

2.2.1 入侵检测系统组成

入侵检测系统的模块组成如下表2.1所示：

表 2.1 入侵检测系统的模块组成

组成名称	主要功能
数据源（Data source）	检测获取的原始数据
探测器单元（Sensor）	从数据源数据

表 2.2 （续）入侵检测系统的模块组成

组成名称	主要功能
行为 (Activity)	原始数据的实例
分析单元 (Analyzer)	分析和提取数据特征
事件 (Event)	对原始数据的分类结果
管理单元 (Manager)	管理各模块配置及数据综合报表

数据源 (Data source) 是系统通过监控获取的原始数据, 这些数据未经过授权或者存在异常。对于网络入侵检测来说, 数据源是网络通信数据包; 对于主机入侵检测来说, 数据源包括操作系统的审计数据、校验数据和应用程序的审计数据等^[17]。

探测器单元 (Sensor) 是以一定频率定期从数据源收集数据, 并将数据提供给系统中的其他模块。

行为 (Activity) 是数据源中的一个实例。它可能是正常的的数据, 也可能是表示对主机或网络存在威胁的攻击数据。实验中的数据集由入侵检测系统中的一系列行为组成, 这些行为构成了分析单元的样本输入。

分析单元 (Analyzer) 是系统的核心模块, 负责分析探测器收集到的数据, 提取数据特征。在本课题中, 分析单元的功能由数据预处理和基于卷积神经网络的模型来实现。

事件 (Event) 是对原始数据进行分类后得到的结果, 能够识别出攻击数据。当系统检测到攻击数据时, 会生成事件, 并触发告警。

管理单元 (Manager) 是管理整个入侵检测系统的数据库, 数据库中存储着计算过程中的各种中间数据和最终结果数据。管理单元还能对数据进行汇总, 并生成综合报表。它还负责配置探测器单元、分析单元和事件告警单元。

2.2.2 入侵检测系统流程

入侵检测系统的工作流程包括三个主要步骤, 分别为数据预处理, 特征建模, 分类器分类。

数据预处理有两部分工作。首先是通过属性映射, 将不同类型的特征转换为数字型值, 这样便于算法处理。其次, 消除不同属性值之间的量纲差异, 通常通过数据归一化来实现^[17]。

特征建模是对数据特征进行建模, 从网络连接数据中提取特征。

分类器分类就是使用分类器对数据进行分类, 将数据分为正常数据和不同类型的攻击数据, 并输出分类结果。

设计入侵检测系统时, 需要确保系统具备以下特性, 可靠性、可用性、可验证性和准确性。这样, 系统能够高效且及时地识别出网络或系统中的异常行为, 并能够做出适当的响应。

2.3 入侵检测系统需求分析

2.3.1 现有入侵检测系统的局限性

传统的入侵检测系统主要基于规则引擎，通过预设的规则来检测网络流量和系统行为中的异常情况。然而，随着攻击手段的日益复杂，规则引擎很难准确地识别出新的攻击方式，导致误报率较高。例如，当网络中出现合法的高流量行为（如大型文件下载或在线视频观看）时，传统 IDS 可能会将其误判为 DDoS 攻击。

规则引擎需要定期更新规则库，以适应不断出现的新攻击手段。但在实际应用中，由于规则更新的速度相对较慢，无法及时应对新兴的攻击方式。例如，当一种新的恶意软件出现并开始传播时，传统的 IDS 可能需要数天甚至数周的时间来更新规则库，从而在这段时间内无法有效地检测到该恶意软件的攻击。

传统的入侵检测系统主要依赖于已知攻击模式的签名匹配，对于未知攻击或零日攻击（Zero-day Attack，这是指软件漏洞被发现后，在软件厂商发布补丁之前被攻击者利用的攻击）几乎无能为力。

2.3.2 引入机器学习算法的可行性分析

通过引入机器学习算法，入侵检测系统能自动学习网络流量和系统行为的正常模式，从而更准确地识别出异常行为^[18]。机器学习算法可以从大量的数据中提取特征，发现隐藏在数据中的规律，与传统的规则引擎相比，可以显著降低误报率和漏报率。

机器学习模型可以快速适应新的攻击方式，通过对网络数据的不断学习和更新，及时检测到未知攻击或零日攻击。这使得入侵检测系统能够更有效地保护网络和计算机系统免受新出现的威胁。

传统的入侵检测系统需要大量的人力进行规则的编写、维护和更新。本课题的系统可以通过自动学习和更新模型，减少对人工干预的依赖，从而降低企业的人力成本。

2.4 相关算法理论

2.4.1 MLP 算法

多层感知机（MLP）是一种基础的人工神经网络（ANN，Artificial Neural Network）结构，主要用于分类和回归任务。它采用全连接层结构，每一层的所有神经元与下一层的所有神经元相连，通过激活函数（如 Sigmoid、ReLU）引入非线性，能够拟合复杂的非线性关系。训练时通常采用反向传播算法，根据损失函数（如均方误差、交叉熵）的梯度来更新权重。

MLP是为了解决单层感知机的局限性而发展起来的。它是一种神经网络，其中输入与输出之间的映射是非线性的。MLP 包括输入层、输出层和一个或多个隐藏层，每个隐藏层由多个神经元堆叠在一起，结构示意图如图2.1。




图 2.1 MLP 结构示意图

在单层感知机中，神经元必须具有一个激活函数（如 ReLU 或 Sigmoid），用于设置阈值。而在 MLP 中，神经元可以使用任意的激活函数。

反向传播算法是用于训练MLP模型的关键步骤。通过计算梯度来调整权重和偏置，以最小化预测结果与真实结果之间的误差。

当前向传播的时候，输入层通过初始权重计算加权和，将结果传递给隐藏层；激活函数应用于隐藏层输出，结果继续传播至输出层；损失函数（如均方误差 MSE）计算预测值与实际值的差异。

当反向传播的时候，步骤为计算损失函数相对于每个权重的梯度；从输出层开始，通过链式法则，将误差逐层传播回去；更新每一层的权重以最小化损失函数；梯度下降中的权重更新公式在每次迭代中，通过前向传播计算所有层的加和后，利用均方误差（Mean Squared Error, MSE）计算损失，并基于损失对所有输入-输出对计算梯度。然后，通过反向传播将梯度从输出层传递回第一个隐藏层，逐层更新权重。

权重的更新公式如式（2.1）：

$$\Delta w(t) = -\epsilon \frac{dE}{dw(t)} + \alpha \Delta w(t-1) \quad (2.1)$$

其中， $\Delta w(t)$ 表示当前迭代的权重更新值。

ϵ 表示学习率，用于控制每次更新的步长。

$\frac{dE}{dw(t)}$ 表示损失函数 E 对权重 $w(t)$ 的梯度。

$\alpha\Delta w(t-1)$ 是动量项，其中 α 是动量系数， $\Delta w(t-1)$ 是上一轮的权重更新值。

这个过程会持续迭代，直到每对输入-输出的梯度收敛，即新计算的梯度变化小于指定的收敛阈值（convergence threshold）。一旦收敛，网络的权重被优化到能够最小化损失函数的值。反向传播是从输出开始回溯，逐层计算每个变量对最终输出的影响梯度。在深度学习中，这一过程用于计算模型参数的梯度，从而更新模型的权重，以最小化损失函数并提高模型的预测准确性。

2.4.2 L-SVM 算法

线性支持向量机（L-SVM, Line-Support Vector Machine）作为经典的二分类算法，其核心机制可概括为：在特征维度空间中构建最优线性决策边界。该算法接收带有类别标签的训练样本集（由特征向量及对应分类标识组成），通过优化间隔最大化原则确定分类超平面。其本质目标是寻找具备最大分类间隔的线性判别面，使不同类别数据点在特征空间中形成最宽泛的隔离带。这一过程通过支持向量驱动完成——仅依赖距离决策面最近的少量关键样本点（即支持向量）确定超平面参数，这些边界样本对分类规则的构建起决定性作用。相比传统分类模型，L-SVM通过结构风险最小化策略，在模型复杂度与泛化性能间实现更优平衡，尤其适用于中小规模数据集的精确分类任务。

该超平面如式（2.2）决策边界定义：

$$f(x) = w^T x + b \quad (2.2)$$

其中 w 是权重向量， b 是偏置项。为了使这个超平面对应的是最大间隔分类面，需要满足两个条件：一是所有正类样本位于超平面一侧；二是所有负类样本位于另一侧。

2.4.3 Q-SVM 算法

二次核支持向量机（Q-SVM）作为支持向量机家族的非线性扩展，其核心机制在于利用核方法实现数据空间的隐式维度升维。通过特定的核函数映射，该算法将低维输入特征投影至高维特征空间，使原本在原始空间中难以线性分割的复杂模式，转化为高维空间中的线性可分问题。这种映射过程无需显式计算高维坐标，而是通过核函数内积运算间接完成，从而在保留计算可行性的前提下，有效捕捉数据中蕴含的非线性关联结构。

核函数的作用在于无需显式计算高维空间中的映射，而是通过内积的方式间接完成这一过程。对于二次核函数而言，其形式通常为式（2.3）：

$$K(x_i, x_j) = (\text{langlex}_i, x_j, \text{range} + c)^2 \quad (2.3)$$

其中 c 是常数项，用于调整核函数的行为。这种核函数能够捕捉数据之间的平方级交互作用，从而适应更广泛的模式识别任务。

在优化过程中，类似于线性SVM，Q-SVM也试图解决一个凸二次规划问题。然而，由于采用了非线性核函数，目标函数的形式变得更加复杂。具体来说，在构建拉格朗日乘子法的过程中，涉及到了矩阵的定义以及其它约束条件的设置。

2.4.4 LDA 算法

线性判别分析（LDA，Linear Discriminant Analysis）是一种经典的监督学习方法，主要用于降维和分类任务。LDA算法首先将特征值从高维特征空间投影到低维特征空间中。在二维特征空间中，对于给定的特征值，LDA算法将特征值投影到一条直线上达到降维目的^[19]。

对于分类问题而言，LDA试图最大化类间的分离度，同时最小化类内的差异性。这使得同一类别的样本在投影后聚集得更紧密，而不同类别的样本之间的距离更大。

对于给定的数据集 x 和标签 y ，假设有 k 个类别，第 k 类的数据服从多元正态分布 $N(\mu_k, \Sigma)$ ，其中 μ_k 是第 k 类的均值向量， Σ 是第 k 类的相同协方差矩阵。第 k 类的先验概率为 $\pi_k = P(Y = k)$ 。

LDA的目标是最大化后验概率 $P(Y = k | X = x)$ 。根据贝叶斯定理式（2.4）：

$$P(Y = k | X = x) = \frac{\pi_k \times f_k(x)}{\sum_{i=1}^K \pi_i \times f_i(x)} \quad (2.4)$$

其中 $f_k(x)$ 是第 k 类的概率密度函数(PdF)。取对数并简化后，定义线性判别函数：

$$\delta_k(x) = \ln \pi_k + \mu_k^T \Sigma^{-1} x - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k \quad (2.5)$$

$$\tilde{y} = \arg \max_k \delta_k(x) \quad (2.6)$$

架设所有类别的协方差矩阵相同，即 $\Sigma_k = \Sigma$ ，多元正态分布的PDF为式（2.7）：

$$f_k(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (x - \mu_k)^T \Sigma^{-1} (x - \mu_k)\right) \quad (2.7)$$

由于协方差矩阵 Σ 相同，化简之后二次项可被抵消，因此判别函数为线性的。

2.4.5 QDA 算法

二次判别分析（QDA, Quadratic Discriminant Analysis）是一种基于贝叶斯定理的分类方法，其核心思想在于假设每个类别的数据服从多元高斯分布，并允许各个类别具有不同的协方差矩阵。QDA通过估计每种类别的参数并利用这些参数构建决策边界来进行分类。

具体来说，QDA的目标是找到一个最优的二次函数作为判别面，使得不同类别的概率密度函数能够被区分开来。这种方法相较于线性判别分析（LDA），不再强制要求各类别共享同一个协方差矩阵，因此可以适应更加复杂的非线性关系。

对于给定的数据集 x 和标签 y ，假设有 k 个类别，第 k 类的数据服从多元正态分布 $N(\mu_k, \Sigma_k)$ ，其中 μ_k 是第 k 类的均值向量， Σ_k 是第 k 类的协方差矩阵（不同类别间协方差矩阵不同）。第 k 类的先验概率为 $\pi_k = P(Y = k)$ 。QDA的目标是最大化后验概率。根据贝叶斯定理，后验概率可以通过先验概率和似然函数联合计算得出式（2.8）

:

$$P(Y = k | X = x) = \frac{\pi_k \times f_k(x)}{\sum_{i=1}^K \pi_i \times f_i(x)} \quad (2.8)$$

为简化计算，取对数并忽略常数项，定义判别函数 $\delta_k(x)$ 如式（2.9）：

$$\delta_k(x) = \ln \pi_k - \frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) \quad (2.9)$$

分类规则为式（2.10）：

$$\tilde{y} = \arg \max_k \delta_k(x) \quad (2.10)$$

将判别函数展开后，可见其二次性如式（2.11）：

$$\delta_k(x) = -\frac{1}{2} x^T \Sigma_k^{-1} x + \mu_k^T \Sigma_k^{-1} x - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k + \ln \pi_k - \frac{1}{2} \ln |\Sigma_k| \quad (2.11)$$

其中 $-\frac{1}{2} x^T \Sigma_k^{-1} x$ 为二次项， $\mu_k^T \Sigma_k^{-1} x$ 为线性项， $\frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k + \ln \pi_k - \frac{1}{2} \ln |\Sigma_k|$ 为常数

项。由于不同类别的协方差矩阵 Σ_k 不相同，二次项无法抵消，因此决策边界为二次曲面。这种特性赋予了QDA更强的表现力，使其适用于处理更复杂的数据结构。

2.4.6 AE 算法

自编码器在入侵检测系统中扮演了重要角色，因为它能自动提取数据中的有效特征，去除噪声。对于网络流量数据而言，通过自编码器学习得到的低维表示能够捕捉到数据的潜在结构，从而帮助检测系统更准确地判断是否存在异常行为。例如，正常的网络流量通常具有某些规律，而攻击流量可能表现出与之不同的模式。自编码器可以在不依赖标签的情况下学习这些模式，帮助识别异常流量。自编码器的优势在于它能够在大规模、复杂的数据中发现隐藏的特征，而不需要人工干预。

AE算法属于深度学习算法，AE 算法包含编码器和解码器操作，如图2.2：首先，它将输入数据向量转换为通常较低的表现形式（编码器）；接下来，它尝试从压缩向量重建原始输入（解码器）。AE 以无监督方式训练，能够从未标记数据中捕获重要特征。图3显示了具有单个隐藏层的经典 AE 模型。输入数据向量 z 被编码为较低的表现形式 e 如式（2.12）：

$$e = \varsigma (zW + b) \quad (2.12)$$

其中 W 表示权重矩阵， b 表示偏差向量， ς 表示编码器的激活函数。接下来，解码操作根据编码表示 e 重建输入 z 如式（2.13）：

$$\tilde{z} = \zeta (eW_n) \quad (2.13)$$

其中 ζ 表示解码器的激活函数， $\tilde{z}$ 是重构向量，模型结构如图2.2。

Autoencoder (AE n:m:n)




图 2.2 经典 AE 自编码模型

AE自编码器的训练目标是 최소화输入数据 X 和重建数据 X' 之间的差异，通常使用重建误差来作为损失函数。最常见的损失函数是均方误差 MSE 或交叉熵（仅对于二值数据），其中均方误差常用于连续数据如式（2.14）：

$$Loss(X - X') = \|X - X'\|^2 \quad (2.14)$$

交叉熵损失常用于处理二值数据或分类问题，如式（2.15）：

$$Loss(X, X') = -[X' \log(Xi) + (1 - X') \log(1 - Xi)] \quad (2.15)$$

通过反向传播和梯度下降，模型不断优化编码器和解码器的参数，最小化重建误差，从而学到如何有效地压缩和恢复数据。

2.4.7 LSTM 算法

长短期记忆网络（LSTM，Long Short-Term Memory）是一种特殊的递归神经网络（RNN，Recurrent Neural Network），用于处理和预测时序数据^[20]。LSTM的核心优势在于

能够捕捉数据中的长期依赖关系，这使它在时间序列分析中表现尤为突出。与普通RNN相比较，LSTM通过引入门控机制，能够有效地避免传统RNN在长序列训练过程中遇到的梯度消失问题。LSTM的结构包含输入门、遗忘门和输出门，这些门的作用是控制信息流的传递和更新，使得模型可以决定哪些信息需要保留，哪些信息需要遗忘。

在入侵检测系统中，LSTM可以有效地处理网络流量的时序数据。例如，当系统监控网络活动时，LSTM可以通过学习历史流量数据的模式，判断未来的数据是否正常或存在异常行为。因为网络流量本身具有时序特性，LSTM可以捕捉到这些时间上的变化趋势，识别出潜在的安全威胁。在本课题中，LSTM被用来处理从网络中获取的时序数据，通过训练模型让其学习正常流量和攻击流量之间的差异，进而对未知的攻击进行有效检测。

图2.3展示了一个标准LSTM架构。它包括一个单元（g）、一个输入门（i）、一个输出门（o）和一个遗忘门（l）。一层LSTM单元能够学习数据序列中时间步骤之间的长期依赖关系。这样的LSTM层有两种状态：隐藏状态（或输出状态），包含时间步骤t的输出；以及单元状态，存储从先前时间步骤中学到的信息。在每个时间步骤t，隐藏状态和单元状态都使用前面提到的门进行更新。




图 2.3 标准 LSTM 架构

遗忘门用于从单元状态中删除信息如式（2.16）。

$$l_t = \sigma(w_l[h_{t-1}, x_t] + b_l) \quad (2.16)$$

输入门用于从单元状态中添加信息，如式（2.17）。

$$i_t = \sigma(w_i[h_{t-1}, x_t] + b_i) \quad (2.17)$$

结合遗忘门和输入门的结果更新单元状态如式（2.18）。

$$\tilde{c}_t = \tanh(w_c[h_{t-1}, x_t] + b_c) \quad (2.18)$$

输出门用于从单元状态中选择有用的信息，并将其作为输出进行传输如式（2.19）式（2.20）。

$$o_t = \sigma(w_o[h_{t-1}, x_t] + b_o) \quad (2.19)$$

$$h_t = o_t \tanh(c_t) \quad (2.20)$$

式中 w 为权重矩阵； b 为偏置项； f 为遗忘门； c 为输入门； o 为输出门； σ 为 *sigmoid* 函数； $\tanh$ 为双曲正切函数。

2.5 模型评估

2.5.1 评估指标

混淆矩阵是入侵检测技术中常用的一种分类性能评价指标，混淆矩阵是一种可视化的显示工具，用来评估划分模型的优缺点及其差异。它包含四个元素：TP 为 NSL-KDD 数据集中正常流量的正常样本数，FN 为 NSL-KDD 数据集中正常流量的正常样本数，属于其他异常流量的异常样本数；FP 为 NSL-KDD 数据集中其他异常流量的正常样本数；TN 为 NSL-KDD 数据集中正常流量下的异常样本个数。混淆矩阵元素如表 2.3 所示。

表 2.3 混淆矩阵元素

真实类别	预测类别	
	正面例子	反面例子
正面例子	TP	FN
反面例子	FP	TN

基于混淆矩阵中的元素，本课题使用以下度量来评估检测：包括准确率（Accr）、精确率（Precision）、召回率（Recall）和 F1 分数。

准确率（Accuracy）表示正确流量的正常样本数占总样本容量的百分比，是系统评估所有攻击和等级能力的基准，是衡量模型能力的指标，它的公式为式（2.21）。准确率就是模型判断正确的流量（无论是正确判断为正常的，还是正确判断为入侵的）占总流量的比例，越高说明模型整体判断准的概率越大，就像一个学生考试的总分正确率。

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (2.21)$$

精确率（Precision）叙述了全部被检测为正类的样本之中被分类正确的正例样本的占比，它表达了模型对于各个类别的分类能力，它的公式为式（2.22）。

$$Precision = \frac{TP}{TP + FP} \quad (2.22)$$

召回率（Recall）表示预测正确的正例样本占实际正例样本的百分比，它的公式为式（2.23）。

$$Recall = \frac{TP}{TP + FN} \quad (2.23)$$

F1分数本身可能不会产生所有可能的结果，它的公式为式（2.24）。数提供了一种更准确的衡量成绩的方法，因为F1分数同时包含准确率和召回率信息。

$$F1 - score = \frac{2 \times Recall \times Precision}{Recall + Precision} \quad (2.24)$$

2.5.2 损失值

损失函数是模型评估性能的一个重要指标，它能够衡量模型预测与实际标签之间的差距。

在二分类任务中，常使用二元交叉熵损失（Binary Cross-Entropy Loss）来计算损失。交叉熵损失在处理分类问题时非常常用，尤其是在二分类问题中，它反映了模型输出的概率分布与真实标签之间的不匹配程度。对于每个样本，交叉熵损失计算的是模型预测概率与真实标签之间的差异，如式（2.25）。

$$Loss(p, y) = -[y \log(p) + (1 - y) \log(1 - p)] \quad (2.25)$$

y 是实际标签（0 或 1），表示样本是否属于正类（例如，正常或攻击）。

p 是模型输出的概率值，表示样本属于正类的预测概率。

在多分类任务中，常使用交叉熵损失（CrossEntropyLoss）。交叉熵损失衡量模型预测的概率分布与真实分布之间的差异，常用于多分类任务。它通过最小化两者差异来优化模型参数，使预测更接近真实标签。

对于真实分布 p 和预测分布 q ，交叉熵定义为式（2.26）：

$$H(p, q) = -\sum_{i=1}^c p_i \log q_i \quad (2.26)$$

分类任务中，真实标签 p 通常为 one-hot 编码（如第 k 类为 1，其余为 0），预测值 q 由 softmax 生成概率分布。此时交叉熵简化为式（2.27），即仅计算正确类别的预测概率的负对数。

$$Loss = -\log q_k \quad (2.27)$$

模型输出的原始分数（logits）通过 softmax 转换为概率如式（2.28）：

$$q_i = \frac{\exp(z_i)}{\sum_{j=1}^C \exp(z_j)} \quad (2.28)$$

确保式（2.28）中的 $\sum q_i = 1$ ，符合概率分布。

损失函数作为模型性能的核心评估指标，其数值变化直接反映预测结果与真实分布的契合程度。当损失值处于较低水平时，表明预测概率分布与真实标签的匹配度显著提升，此时模型展现出的分类或回归能力更为优异。反之，若损失值出现显著上升，则意味着预测结果与实际数据分布存在明显偏离，这种偏差直接导致模型泛化性能的弱化。从数学本质而言，优化过程通过最小化损失函数来逼近真实数据分布，因此损失值的变化曲线可视为模型性能优劣的直观量化指标——较小的损失值对应更优的决策边界拟合效果，而增大的损失值则预示着模型需要进一步调整参数以改善对数据模式的捕捉能力。

在训练过程中，目标是通过优化损失函数（通过反向传播算法），使得损失值不断减小，从而提高模型的准确性。损失函数不仅用于评估模型的预测效果，还直接影响着模型参数的调整。

第三章 基于机器学习的入侵检测的设计

3.1 数据集介绍

NSL-KDD 是原始 KDD99 数据集的一个子集，它被广泛用作多个入侵检测系统的基准。NSL-KDD 克服了之前 KDD99 基准的一些限制，例如训练和测试集中的冗余和重复记录，这些限制使分类器偏向更频繁的样本。NSL-KDD 是加拿大网络安全研究所免费提供的数据集。它有训练和测试数据集，这里表示为 KDDTrain+和知识发现Test+，分别包括 125,973 和 22,544 个实例。具体而言，由于 KDDTest+数据集包括 17 种额外的攻击类型，这些类型未包含在 KDD Train+，为了公平评估，删除了与此类类别对应的实例（3751）。结果，KDDTest+包含 $22,544 - 3751 = 18,793$ 个示例。NSL-KDD 数据集有 41 个特征如错误!未找到引用源。。

表 3.1 NSL-KDD 的 41 个有效特征

序号	特征全称	特征含义	类型	范围
1	duration	连接持续时间（秒）	连续型	(0, 58329)
2	protocol type	协议类型（TCP、UDP、ICMP）	离散型	/
3	service	目标主机的网络服务类型（如 HTTP、FTP）	离散型	/
4	flag	连接状态标识（如 SYN、FIN）	离散型	/
5	source bytes	源主机到目标主机的字节数	连续型	(0, 1.38e9)
6	Destination bytes	目标主机到源主机的字节数	连续型	(0, 1.31e9)
7	land	若连接来自/送达同一主机和端口则为 1，否则为 0.	离散型	0 或 1
8	Wrong fragement	错误分段数量（不符合协议规范的数据包）	连续型	(0, 3)
9	urgent	TCP 紧急标志（URG）的数据包数量	连续型	(0, 14)
10	hot	访问敏感文件和目录的次数	连续型	(0, 101)
11	Num failed logins	登陆尝试失败次数	连续型	(0, 5)
12	Logged in	成功登陆则为 1，否则为 0	离散型	0 或 1

13	Num compromised	被入侵的主机数量	连续型	(0, 7479)
14	Root shell	若获得 root 权限的 shell 则为 1, 否则为 0	离散型	0 或 1

表 3.2 (续) NSL-KDD 的 41 个有效特征

序号	特征全称	特征含义	类型	范围
15	Su attempted	若尝试执行 su root 命令则为 1, 否则为 0	离散型	0 或 1
16	Num root	Root 用户访问次数	连续型	(0, 7468)
17	Num file creations	文件创建操作次数	连续型	(0, 100)
18	Num shells	使用 shell 命令的次数	连续型	(0, 5)
19	Num access files	访问控制文件的次数	连续型	(0, 9)
20	Num outbound cmds	FTP 会话中出站连接次数 (该特征在数据中全为 0)	连续型	0
21	Is host login	若登录属于 “hot” 列表则为 1, 否则为 0	离散型	0 或 1
22	Is guest login	若访客登陆 “hot 列表” 则为 1, 否则为 0	离散型	0 或 1
23	Count	过去 2 秒内相同目标主机的连接数	连续型	(0, 511)
24	Srv count	过去 2 秒内相同服务的连接数	连续型	(0, 511)
25	Serror rate	相同目标主机的连接中 SYN 错误百分比	连续型	(0.00, 1.00)
26	Srv serror rate	相同服务的连接中 SYN 错误百分比	连续型	(0.00, 1.00)
27	Rerror rate	相同目标主机的连接中 REJ 错误百分比	连续型	(0.00, 1.00)
28	Srv rerror rate	相同服务的连接中 REJ 错误百分比	连续型	(0.00, 1.00)
29	Same srv rate	相同目标主机和服务连接的百分比	连续型	(0.00, 1.00)
30	Diff srv rate	相同目标主机但不同服务连接的百分比	连续型	(0.00, 1.00)

31	Srv diff host rate	相同服务但不同目标主机连接的百分比	连续型	(0.00, 1.00)
32	Dst host count	前 100 个连接中相同目标主机的连接数	连续型	(0, 255)
33	Dst host srv count	前 100 个连接中相同目标主机和服务的连接数	连续型	(0.00, 255)
34	Dst host same srv count	前 100 个连接中相同目标主机和服务的连接占比	连续型	(0.00, 1.00)

表 3.3 (续) NSL-KDD 的 41 个有效特征

序号	特征全称	特征含义	类型	范围
35	Dst host diff srv rate	前 100 个连接中相同目标主机但不同服务的连接占比	连续型	(0.00, 1.00)
36	Dst host same src port rate	前 100 个连接中相同目标主机和源端口的连接占比	连续型	(0.00, 1.00)
37	Dst host srv diff host rate	前 100 个连接中相同目标主机和服务但不同源主机的连接占比	连续型	(0.00, 1.00)
38	Dst host serror rate	前 100 个连接中相同目标主机和的 SYN 错误连接占比	连续型	(0.00, 1.00)
39	Dst host srv serror rate	前 100 个连接中相同目标主机和服务 dSYN 错误连接占比	连续型	(0.00, 1.00)
40	Dst host rerror rate	前 100 个连接中相同目标主机的 REJ 错误连接占比	连续型	(0.00, 1.00)
41	Dst-host srv rerror rate	前 100 个连接中相同目标主机和服务的 REJ 错误连接占比	连续型	(0.00, 1.00)

此外, NSL-KDD 数据集中的攻击类型可分为四个不同的攻击类别, 如表3.4。下列介绍一下四个攻击类别。

DoS (拒绝服务) 通过向服务器发送超过系统处理能力的流量信息, 导致机器变慢或关闭。DoS攻击会影响合法的网络流量或对服务的访问。

R2L (远程) 是包括通过向系统发送远程欺骗数据包来提供对机器的非法本地访问的攻击。

U2R（本地提权）是包括提供根访问权限的攻击。在这种情况下，黑客确定系统漏洞并开始以普通用户身份使用系统。

扫描（Probing）是包括通过收集有关网络的信息来逃避安全控制系统的攻击。

表 3.4 NSL-KDD 中的攻击类型

数据类型	KDDTrain+	KDDTest+
DoS	45926	7458
R2L	995	2754
U2R	52	200
扫描	11655	2421
正常	67345	9711
总计	125973	22544

3.2 数据预处理

NSL-KDD 数据集从不一致的值（异常值）中过滤出来，这是数据规范化之前的一个重要操作。已知异常值会干扰学习过程，导致入侵检测系统中的漏检。数据标准化通常指的是将数据的每个特征减去均值，然后除以标准差，使得数据的分布具有零均值和单位方差^[21]。本课题使用Z-score标准化方法来处理，其公式为式（3.1）：

$$X_{\text{standardized}} = (x - \mu) / \sigma \quad (3.1)$$

其中：X 是原始数据， μ 是数据的均值， σ 是数据的标准差，对于缺失值使用0填充。

本课题并没有显式地进行异常值检测和删除，因为使用Z-score标准化，这本身就能在一定程度上处理异常值的影响。通过对于缺失值统一用0填充，对于数值型特征，保留了原始数据，没有进行异常值过滤，使得标准化后的数据有以下特点：所有数值型特征的均值为0；标准差为1；数据分布更加集中，有利于模型训练；不同特征之间的尺度差异被消除。

数据预处理步骤中，数据标准化化对实验有着重要意义：可以提升深度学习模型的收敛速度，节省网络学习的计算资源和时间成本；可以在一定程度上避免因奇异数据引起的无法收敛的问题；可以在一定程度上避免因数据量级差别大而使部分特征被掩盖的问题。

3.3 特征工程

3.3.1 特征分析

特征分析的目的是全面理解数据分布和特征间的关系，为后续模型训练提供依据。具体流程为对数据集中所有数值型特征（如流量包大小、持续时间等）进行统计描述：

计算均值、标准差等基础统计量，分析特征的分布范围和离散程度。表3.5显示了部分特征的均值与标准差^[21]。

表 3.5 部分特征的均值与标准差

特征名称	均值	标准差
src_bytes	45567.10082399263	5870354.480802253
dst_bytes	19779.27143333439,	4021285.112110193
logged_in	0.3957387355920363	0.48901072282187213
...	...	...

对类别型特征（如协议类型、IP地址类别等）进行分布统计：统计每个类别的出现频率，本课题对TCP、UDP、ICMP这三个协议类型进行统计。下面介绍一下三个协议类型：

TCP 是一种面向连接的可靠传输协议，提供有序的数据流传递服务并确保数据包按顺序到达目标设备。

UDP 提供了一种无连接的服务模式，相较于 TCP 更加轻量级但也缺乏可靠性保障机制。因此，在某些实时性强但容忍一定丢包率的应用场景下（如视频会议或在线游戏），会选择采用 UDP 进行数据交换。

ICMP 主要用于发送错误消息以及相关信息来处理 IP 层遇到的问题，例如主机不可达、路由重定向等事件通知。虽然严格意义上不属于传输层范畴，但在实际日志记录或者特征提取过程中也可能单独标记出来作为一类特殊用途的协议形式。

表3.6为TCP、UDP、ICMP这些协议类型的数据集中分布情况：

表 3.6 数据集中协议类型的分布情况

协议类型	在总体数据中占比	在攻击类型中占比
TCP	81.52%	38.82%
UDP	11.90%	32.28%
ICMP	6.58%	24.79%

3.3.2 独热编码

本课题使用独热编码技术将协议类型、服务（service）和标志（flag）这三个分类特征转换为数值。具体来说，每个分类属性都用二进制值表示。例如，协议类型有三个属性：TCP、UDP和ICMP，使用独热编码技术，分别将它们转换为二进制向量，例如：[1,0,0]、[0,1,0]、[0,0,1]。类似地，服务和标志也被转换为独热编码向量。总体而言，41维特征被映射到 122 维特征。

以标志（flag）为例的独热编码如表3.7所示：

表 3.7 flag 的独热编码

flag 编号	编码
flag_1	[1,0,0,0,0,0,0]
flag_2	[0,1,0,0,0,0,0]
flag_3	[0,0,1,0,0,0,0]

flag_4	[0,0,0,1,0,0,0,0]
flag_5	[0,0,0,0,1,0,0,0]
flag_6	[0,0,0,0,0,1,0,0]
flag_7	[0,0,0,0,0,0,1,0]
flag_8	[0,0,0,0,0,0,0,1]

3.3.3 数据划分

数据划分为机器学习中的一个重要概念，指的是将原始数据集按照一定比例分成若干子集的过程。通常情况下，数据会被划分为三个主要部分：训练集（Training Set）、验证集（Validation Set）和测试集（Test Set）。这种划分的主要目的是为了确保模型能够有效地泛化到未见过的数据。训练集用于构建和调整模型参数的部分，使模型能够从数据中学习模式。验证集用于调参或选择最佳模型版本的部分，在此阶段可以优化超参数并防止过拟合。测试集用于最终评估模型性能的部分，提供关于模型在新数据上的表现的信息。

数据划分可以防止过拟合，通过分离出独立的测试集，可以在不干扰模型训练的情况下评估其真实性能。这样能有效检测是否存在过拟合现象，即模型仅对训练数据表现出色但在未知数据上效果较差的情况。也可以提高模型可靠性，合理的数据划分有助于提高模型预测能力的一致性和稳定性。当模型经过充分训练并在验证集中进行了适当调节后，再利用完全隔离的测试集来衡量其实际效能，则可获得更可靠的评价指标。还可以保证资源高效分配，对于大规模数据集而言，合理规划各阶段所需样本量不仅节约计算资源还能加快实验进程。例如设置较小比例作为验证/测试用途即可满足需求而不必浪费过多实例参与非必要环节。

本课题采用 10 折交叉验证法评估模型性能。该方法将完整数据集随机均分为十组等容量子集，每轮迭代选取一组作为独立测试集，其余九组合并构建训练集。通过十轮循环验证，确保每个样本均参与过测试过程，最终整合十次评估结果计算综合指标。这种策略有效规避了单次划分可能引入的样本偏差，通过多轮迭代平均更客观反映模型泛化能力，尤其适用于中小规模数据集的稳定性能评估。

3.4 模型构建

3.4.1 模型对比

（1）二分类实验分析

通过对这些算法进行二分类实验，实验中的异常类别涵盖了 DoS、Probe 以及 R2L 这三个类别。结果显示，MLP 分类器在检测正常类别时的 F1 得分为 86.65%，在检测异常类别时的 F1 得分为 70.69%。将 Q-SVM 分类器与 SVM 分类器做对比可以发现，Q-SVM 分类器的平均 F1 得分率优于 L-SVM，二者的平均 F1 得分率分别为

81.39% 和 77.54%。具体来讲, 在检测正常和异常类别方面, Q-SVM 分类器都展现出了更佳的性能, 其对应的 F1 得分分别为 87.87% 和 74.90%。再来看 QDA 分类器和 DA 分类器的比较, QDA 分类器的平均 F1 得分胜过 LDA, 二者的平均 F1 得分分别为 77.78% 和 75.16%。不过, LDA 分类器在检测正常样本时取得了更好的 F1 Score 分数, 为 85.26%, 而 QDA 在检测异常方面表现最为出色, F1 得分为 71.66%。和深度分类器比较的话, LSTM 架构的平均 F1 得分是 79.24%。而我们所提出的深度 AE 分类器的 F1 得分是最高的, 平均值达到了 82.00%。除此之外, 基于 AE 的分类器在准确度上也超过了上述提到的那些方法(具体可以参见表 3.8 表 3.9 表 3.10)。此分类器与 LSTM、MLP、L-SVM、Q-SVM、LDA 以及 QDA 分类器相比, 准确度为 84.21%, 而后者们的准确度分别对应的是 82.04%、81.65%、80.8%、83.15%、79.27% 和 76.84%。

表 3.8 二分类精确度报告

类别	精确度						
	AE	LSTM	MLP	L-SVM	Q-SVM	LDA	QDA
正常	81.09%	79.00%	78.49%	77.68%	80.84%	75.81%	81.08%
异常	92.91%	91.25%	91.57%	90.96%	91.34%	92.38%	76.34%
平均	87%	85.13%	85.03%	84.32%	86.09%	84.09%	78.71%

表 3.9 二分类召回率报告

类别	召回率						
	AE	LSTM	MLP	L-SVM	Q-SVM	LDA	QDA
正常	96.96%	96.47%	96.69%	96.55%	96.24%	97.41%	86.94%
异常	63.79%	58.92%	57.57%	55.56%	63.48%	50.22%	67.52%
平均	80.37%	77.70%	77.13%	76.06%	79.86%	73.81%	77.23%

表 3.10 二分类 F1 Score 报告

类别	F1 Score						
	AE	LSTM	MLP	L-SVM	Q-SVM	LDA	QDA
正常	88.32%	86.86%	86.65%	86.09%	87.87%	85.26%	83.91%
异常	75.64%	71.61%	70.69%	68.99%	74.90%	65.07%	71.66%
平均	81.98%	79.24%	78.67%	77.54%	81.39%	75.16%	77.78%

(2) 多分类实验报分析

通过对这些算法进行多分类实验。实验中, 比较了多种分类器的性能, 包括浅层的 MLP、L-SVM、Q-SVM、LDA、QDA, 以及基于深度学习的 LSTM 和 AE 分类器。

实验结果表明, MLP 分类器对正常、DoS 和 Probe 攻击类别的 F1 得分分别是 87.1%、97.08% 和 77.13%。L-SVM 分类器的平均 F1 得分为 75.11%, Q-SVM 分类器的平均 F1 得分为 69.76%, Q-SVM 分类器优于 L-SVM 分类器。具体来说, L-SVM 对正常、DoS 和 Probe 攻击类的 F1 得分分别是 86.55%、96.69% 和 86.22%。而 Q-SVM 对正常、DoS 和 Probe 攻击类的 F1 得分分别是 88.32%、97.41% 和 82.81%。

另一方面, LDA 分类器的平均 F1 得分为 76.49%, 优于 QDA 分类器的 64.36%。LDA 分类器的 F1 得分分别是 90.69%、91.14% 和 70.87%。QDA 分类器在正常、DoS 和 Probe 攻击类别中的 F1 值分别是 87.98%、74.64% 和 47.86%。但是, 基于 MLP、L-SVM 和 Q-SVM 的分类器在检测 R2L 攻击类别时效果不理想, F1 得分分别为 11.74%、9.45% 和 31.90%。相比之下, DA 分类器在检测 R2L 异常方面表现更好, LDA 的 F1 Score 得分为 53.27%, QDA 的 F1 得分为 46.96%。

与深度分类器相比, LSTM 架构的平均 F 值为 67.17%。LSTM 分类器在检测正常、DoS 和探测攻击类型方面表现出色, F1 Score 值分别为 86.12%、96.90% 和 84.05%。但在检测 R2L 攻击类别方面仍有不足。

最后, 深度 AE 分类器的表现优于所有其他机器学习算法, F1 分数高达 98%。AE 分类器的准确率也优于传统机器学习技术, 最高的准确率达到 87%。相比之下, LSTM、MLP、L-SVM、Q-SVM、LDA 和 QDA 分类器的准确率分别达到了 80.67%、81.43%、81.4%、83.65%、83.17% 和 79.47%, (具体如表3. 11表3. 12表3. 13)。

表 3. 11 多分类准确率报告

类别	准确率						
	AE	LSTM	MLP	L-SVM	Q-SVM	LDA	QDA
正常	85.03%	77.70%	79.46%	78.37%	81.35%	88.01%	84.28%
Dos	97.05%	96.39%	97.21%	96.52%	97.71%	95.45%	97.79%
Probe	69.82%	75.26%	64.33%	77.03%	71.15%	60.20%	31.62%
R2L	99.49%	80.00%	99.19%	95.15%	98.68%	79.62%	99.34%
平均	87.85%	82.34%	85.05%	86.77%	87.22%	80.82%	78.26%

表 3. 12 多分类准确率报告

类别	召回率						
	AE	LSTM	MLP	L-SVM	Q-SVM	LDA	QDA
正常	96.19%	96.58%	96.35%	96.64%	96.59%	93.53%	92.02%
Dos	98.18%	97.42%	96.96%	96.86%	97.11%	87.19%	60.35%
Probe	94.03%	95.16%	96.29%	97.90%	99.03%	86.13%	98.39%
R2L	39.78%	0.81%	6.24%	4.97%	19.03%	40.03%	30.75%
平均	82.04%	72.49%	73.96%	74.09%	77.94%	76.72%	70.38%

表 3. 13 多分类准确率报告

类别	F1 Score						
	AE	LSTM	MLP	L-SVM	Q-SVM	LDA	QDA
正常	90.27%	86.12%	87.10%	86.55%	88.32%	90.69%	87.98%
Dos	97.61%	96.90%	97.08%	96.69%	97.41%	91.14%	74.64%
Probe	80.14%	84.05%	77.13%	86.22%	82.81%	70.87%	47.86%
R2L	56.83%	1.61%	11.74%	9.45%	31.90%	53.27%	46.96%
平均	81.21%	67.17%	68.26%	69.73%	75.11%	76.49%	64.36%

实验采用包括精确度、召回率、F1 分数和准确率在内的标准指标来评估所提出的入侵检测系统的有效性。通过统计分析提取相关性最高的特征, 并将其作为输入, 输入到深度自编码器 和 LSTM 架构, 以及浅层机器学习方法 (包括多层感知器 MLP、L-SVM

、Q-SVM、LDA 和 QDA）。此外，还执行了二分类（正常 vs 异常）和多分类任务。实验结果表明，与浅层机器学习架构相比，Q-SVM 分类器在二分类（准确率 83.15%）和多分类（准确率 83.65%）方面均取得了最佳性能。就深度 ML 架构而言，与 LSTM 分类器相比，AE 分类器在二分类（准确率 84.21%）和多分类（准确率 87%）方面均取得了最高的性能。因此，对浅层和深度分类器进行整体比较评估表明，AE 架构优于所有其他 ML 方法。

综上所述，本课题选择将LSTM与自编码器结合，设计了一个既保留LSTM处理时序数据的优势，又能利用自编码器进行特征提取的能力，同时提高了模型的泛化能力的模型。

3.4.2 基于自编码器的 LSTM 模型

将LSTM与自编码器结合，能够更好地处理复杂的入侵检测任务。LSTM负责处理时序数据中的时间依赖关系，而自编码器则通过特征提取来压缩和抽象数据。两者结合后，LSTM可以处理数据的时序性，并通过自编码器进行特征的降维和精炼，从而使得模型能够在处理高维数据时更加高效。

图3.1展示了所提出的基于 AE 的 LSTM 模型架构，即 AE 分类器。具体而言，AE 将 128 维特征表示 z 编码为 32 维向量 e ，然后将其解码回相同的输入特征空间。




图 3.1 LSTM 和自编码器的融合模型结构

在本课题中，LSTM和自编码器的融合模型首先通过自编码器提取网络流量的有效特征，然后将这些特征输入到LSTM网络中进行时序建模。这种结合方式能够使模型在识别入侵行为时，不仅关注数据的时间变化，还能够更好地理解数据的内在结构。通过多任务学习的方式，融合模型还可以进一步提高准确性和鲁棒性。与传统的单一模型相比，

LSTM和自编码器的结合能够使入侵检测系统更加灵活，识别更加复杂和多样化的攻击模式，具有更强的泛化能力。

3.4.3 知识蒸馏架构

在模型构建部分，入侵检测系统采用知识蒸馏（Knowledge Distillation）架构，包含教师模型和学生模型。知识蒸馏是一种机器学习技术，目的是将预先训练好的大型模型（即“教师模型”）的学习成果转移到较小的“学生模型”中。这种知识蒸馏的策略学习的是教师模型(结构较为复杂的模型)的输出分布(logits)，这种分布信息比原始的(0-1)label具有更加丰富的信息，能够让学生模型(架构较为简单的模型)取得更好的效果。在深度学习中，它被用作模型压缩和知识转移的一种形式，尤其适用于大规模深度神经网络。知识蒸馏的本质是知识迁移，模仿教师模型的输出分布，使学生模型继承其泛化能力与推理逻辑。

知识蒸馏算法由三部分组成，分别是：知识（Knowledge）、蒸馏算法（Distillation algorithm）、师生架构（Teacher-student architecture），一般的师生架构如图3.2图3.2 师生模型架构所示：




图 3.2 师生模型架构

教师模型先由自编码器进行特征降维，接着再通过双向LSTM层（2层，隐藏层大小为256）、Dropout层（0.5）和全连接层构成；学生模型作为简化版，包含自编码器（编码维度32）、双向LSTM层（1层，隐藏层大小128）、Dropout层（0.3）和全连接层。

知识蒸馏过程分为两步：首先，使用完整数据集训练教师模型，使其能学习到复杂的特征表示并生成软标签（soft labels）；然后，学生模型在训练时同时使用教师模型的软标签和原始标签，其损失函数包含两部分，即学生模型预测与真实标签的差异（hard_loss）以及学生模型预测与教师模型软标签的差异（soft_loss），概率公式为式（3.2）。

$$q_i = \frac{\exp(Z_i/T)}{\sum_j \exp(Z_j/T)} \quad (3.2)$$

T为温度参数（temperature），用于调整软标签的概率分布，使学生模型能够更好地吸收教师模型的知识。在训练过程中，先完成教师模型的训练，再通过知识蒸馏让学生模型学习，同时使用验证集监控性能，以保存最佳模型。这种方法旨在利用教师模型的强大特征提取能力，指导学生模型在保持较小模型规模的同时获得较好的性能，从而提高入侵检测系统的效率和准确性。

3.5 模型训练过程

在训练过程中，首先加载并处理数据集。数据经过标签编码和特征选择，保留最有助于分类的特征。数据集被划分为训练集、验证集和测试集，且所有特征都进行了标准化处理，以确保模型的训练更加稳定。训练数据和验证数据通过 PyTorch 的 DataLoader 进行批次加载。

训练中采用了 Adam 优化器及 BCELoss。该自适应学习率算法可加速训练并防止梯度异常，确保模型稳定收敛^[22]。BCELoss 则适用于二分类任务，用于计算模型输出与实际标签之间的差异。每一轮训练过程中，模型会根据训练数据进行前向传播、计算损失、进行反向传播更新网络参数。每个 epoch 的训练过程中，模型会根据训练集和验证集的损失情况进行调整。模型训练时会输出每个 batch 的训练损失，并且在每个 epoch 结束后评估验证集的表现。通过在验证集上的损失和准确率，能够监控模型是否出现过拟合。训练结束后，模型在测试集上的性能得到评估，计算并输出准确率。最终，训练好的模型会被保存，以便后续使用和推理。

第四章 系统设计与实现

本课题是一个基于Django的入侵检测系统，集成了机器学习模型，主要功能包括：用户认证和管理、入侵检测模型的管理和调优、网络流量分析、IP规则管理、数据可视化展示。

项目使用了Django的MVT（Model-View-Template）架构，并集成了多个第三方库来支持机器学习功能。系统采用了模块化的设计，便于维护和扩展。

4.1 入侵检测系统的数据表设计

用户表用于存储系统用户的信息，涵盖普通用户和超级管理员。用户表结构如表4.1所示：

表 4.1 用户表

编号	字段	类型	说明
1	id	int	主键，标识用户
2	username	string	用户账号
3	nickname	string	用户别名
4	password_hash	string	密码哈希值
5	password_salt	string	加密盐值
6	status	int	用户状态，用于区分状态
7	create_at	date	创建时间
8	update_at	date	更新时间
9	is_authorize	bool	是否授权

设计用户表的目的是为了对系统用户进行统一管理，确保只有授权用户能够访问和操作入侵检测系统。通过存储用户的基本信息、认证凭据和状态，系统可以实现用户的身份验证、授权管理和账户维护等功能。

任务表用于存储扫描任务的信息及结果，结构如表4.2：

表 4.2 任务表

编号	字段	类型	说明
1	task_id	int	主键，标识扫描任务
2	user	string	外键，关联 user 表的 id
3	temp_result_file_path	string	临时保存目录地址
4	start_time	date	启动时间
5	end_time	date	结束时间
6	exec_time	date	执行任务时间
7	status	string	任务状态

任务表的设计旨在记录和管理入侵检测系统中的扫描任务。它关联了用户表，以便追踪任务的创建者和执行者。通过存储任务的启动时间、结束时间、执行时间以及状态

等信息，系统可以对任务进行有效的调度、监控和结果分析，帮助管理员了解任务的执行情况和结果，以便及时采取相应的措施。

模型调优表用于存储用户对模型的每一次调优参数及对应结果，结构如表4.3：

表 4.3 模型调优表

编号	字段	类型	说明
1	tuning_id	int	主键，标识每一次调优任务
2	user	string	外键，关联用户表用户
3	tuning_model	string	调优模型标识，模型名称
4	start_time	date	开始调优时间
5	end_time	date	结束调优时间
6	lr	float	调优参数：学习率
7	wd	float	调优参数：权重衰减
8	batch_size	int	调优参数：批量大小
9	num_epochs	int	调优参数：训练轮数
10	accuracy	float	调优结果：验证集准确率
11	loss	float	调优结果：验证集损失率
12	test_accuracy	float	调优结果：测试集准确率
13	create_at	date	调优任务写入时间

模型调优表的设计是为了记录和分析用户在入侵检测模型调优过程中的参数设置和结果。通过存储调优任务的详细信息，包括调优模型、开始和结束时间、调优参数（如学习率、权重衰减、批量大小和训练轮数）以及调优结果（如验证集准确率、损失率和测试集准确率），系统可以为用户提供了一种追踪模型性能和优化过程的手段。这有助于用户不断改进和优化入侵检测模型，提高其准确性和有效性。

4.2 入侵检测系统的 Web 服务系统设计

前端提供页面展示，后端提供实际功能接口，数据库提供数据存储能力。用户在前端操作后，对应操作会请求到后端，后端对数据库进行增删改查等操作，同时将结果反馈到前端。前后端通信示意图如图4.1所示。




图 4.1 前后端通信示意图

本课题的前端页面设计使用 HTML 构建用户界面。后端逻辑处理使用了 Django 的视图函数或类视图处理请求，并与数据库交互。前后端数据交互是通过 AJAX 或表单提交将前端数据发送到后端，并将后端处理结果返回给前端。路由配置方法为使用 Django 的 URL 配置将请求路由到对应的视图函数。模板渲染使用了 Django 模板引擎将后端数据动态渲染到前端页面。

4.3 入侵检测系统的模块实现

4.3.1 用户登录模块

本界面用户可以输入的用户名以及键入密码，系统对用户输入的用户名和，密码以及验证码进行相应的验证，如果结果的检验符合要求。那么系统就会根据用户输入的用户名进行到系统查询界面，界面展示如图 4.2。



图 4.2 用户登录界面

本课题使用captcha模块实现随机验证码功能，Django自带的form模块实现表单自动化验证的功能，使用md5+salt算法加密用户密码，避免明文保存，向用户的密码中加入一个随机生成的字符串，然后对这个组合进行MD5加密，可以有效地防止彩虹表攻击和生日攻击，因为即使是相同的密码，加上不同的Salt后也会生成不同的哈希值。

4.3.2 数据集分析模块

将前端上传的测试集文件进行初步校验后，将数据读出来，再根据用户选择的模型，送到入进行检测。




图 4.3 测试集攻击类型分布

图4.3展示了测试集中不同攻击类型的具体分布情况与占比。

协议类型统计

测试集中TCP、UDP和ICMP等不同网络协议的使用频率分布，帮助理解网络流量特征。




图 4.4 协议类型统计

图4.4为测试集中协议类型分布的统计情况，通过对不同协议类型的流量进行统计，IDS 可以根据协议类型的异常波动等特征识别出正常的网络行为与潜在的攻击行为。此

外不同的攻击可能集中在特定的协议上，例如 DDoS 攻击常常伴随着大量的 ICMP 或 UDP 流量，而 TCP 攻击可能集中在特定的端口或连接方式上。入侵检测系统还可以根据协议类型统计可以分析流量的正常模式和攻击时的异常模式，进而建立基准并实时监控。通过这种方式，IDS 能够对网络流量的特征进行建模，从而更好地检测和防止。




图 4.5 服务类型 TOP10 统计

图4.5展示了常见的服务类型 TOP10 ，表4.4对此做了详细说明。

表 4.4 服务类型 TOP10 说明

服务类型	数量	协议/端口	说明
HTTP	7853	TCP/80	超文本传输协议，用于网页浏览
Private	4774	自定义端口（非标准）	企业或组织内部定义的非公开服务，通常用于专用网络通信
Telnet	1626	TCP/23	远程终端协议，用于明文远程登录和管理设备
POP3	1019	TCP/110	邮局协议第 3 版，用于从邮件服务器下载电子邮件
SMTP	934	TCP/25	简单邮件传输协议，用于发送电子邮件
Domain_u	894	UDP/53, TCP/53	DNS 服务的变体，用于域名解析（可能为内部定制版本）
ftp_data	851	TCP/20	FTP 数据通道，用于文件传输时的实际数据传输
other	838	多种	未明确分类的其他服务类型（如自定义协议或非标准端口）
Ecr_i	752	自定义端口（非标准）	企业自定义服务（如 Enterprise Custom

1)，可能用于内部系统通信			
FTP 控制通道，用于建立和管理文件传输会话			
FTP	692	TCP/21	




图 4.6 连接时长分布统计

图4.6为连接时长的分布统计情况。连接时长分布通常指的是在特定时间段内，网络连接持续的时间分布情况。入侵检测系统通过分析连接时长，可以识别出某些异常的连接模式。长时间的连接可能指示着持续的数据泄露、远程控制或信息收集等活动。

通过连接时长分布的统计可以帮助管理员在海量数据中找出异常的连接模式，进而发现安全威胁、优化资源使用和提升系统的整体安全性。

4.3.3 模型测试模块

此模块允许上传指定的测试集数据进行数据检测，通过机器学习训练出的模型进行结果预测，同时需要将预测结果进行展示更新。界面如图 4.7。



图 4.7 模型测试界面

点击“选择文件”按钮开始上传测试数据集，用户可以选择相关网络流量测试集进行恶意流量检测。

点击“二分类模型”按钮，系统会切换为二分类的模型。

点击“多分类模型”按钮，系统会切换为多分类的模型。

点击“开始检测”按钮，会将数据集上传系统，系统会根据选择的模型类别去做相应的恶意流量检测的任务。




图 4.8 测试集二分类检测报告

二分类：使用训练后的模型进行测试，选择KDD_Test+.txt进行模型测试，能够展示准确率和恶意流量占比，图4.8为二分类检测报告，可以看到模型测试出正常流量占比为43.08%。恶意流量占比为56.92%，模型准确度为76.91%。




图 4.9 测试集多分类检测报告

多分类：使用训练后的模型进行测试，选择KDD_Test+.txt进行模型测试，能够展示准确率以及具体被模型检测出恶意流量的类别。图4.9可以看到此模型检测出了11种不同的攻击类型，这些类型都属于Dos、Probe、R2L和U2R，此外正常流量占比最大，但是模型准确率不太理想，可以通过后续模型调优来调整准确率，从而可以更精准的检测恶意流量类别。

4.3.4 模型预览图

左侧使用了柱状图，可直观对比两模型在验证集、测试集准确率及损失值的差异，展示了二分类和多分类的模型指标的对比，如验证集准确率、损失值和测试集准确率。右侧使用了雷达图，展示多维度指标（如精确率、召回率、F1分数），方式展示了二分类和多分类的模型指标的对比。



图 4.10 模型分析结果

如图4. 10，结合雷达图与堆叠柱状图的综合展示，可以得到在二分类模型上表现数据为验证集准确率（96.98%），损失值（0.12），测试集准确率（76.91%）。在多分类模型上表现数据为验证集准确率（99.31%），损失值（0.41），测试集准确率（69.56%）。

4.3.5 模型调优

通过调整不同的参数值，达到训练调优的目的，通过调整不同的指标来对模型进行持续优化。

学习率为控制参数更新的步长，影响模型的收敛速度和稳定性。较小的学习率可能导致收敛速度慢，而较大的学习率可能导致训练不稳定，甚至使模型无法收敛。

权重衰减是正则化参数，防止模型过拟合。它通过对模型的权重施加惩罚，促使模型学到较为简单的结构，从而避免过拟合。

批量大小是每次训练时输入给模型的样本数。较小的批量大小使得每次参数更新更加频繁，适应性强，但训练速度较慢；较大的批量大小则能更稳定地估计梯度，但训练过程中可能会出现内存问题。总而言之，它可以影响训练速度和梯度更新的稳定性。

训练轮数是训练轮数是整个训练集被模型学习的次数，决定模型训练的充分程。训练轮数较少可能导致模型未学到足够的特征，过多可能导致过拟合。

Alpha通常是模型中某些正则化项或调整机制的参数，在本课题中为LSTM中的权重衰减或其他层的超参数。Alpha的调节可能影响模型的稳定性和正则化效果。调整它有助于模型的细节优化。

Temperature通常与软目标（soft targets）和知识蒸馏（Knowledge Distillation）相关。通过调节温度，可以调整模型输出的分布，使得输出更加平滑。

过采样是解决数据不平衡问题的一种方法。在训练过程中，系统通过增加少数类样本的比例来平衡类别分布，避免模型偏向多数类。

图4. 11为本系统的模型调优参数配置。




图 4.11 参数配置图

调节相关参数后，后台会进行数据集训练，并显示验证集上的Loss与正确率如图4.12所示。训练完成以后，在系统界面会显示验证集的评估数据，如图4.13。

```
C:\Windows\System32\cmd.e  ×  +  v

epoch 1, iter 78: train loss 0.333
epoch 1, iter 156: train loss 0.241
epoch 1, iter 234: train loss 0.116
epoch 1, iter 312: train loss 0.064
epoch 1, iter 390: train loss 0.053
epoch 1, iter 394: train loss 0.050
整体验证集上的Loss: 10.238885097205639
整体验证集上的正确率: 0.9693577885627747
-----第 2 轮训练开始-----
epoch 2, iter 78: train loss 0.045
epoch 2, iter 156: train loss 0.020
epoch 2, iter 234: train loss 0.024
epoch 2, iter 312: train loss 0.020
epoch 2, iter 390: train loss 0.039
epoch 2, iter 394: train loss 0.026
整体验证集上的Loss: 7.550923235714436
整体验证集上的正确率: 0.9751527905464172
-----第 3 轮训练开始-----
epoch 3, iter 78: train loss 0.045
epoch 3, iter 156: train loss 0.031
epoch 3, iter 234: train loss 0.028
epoch 3, iter 312: train loss 0.025
epoch 3, iter 390: train loss 0.038
epoch 3, iter 394: train loss 0.016
整体验证集上的Loss: 6.4184611439704895
整体验证集上的正确率: 0.9774946570396423
Accuracy of the network on the test set: 77 %
得到的就结果为: 0.9774946570396423 0.033550918102264404 77.09710331366722
[18/May/2025 17:17:44] "POST /tuning_lstm/ HTTP/1.1" 200 84
```

图 4.12 后端训练过程



图 4.13 二分类训练准确率

本课题提出的模型二分类问题学习率在 $5e-5$ 时表现较好，多分类问题在 $8e-5$ 时表现较好，能够保证模型稳定收敛。权重衰减建议值通常为 $6e-6$ ，能够有效防止过拟合。批量大小建议值为 256，能够平衡训练速度和模型性能。训练轮数通常为 20 轮，既能保证模型充分学习，又不会导致过拟合。其余参数 α 默认值为 0.5，温度参数默认值 2.0。通过测试，该模型在二分类任务中准确率达到84.21%，多分类任务中平均F1分数达81.21%。这些所有的参数可能需要根据具体的数据集特点和任务需求进行微调。如果发现模型性能不理想，可以尝试调整这些参数，特别是学习率和训练轮数。

第五章 总结与展望

5.1 系统成果总结

随着网络攻击手段的多样化和复杂化，传统的入侵检测方法在应对新型威胁时逐渐暴露出局限性。本课题针对这一问题，设计并实现了一种基于LSTM和自编码器结合的入侵检测系统。通过将LSTM对时序数据的处理能力与自编码器的特征提取功能相结合，系统能够自动从网络流量中学习关键特征，并利用多任务学习框架提升模型的分类性能和泛化能力。

在实验阶段，系统首先筛选出对分类贡献最大的特征，再对数据进行标准化处理和分批次训练。采用Adam优化器和交叉熵损失函数进行模型训练后，系统在测试集上表现出了较高的检测准确率，验证了设计的有效性。相较于传统方法，本课题的创新点主要体现在以下三个方面：

特征提取更智能，模型能自动从原始数据中学习时序依赖和深层特征，减少了对人工特征工程的依赖；

分类性能更优，结合LSTM和自编码器的多任务学习框架，在提升检测精度的同时增强了模型的稳定性；

训练效率更高，通过调整共享编码器参数，减少了模型的计算复杂度，训练速度显著提升。

然而，系统仍存在一些不足之处：首先，实验仅基于公开数据集进行验证，实际网络环境中的流量可能更加复杂；其次，模型对硬件资源的要求较高，实时检测的响应速度有待优化；最后，模型的可解释性仍需加强，以便在实际部署时更好地辅助安全分析。

5.2 未来工作展望

针对当前系统的不足，未来的改进方向可以从以下几个方面展开：

提升模型的适用性，例如在更多实际网络环境中进行测试，收集不同场景下的流量数据，增强模型的泛化能力，尝试将模型与其他轻量级算法（如决策树、随机森林）结合，降低对计算资源的需求，提高实时检测效率。

优化器的选择，因为优化器控制着模型如何更新权重。常见的优化器有SGD（随机梯度下降）、Adam。Adam（自适应矩估计）结合了动量和自适应学习率的优点，适用于大多数任务，尤其是在处理具有稀疏梯度的任务时，表现良好。相比于传统的SGD，

Adam在训练过程中能自动调整每个参数的学习率，通常能加速收敛。SGD，简单有效，适用于很多标准任务，但可能需要更多的调整来避免震荡和局部最优解。

模型正则化（**Regularization**），正则化方法通过对模型施加额外的约束，避免模型在训练集上表现过好而在验证集上性能较差，从而减轻过拟合的风险。

模型架构改进，例如对于更复杂的任务，可以尝试增加网络的层数，使其能够学习到更复杂的特征。然而，层数过多也可能导致过拟合。根据任务的不同，选择合适的激活函数也是优化的一部分。例如，ReLU、Leaky ReLU、Swish等激活函数，能更有效地推动网络训练。

参考文献

- [1] Ingre B, Yadav A. Performance analysis of NSL-KDD dataset using ANN[C]//2015 international conference on signal processing and communication engineering systems. IEEE, 2015: 92-96.
- [2] Ibrahim L M, Basheer D T, Mahmod M S. A comparison study for intrusion database (Kdd99, Nsl-Kdd) based on self organization map (SOM) artificial neural network[J]. Journal of Engineering Science and Technology, 2013, 8(1): 107-119.
- [3] Mohamed H, Hefny H, Alsawy A. Intrusion Detection System Using Machine Learning Approaches[J]. Egyptian Computer Science Journal, 2018, 42(3).
- [4] Gao Y, Liu Y, Jin Y, et al. A novel semi-supervised learning approach for network intrusion detection on cloud-based robotic system[J]. IEEE Access, 2018, 6: 50927-50938.
- [5] Alrawashdeh K, Purdy C. Toward an online anomaly intrusion detection system based on deep learning[C]//2016 15th IEEE international conference on machine learning and applications (ICMLA). IEEE, 2016: 195-200.
- [6] Tang T A, Mhamdi L, McLernon D, et al. Deep learning approach for network intrusion detection in software defined networking[C]//2016 international conference on wireless networks and mobile communications (WINCOM). IEEE, 2016: 258-263.
- [7] Kim J, Shin N, Jo S Y, et al. Method of intrusion detection using deep neural network[C]//2017 IEEE international conference on big data and smart computing (BigComp). IEEE, 2017: 313-316.
- [9] Yan B, Han G. Effective feature extraction via stacked sparse autoencoder to improve intrusion detection system[J]. IEEE Access, 2018, 6: 41238-41248.
- [10] Xu C, Shen J, Du X, et al. An intrusion detection system using a deep neural network with gated recurrent units[J]. IEEE Access, 2018, 6: 48697-48707.
- [11] Imamverdiyev Y, Abdullayeva F. Deep learning method for denial of service attack detection based on restricted boltzmann machine[J]. Big data, 2018, 6(2): 159-169.
- [12] Javaid A, Niyaz Q, Sun W, et al. A deep learning approach for network intrusion detection system[C]//Proceedings of the 9th EAI International Conference on Bio-inspired Information and Communications Technologies (formerly BIONETICS). 2016: 21-26.
- [13] Yin C, Zhu Y, Fei J, et al. A deep learning approach for intrusion detection using recurrent neural networks[J]. IEEE Access, 2017, 5: 21954-21961.
- [14] Shone N, Ngoc T N, Phai V D, et al. A deep learning approach to network intrusion detection[J]. IEEE transactions on emerging topics in computational intelligence, 2018, 2(1): 41-50.
- [15] 陈友,程学旗,李洋,等.基于特征选择的轻量级入侵检测系统[J].软件学报,2007,(07):1639-1651.
- [16] Lounnapha S.基于CNN和SVDD的DDoS攻击检测研究[D].兰州交通大学,2020.
- [17] 武天舒.卷积神经网络在入侵检测系统中的研究与应用[D].华南理工大学,2018.
- [18] 罗晓璐,陈鑫,卢微.机器学习在网络入侵检测系统中的应用与效能分析[J].网络安全技术与应用,2024,(12):10-12.
- [19] 颜雯丽,丁昊,刘宁波,等.基于线性判别分析的海上目标检测算法[J].雷达科学与技术,2024,22(06):681-688.
- [20] 张宇航.基于深度学习的入侵流量检测研究[D].北方工业大学,2024.
- [21] 陈万松.数据流特征选择策略的研究[D].苏州大学,2011.
- [22] 王淇艺.基于机器学习的入侵检测算法研究[D].北京邮电大学,2018.

致 谢

四年的大学生涯即将结束，心中思绪万千。时间如白驹过隙，转眼间就到了毕业的时候。

首先我要感谢的是我的论文指导老师，老师有着严谨的教学态度，一遍遍的指导我的毕设与论文，为我提出修改的建议，指出方向。我将牢记老师的教诲，不管是在这个课题，还是在以后的生活中，都会以不断进取的态度来要求自己。

其次我还要感谢我的家人，感谢她们在学习和生活中给我的帮助，在我心情低落时给我鼓励，并且对我未来的方向也表示理解与支持。

再者我还要感谢我的朋友，在我实习、论文、备考忙的不可开交而压力倍增的时候，开导我，还抽出周末的时间与我一起写论文、修改毕设。

最后感谢所有老师，感谢在这四年里老师们的倾囊相授，感谢答辩老师们一次又一次的建议，还要感谢学校给了我一次又一次锻炼的机会，让我受益匪浅。衷心祝愿各位老师工作顺利，身体健康。

