



河南工业大学

2026 届毕业生 毕业设计说明书

题 目：基于 Hadoop 的心脏病健康数据分析与预测系统

院系名称： 信息工程学院专业班级： {{ class_name }}

学生姓名： {{ name }}学 号： {{ student_id }}

指导教师： {{ advisor }}教师职称：

2025 年 5 月

摘 要

心血管疾病长期位居全球主要死因首位，发病前高风险人群识别对降低发病率和死亡率具有重要意义。本文面向心脏病健康数据，设计并实现了一套集离线数据仓库、统计分析、机器学习预测和 Web 可视化于一体的大数据分析系统。系统整合 Indicators of Heart Disease (2020) 数据集 (319795 条、18 个字段)、Indicators of Heart Disease (2022 UPDATE) 数据集 (246022 条、40 个字段) 和 UCI Cleveland 临床数据 (303 条、13 个临床指标) 三类数据源，并基于 Hadoop 和 Hive 构建 ODS-DWD-ADS 三层数据仓库。经过数据清洗、字段对齐和多维聚合后，ADS 层结果同步至 MySQL，用于支撑在线查询和前端展示。

本文从年龄、性别、BMI、生活习惯、共病史和 UCI 临床指标六个维度开展统计分析。在 Indicators of Heart Disease (2020) 数据集上训练逻辑回归、SGD 线性分类器、随机森林和 Extra Trees 四种模型，并以 AUC 作为主要模型选择指标。实验结果表明，逻辑回归模型 AUC 达到 0.8207，召回率为 78.30%，综合表现较优；在 UCI Cleveland 数据集上，该模型 AUC 达到 0.9665，准确率为 86.89%。系统前端采用 Vue3 和 ECharts 实现可视化大屏及多页分析界面，后端基于 Django REST Framework 提供数据查询与在线预测接口。用户输入健康指标后，系统可返回心脏病风险等级及主要影响因素。系统采用 Docker Compose 进行容

Heart Disease Health Data Analysis and Prediction System Based on Hadoop

Abstract

Cardiovascular disease has long been the leading cause of death worldwide, making early risk identification crucial for reducing morbidity and mortality. This thesis designs and implements a big data analysis system for heart disease health data, covering an offline data warehouse, statistical analysis, machine learning prediction, and web-based visualization. The system integrates the Indicators of Heart Disease (2020) dataset (319,795 records, 18 fields), the Indicators of Heart Disease (2022 UPDATE) dataset (246,022 records, 40 fields), and the UCI Cleveland clinical dataset (303 records, 13 clinical indicators). A three-layer data warehouse (ODS-DWD-ADS) is built on the Hadoop platform using Hive for data cleaning, field standardization, and multi-dimensional aggregation, with ADS results synchronized to MySQL for online queries. Analysis dimensions cover age, gender, BMI, lifestyle habits, comorbidity history, and UCI clinical indicators. Four classification models were trained on the Indicators of Heart Disease (2020) dataset, with logistic regression achieving the best AUC of 0.8207 and a recall of 78.30%. On the UCI Cleveland dataset, the same model reached an AUC of 0.9665 with

86.89% accuracy. The frontend is built with Vue3 and ECharts for visualization dashboards, while the backend uses Django REST Framework for data query and online prediction APIs. The entire system is deployed using Docker Compose with a separated frontend and backend architecture.

Keywords heart disease; big data analysis; Hadoop; Hive data warehouse; machine learning; visualization

目 录

在 Word/WPS 中更新目录后显示

1 概述

1.1 研究背景

心血管疾病长期位居全球主要死因首位。世界卫生组织 2023 年发布的数据显示，全球每年约有 1790 万人死于心血管疾病，约占全球死亡总数的 32%。我国心血管疾病负担同样较重，城乡居民死亡原因中，心血管疾病均处于前列。《中国心血管健康与疾病报告 2022》估算显示，我国心血管病现患人数约为 3.3 亿，其中冠心病患者超过 1100 万。心脏病的发生并非由单一因素决定，年龄、性别、吸烟、糖尿病、高血压等因素往往共同作用，且不同因素之间存在交互影响。因此，若能在发病前识别高风险人群，并通过生活方式干预或早期医学干预降低风险，将有助于降低心脏病发病率和死亡率。

传统的心脏病风险评估主要依赖医生的临床经验和单一指标的阈值判断。Framingham 风险评分是目前应用最广的工具之一，它用年龄、总胆固醇、HDL 胆固醇、收缩压、吸烟状态等几个变量算出未来 10 年的冠心病风险概率。这种方法简单直观，但局限也很明显——变量数量有限，无法纳入 BMI、睡眠时长、精神健康天数等维度的信息；对不同人群的适用性也受到质疑。

近年来，大数据技术的快速发展为心脏病风险分析提供了新的技术路径。公开健康调查数据集中包含大规模人群的健康行为、疾病史和生活方式等信息，为多因素风险分析提供了数据基础。Hadoop、Hive 等分布式计算与数据仓库技术适用于此类数据的清洗、转换和多维聚合处理。基于聚合后的特征数据训练机器学习模型，可以同时纳入多个维度的风险因素，从而提升风险评估的细粒度和综合性。进一步结合 ECharts 等可视化工具展示分析结果，可提高系统结果的可读性和应用价值。

1.2 国内外研究现状

心脏病风险预测是机器学习在医疗领域较早开展应用的方向之一。UCI Machine Learning Repository 在 1988 年公开的 Cleveland 心脏病数据集包含 303 条记录和 13 个临床指标，后续大量研究围绕该数据集展开。Robert Detrano 等人基于临床指标构建冠心病诊断概率算法，为后续心脏病二分类建模提供了早期参考^[1]。

随后，集成学习和深度学习方法逐渐被应用于心脏病风险预测研究，并在分类性能方面取得了进一步提升。Mohan 等人将随机森林与线性模型进行融合，提出 HRFLM 方法，在 Cleveland 数据集上的准确率达到 88.7%^[2]。国内研究中，梁靖涵和许亚杰从机器学习算法选择角度分析心脏病预测诊断模型^[3]。李楠楠使用神经网络

络方法构建心血管疾病预测模型^[4]。朱宵彤等人进一步关注深度学习模型在心血管疾病预测中的应用^[5]。吕婷婷等人总结了深度学习在心电图自动诊断和心血管疾病预测中的作用^[6]。左维从危险人群分级角度讨论风险预测与心血管疾病之间的相关性^[7]。Kaggle 平台发布的 Indicators of Heart Disease 数据集基于 CDC BRFSS 2020 调查数据构建，包含 319795 条记录和 18 个字段，其数据规模相较传统临床数据集有显著提升，为大样本心脏病风险分析提供了条件。

Hadoop 和 Hive 在健康数据处理、离线数据仓库和多维统计分析中也具有较强适用性。林在宁等人基于 Hadoop 设计网站大数据分析系统，说明分布式平台可支撑数据采集、存储和统计分析链路^[8]。王金元等人将 Hadoop 用于分布式财务异常数据分析，体现了该技术在异常识别与批量处理场景中的适配性^[9]。卢金龙从 Hadoop 生态圈角度讨论数据分析平台设计，为本文的数据仓库分层提供了技术参考^[10]。宋柯萱对 Hadoop 大数据分析与优化方法进行总结，说明集群计算效率和数据处理流程需要结合业务场景共同设计^[11]。

在算法细化与系统展示方面，吴静基于改进随机森林完成分类系统设计，说明树模型适合处理多维特征分类任务^[12]。聂云丽和高国忠将随机森林用于页岩气甜点

分类，为集成学习模型在结构化数据分类中的应用提供了参考^[13]。刘文昌等人将 SMOTE 与 gcForest 用于医疗小样本分类研究，提示类别不均衡会影响医疗预测模型表现^[14]。董佳围绕融合采样算法处理不平衡数据分类问题，为本文后续模型优化提供了可借鉴思路^[15]。陈静雯等人设计了基于机器学习的疾病预测可视化系统，体现了预测模型与可视化页面结合的应用价值^[16]。范梓豪和杨楚雯基于 Vue 实现气象信息可视化大屏，说明前端框架和图表库适合构建多指标展示界面^[17]。张业男以农业数据为例开展可视化大屏教学案例研究，为本文大屏页面组织提供了参考^[18]。郭尚志等人讨论机器学习在医疗大数据分析与临床应用中的作用，说明模型训练结果需要结合具体业务流程落地^[19]。刘珺等人总结医疗大数据分析技术在临床医学中的应用，强调数据治理、统计分析和临床辅助决策之间的衔接^[20]。医疗数据分析中的隐私保护研究提醒系统设计需要同步考虑数据安全和隐私约束^[21]。

综合来看，现有研究存在两方面不足。一是大多数机器学习研究只用一个小规模临床数据集，缺少对多数据源、大规模调查数据的整合分析。二是不少大数据平台类的工作止步于可视化展示，没有把机器学习预测和在线服务做进去。本文试图在这两个方面做改进：既在 Hadoop 数据仓库中整合多个数据集做分析，又在此基

础上训练预测模型并提供 Web 在线预测服务。

1.3 研究目的

本课题旨在设计并实现一套基于 Hadoop 的心脏病数据分析与预测系统，系统功能覆盖离线数据仓库构建、多维统计分析、机器学习预测和 Web 可视化展示四个环节。

在数据层面，BRFSS 调查数据与 UCI 临床数据在数据格式、字段含义和特征维度上存在差异，因此需要依托 Hadoop 平台和 Hive 数据仓库构建统一的 ODS-DWD-ADS 三层数据处理流程，为后续分析和建模提供规范化的数据基础。在模型层面，本文对多种机器学习算法进行横向比较，并以定量评价指标作为模型选择依据。在应用层面，本文将统计分析结果和预测能力封装为 Web 系统，使用户能够通过浏览器查看分析图表、填写健康指标并获得风险评估结果。

1.4 项目规划

本系统基于 Hadoop 大数据平台和机器学习技术，构建心脏病健康数据的完整处理链路。具体规划如下六个模块：

1. 多源数据整合：整合 Indicators of Heart Disease (2020) 数据集 (319795 条 18 字段)、Indicators of Heart Disease (2022 UPDATE) 数据集 (246022 条、40

字段) 和 UCI Cleveland 临床数据集 (303 条、14 个临床指标) , 覆盖健康行为调查和临床检测两类数据源。

2. 数据仓库构建 : 在 Hadoop 平台上通过 Hive 构建 ODS-DWD-ADS 三层数据仓库。ODS 层原样存储 CSV 数据 , DWD 层完成类型转换、字段标准化和缺失值处理 , ADS 层按年龄、性别、BMI、生活习惯、共病史和 UCI 临床指标六个维度做聚合统计。

3. 多维统计分析 : 基于 ADS 聚合表从六个维度展示心脏病患病率的分布特征 , 包括年龄段的指数增长趋势、性别差异、生活习惯影响、共病关联强度和睡眠时长的 U 形分布等。

4. 机器学习预测 : 在 Indicators of Heart Disease (2020) 数据集和 UCI Cleveland 两个数据集上训练逻辑回归、SGD 线性分类器、随机森林和 Extra Trees 四种模型 , 以 AUC 为主要选型标准进行对比评估 , 选出最优模型用于在线预测。

5. 数据可视化展示 : 前端采用 Vue3 配合 ECharts 搭建可视化大屏和多页分析界面 , 展示各维度的统计图表、模型评估指标和特征重要性排名。

6. 在线预测服务 : 后端基于 Django REST Framework 提供数据查询和在线预测 API 接口 , 用户输入健康指标后即可获得心脏病风险等级和关键影响因素。整套

系统用 Docker Compose 容器化部署，前后端分离。

论文共分为五章。第一章概述研究背景、国内外现状和项目规划。第二章需求分析，阐述功能需求和非功能需求。第三章概要设计，包括技术支撑、各模块设计和数据库设计。第四章详细设计，描述大数据端、预测模型、后端接口和前端框架的具体实现。第五章系统展示与测试，展示系统运行效果并进行功能和性能测试。

2 需求分析

2.1 功能需求

2.1.1 用户角色与核心功能

本系统面向两类用户角色：普通用户和系统管理员。普通用户是系统的主要受众，包括关注自身心血管健康的公众、从事健康管理和流行病学研究的专业人员，以及医学院校的教学科研人员。系统管理员负责数据维护、系统配置和用户管理。

普通用户的核心需求包括：查看心脏病在年龄、性别、BMI、生活习惯、共病史和临床指标六个维度上的患病率分布图表；输入个人健康指标获取心脏病风险评估结果和关键影响因素；查看四种机器学习模型的评估指标对比和特征重要性排名；在可视化大屏上一览数据集总体概况和核心分析结论。

系统管理员的核心需求包括：管理数据仓库的三层表结构和数据同步状态；查看数据清洗日志和异常记录；管理用户账户和角色权限；查看系统运行日志和预测接口调用记录。

系统用例图如图 2-1 所示。




图 2-1 系统用例图

为了进一步说明系统用例图中的功能边界，本文将普通用户和系统管理员的主要用例拆分为触发条件、前置条件和后置结果。这样可以避免只停留在功能名称层面，也便于后续进行接口设计和测试用例设计。

表 2-2 主要用例说明

用例名称	参与者	触发条件	后置结果
注册登录	普通用户/管理员	用户进入系统并提交账号信息	系统签发 JWT 令牌并进入对应首页
查看数据总览	普通用户	用户进入可视化大屏或数据概览页	系统返回样本数、患病率和数据集规模
年龄分布分析	普通用户	用户选择年龄分析页面	系统展示年龄段样本量和患病率图表
模型指标查看	普通用户	用户进入机器学习模块	系统展示 Accuracy、Precision、Recall、F1、AUC
在线风险预测	普通用户	用户填写健康指标并提交	系统返回概率、风险等级和影响因素 Top3
数据同步监控	管理员	管理员查看同步任务状态	系统展示同步时间、条数、成功/失败状态
模型文件	管理员	管理员替换训练后的模型	系统重新加载 joblib 模型并记录版本

更新 系统日志 查看	文件 管理员 管理员进入日志管理页面	系统按时间倒序展示接口调用和异常 信息
------------------	--------------------------	------------------------

从表 2-2 可以看出，普通用户关注的是分析结果和预测结果，管理员关注的是数据链路和系统运行状态。系统设计时需要将二者的权限边界分开：普通用户只允许访问查询类接口和个人预测历史，管理员可以访问同步日志、用户管理和模型维护接口。

2.1.2 数据分析功能

数据分析模块是系统的核心展示功能，面向普通用户提供六个维度的心脏病患病率统计图表。具体功能需求如下：

年龄维度分析：以柱状图展示各年龄段（18-24、25-29、30-34、35-39、40-44、45-49、50-54、55-59、60-64、65-69、70-74、75-79、80+）的样本量和患病率，支持按数据集切换查看。

性别维度分析：以对比柱状图展示男性和女性的样本数和患病率差异，标注患病率比值。

生活习惯维度分析：将吸烟、饮酒、运动习惯三个因素的患病率以分组柱状图展示，支持单因素和多因素交叉分析。

BMI 维度分析：按偏瘦、正常、超重、肥胖四组展示患病率，以饼图辅助展示

各组人数占比。

共病维度分析：展示中风、糖尿病、肾病、哮喘、皮肤癌五种共病的患病率对比，标注相对风险倍数。

睡眠维度分析：以折线图展示不同睡眠时长与患病率的 U 形关系。

各分析维度对应的页面入口、数据来源和展示方式如表 2-3 所示。所有图表数据均来自 ADS 层聚合表，前端不直接访问 Hive，而是通过 Django API 查询 MySQL 中的同步结果。

表 2-3 数据分析功能明细

功能项	数据来源	展示方式	交互要求
数据总览	ads_heart_overview	指标卡、饼图、条形图	支持按数据集查看
年龄分析	ads_heart_by_age	柱状图、折线图	年龄段排序固定
性别分析	ads_heart_by_sex	对比柱状图	展示样本数和患病率
BMI 分析	ads_heart_by_bmi	分组柱状图、饼图	按偏瘦/正常/超重/肥胖展示
生活习惯分析	ads_heart_lifestyle	分组柱状图	可切换吸烟、饮酒、运动、睡眠
共病分析	ads_heart_comorbidity	横向柱状图	标注相对风险倍数
临床指标分析	ads_uci_clinical_risk	多指标柱状图	仅对 UCI 数据集启用

为保证分析结果具有可解释性，页面不仅展示图形，还应在图表旁显示统计口径说明。例如年龄分析页面需要注明年龄段来自原始字段 AgeCategory，BMI 分析页面需要注明 BMI 分组阈值，共病分析页面需要注明患病率的计算公式为阳性样本数除以总样本数。

2.1.3 机器学习预测功能

机器学习模块提供模型训练结果的查看和在线预测两项功能：

模型对比：展示逻辑回归、SGD 线性分类器、随机森林和 Extra Trees 四种模型在 Indicators of Heart Disease (2020) 数据集和 UCI Cleveland 两个数据集上的 Accuracy、Precision、Recall、F1 和 AUC 五项指标，以分组柱状图、雷达图和 ROC 曲线呈现。

特征重要性：展示影响心脏病风险的 Top-10 特征排名及其重要性数值，支持按数据集切换查看。

在线预测：提供一个包含 16 个健康指标字段的输入表单（BMI、年龄段、性别、吸烟、饮酒、运动习惯、整体健康状况、睡眠时长、行走困难、中风、糖尿病、哮喘、肾病、皮肤癌、身体健康天数、精神健康天数），用户填写后提交即可获得风险概率、风险等级（低/中/高）和影响当前结果最大的三个因素。缺失字段由模型训练时记录的默认值自动补全。

在线预测功能要求训练阶段和推理阶段使用完全一致的特征处理流程。系统不能在前端直接计算风险概率，而应由后端加载训练好的 Pipeline 对象完成预处理和模型推理，避免不同端实现不一致导致结果偏差。

表 2-4 预测模块输入输出要求

类别	字段/结果	处理要求
数值输入	BMI、PhysicalHealth、MentalHealth、SleepTime	允许为空；为空时使用训练集统计默认值补全
分类输入	AgeCategory、Sex、Smoking 等 13 个字段	必须落在枚举集合中；非法值返回 400 错误
模型输出	probability	输出 0 到 1 之间的小数，保留 4 位
等级输出	risk_level	按 0.33 和 0.67 阈值划分低/中/高风险
解释输出	top_factors	返回贡献度绝对值最高的三个因素
记录输出	PredictionRecord	保存输入 JSON、概率、等级、模型名和创建时间

预测结果属于辅助评估信息，系统页面需要明确提示结果不能替代医生诊断。

系统只根据公开数据集训练得到统计模型，输出的是风险趋势判断，而不是医学意义上的确诊结论。

2.1.4 数据管理功能

数据管理模块面向管理员，提供数据仓库和业务数据的维护能力：

数据概览：展示系统接入的三个数据集的样本数、字段数、存储空间和数据质量评分，以饼图和条形图分别展示样本量分布和特征维度对比。

数据清洗记录：展示 ODS 到 DWD 层的清洗日志，包括字段类型转换数、缺失值处理数和异常值过滤数。

数据同步状态：展示 ADS 层到 MySQL 的同步时间、同步条数和失败记录。

预测历史记录：展示所有用户的预测记录，按时间倒序排列，支持按用户和时

间范围筛选。

2.2 非功能需求

系统非功能需求涵盖性能、安全、兼容性和可维护性四个方面，如表 2-1 所示。

表 2-1 非功能需求说明

需求类别	具体要求
性能	API 响应<500ms；预测接口<100ms；页面首屏<2s；图表渲染<300ms
安全	JWT 令牌认证；BCrypt 密码加密；角色权限隔离；输入参数校验
兼容性	Chrome/Firefox/Safari/Edge；支持 1920×1080/1440×900/1366×768 分辨率
可维护性	前后端分离；Django ViewSet 分层；数据仓库三层可扩展；Docker Compose 容器化
可靠性	后端服务异常自动重启；数据同步失败保留日志；模型加载失败回退到上一个可用版本
易用性	图表加载状态清晰；预测表单给出枚举选项；错误信息以中文提示
可扩展性	新增 ADS 主题表后只需补充 Serializer、ViewSet 和前端图表组件

性能方面，预测接口的耗时主要集中在特征预处理阶段，尤其是 OneHotEncoder 转换过程；模型推理阶段耗时较短。页面首次加载需要下载 Vue3 和 ECharts 的 JavaScript 资源，后续页面切换响应较快。ECharts 图表渲染时间与数据点数量正相关，当前各维度聚合后的数据量较小，能够满足页面交互需求。

安全方面，JWT 令牌设置 7 天有效期，过期后需重新登录获取新令牌。BCrypt 加密采用 12 轮盐值计算，即使数据库泄露也无法通过彩虹表攻击还原密码。管理员接口在 Django 的 URL 配置中通过自定义 Permission 类进行拦截，普通用户无法访问管理相关的 API 端点。预测接口对 BMI、睡眠时长等数值型字段做范围校验

(如 BMI 限制在 10-80 之间) , 对年龄段、性别等分类型字段做枚举值校验 , 防止异常输入导致模型推理出错。

兼容性方面 , 前端采用 Vue3 响应式布局并结合 CSS 媒体查询 , 在不同分辨率下自动调整页面结构。ECharts 图表设置 resize 事件监听 , 窗口大小变化时自动重绘。Naive UI 组件库支持主流浏览器 , 系统无需额外引入 polyfill。

可维护性方面 , 前后端代码分别在独立的 Git 仓库中管理。Django 后端通过 DRF 的 Router 自动注册 URL , 新增功能模块只需编写对应的 ViewSet 和 Serializer。数据仓库的 ADS 层设计为宽表形式 , 每张表对应一个分析维度 , 新增维度只需添加一张 ADS 表并编写对应的 HiveQL 聚合语句。Docker Compose 配置文件中为每个服务定义了健康检查和重启策略 , 生产环境下服务异常可自动恢复。

可靠性方面 , 系统将数据同步任务和在线查询服务解耦。Hive 负责离线计算 , MySQL 负责在线查询 , 即使某次同步失败 , 前端仍可读取上一次成功同步的数据。同步日志表记录任务开始时间、结束时间、同步行数和错误信息 , 管理员可以根据日志定位问题。

易用性方面 , 预测页面减少自由文本输入 , 年龄段、性别、吸烟、运动等字段

均采用下拉框或单选框，降低用户输入不规范的概率。图表页面提供加载中、暂无数据和接口异常三种状态提示，减少空白页面造成的理解偏差。

可扩展性方面，ADS 层采用主题表设计。新增分析主题时，可按“新增 Hive 聚合表—同步到 MySQL—新增 Django 接口—新增 ECharts 组件”的顺序扩展，无需改动已有分析页面。

3 概要设计

3.1 技术支撑

3.1.1 大数据端

大数据端负责原始数据的存储、清洗、分析和迁移四个环节：

(1) 数据存储。三个 CSV 数据文件 (Indicators of Heart Disease (2020) 、 Indicators of Heart Disease (2022 UPDATE) 、 UCI Cleveland) 存储在 HDFS 上。Hadoop 集群采用 Docker 方式搭建，包含 1 个 NameNode 和 2 个 DataNode，HDFS 副本数设为 2。HDFS 将文件划分为固定大小的数据块 (默认 128MB)，并分布式存储在不同节点上。NameNode 负责维护文件与数据块之间的元数据信息，DataNode 负责实际数据块的读写操作。

(2) 数据清洗。Hive 是建立在 Hadoop 之上的数据仓库工具，用户提交 SQL (HiveQL) 后，Hive 将其转换为 MapReduce 或 Tez 任务并在集群上执行。本系统在 Hive 上构建 ODS-DWD-ADS 三层数据仓库。ODS 层通过外部表直接映射 HDFS 上的 CSV 文件，字段全部以 STRING 类型载入；DWD 层通过 INSERT OVERWRITE 将 STRING 转换为 DECIMAL、INT 等精确类型，同时进行字段标准

化和缺失值处理；ADS 层基于 GROUP BY 和窗口函数完成多维聚合。

(3) 数据分析。ADS 层产出 9 张聚合表，覆盖年龄、性别、BMI、生活习惯、共病史和 UCI 临床指标六个分析维度。每张表的粒度为数据集与维度值的交叉组合，输出样本数、阳性数和患病率三个核心指标。Hive 的分区和分桶机制能够提升查询效率。本系统按 dataset_name 进行分区，查询某一数据集时仅需扫描对应分区文件。

(4) 数据迁移。ADS 层的聚合结果通过 Python 脚本 (PyHive + PyMySQL) 同步到 MySQL。同步方式采用全量覆盖流程：先 TRUNCATE 目标表，再批量 INSERT。由于 ADS 表的数据规模较小，全量同步耗时保持在秒级。MySQL 同时存储用户账户信息和预测历史记录。

系统技术栈如图 3-1 所示。系统前端采用 Vue3、TypeScript、Naive UI 和 ECharts 实现页面展示，后端采用 Django REST Framework 提供接口服务，数据端采用 Hadoop、HDFS、Hive 和 MySQL 完成数据存储、清洗、聚合与同步，模型端采用 scikit-learn 训练分类模型并通过 joblib 保存模型文件。




图 3-1 系统技术栈图

Hive 数据仓库工作原理如图 3-2 所示。用户通过 CLI、JDBC 或 Web 接口提交 HiveQL，Driver 完成 SQL 解析、语义编译和执行计划优化，并将任务提交给 MapReduce 或 Tez 执行引擎。MetaStore 保存表结构、分区信息和 HDFS 路径，保证 SQL 层和底层文件存储之间能够正确映射。




图 3-2 Hive 数据仓库工作原理

3.1.2 机器学习预测

预测模块使用 scikit-learn 训练四种分类模型：

逻辑回归是基础的二分类模型。该模型对输入特征进行线性加权求和，并通过 Sigmoid 函数输出 0 到 1 之间的概率值。逻辑回归具有训练速度快、可解释性较强等优点，但其表达能力主要限于线性决策边界。本文通过设置 `class_weight='balanced'` 缓解正负样本不均衡问题。

随机森林由 250 棵决策树组成。每棵树在训练阶段基于部分样本和部分特征构建，最终预测结果由所有决策树投票决定。随机采样机制能够降低过拟合风险，集成多棵弱分类器也有助于提高模型泛化能力。

Extra Trees (Extremely Randomized Trees) 与随机森林的主要区别在于节点划分方式：随机森林在每个节点选择较优分裂点，而 Extra Trees 随机选择分裂点。因此，Extra Trees 通常具有较快的训练速度和较低的方差，但偏差可能略高。本文将 Extra Trees 模型的树数量设置为 300 棵。

SGD 线性分类器采用随机梯度下降方法训练线性分类模型，适用于大规模数据集。当 loss 设置为 log_loss 时，该模型与逻辑回归具有相同的概率输出形式，但训练效率更高。

四种模型的选择以 AUC (ROC 曲线下面积) 为首要标准。AUC 衡量的是模型区分阳性和阴性样本的总体能力，不受分类阈值的影响，在正负样本不均衡的情况下比准确率更有参考价值。

3.1.3 系统框架

系统采用前后端分离的 B/S 架构，技术栈如下：

(1) 后端框架。Django 是 Python 生态中应用较为广泛的 Web 框架，内置 ORM、认证系统、管理后台和模板引擎。本系统选用 Django REST Framework (DRF) 构建后端 API。DRF 在 Django 基础上提供序列化器、视图集和路由器，可将数据库查询结果和业务逻辑封装为 RESTful 接口。由于本文机器学习模型基于

Python 的 scikit-learn 训练，预测推理过程同样采用 Python 实现，因此使用 Django

后端能够直接加载模型文件并执行推理，减少跨语言调用带来的复杂度。

(2) 数据库访问。Django 内置 ORM 框架，通过 Python 类定义数据库表结构，支持链式查询、事务管理和数据迁移。对于复杂聚合查询，系统可使用原始 SQL 提升表达灵活性。

(3) 前端框架。Vue3 是当前主流的前端框架之一，采用 Composition API 组织组件逻辑。本系统前端采用 Vue3 搭配 TypeScript 开发，组件库选用 Naive UI，构建工具为 Vite。ECharts 是百度开源的 JavaScript 可视化库，支持柱状图、折线图、饼图、雷达图等数十种图表类型，用于渲染心脏病数据的各类分析图表。

(4) 容器化部署。Docker Compose 将 MySQL、Django 后端和 Vue3 前端分别打包为独立镜像，并进行统一编排启动。通过 docker-compose.yml 定义服务依赖关系、端口映射和数据卷挂载，可在 Linux 服务器上部署完整系统。

系统总体架构如图 3-3 所示。




图 3-3 系统总体架构图

3.2 大数据端模块设计

3.2.1 数据采集模块

本系统整合三个公开数据集。Indicators of Heart Disease (2020) 数据集来源于美国 CDC 的行为风险因素监测系统 (BRFSS) ，覆盖 2020 年约 40 万人的电话调查结果，清洗后剩 319795 条记录，18 个字段。HeartDisease 为二值目标变量

(Yes/No) , 其余 17 个字段覆盖 BMI、吸烟、饮酒、中风、身体健康天数、精神健康天数、行走困难、性别、年龄段、种族、糖尿病、运动习惯、整体健康评价、睡眠时长、哮喘、肾病、皮肤癌。阳性样本占 8.6% , 属于典型的类别不均衡。

Indicators of Heart Disease (2022 UPDATE) 数据集是在 2020 版基础上的扩展 , 字段数量由 18 个增加至 40 个 , 新增疫苗接种、COVID 感染状态、口腔健康等维度。该数据集原始记录数为 445132 条 , 存在一定数量的缺失值 , 清洗后保留 246022 条记录。UCI Cleveland 数据集由 Cleveland Clinic 收集 , 包含 303 名患者记录和 13 个临床检测指标。

三个数据集的基本信息汇总如表 3-1 所示。

表 3-1 三个数据集基本信息

数据集	来源	记录数	字段数	目标变量
Indicators of Heart Disease (2020)	CDC BRFSS 调查	319795	18	HeartDisease (Yes/No)
Indicators of Heart Disease (2022 UPDATE)	CDC BRFSS 调查 (扩展版)	246022	40	HadHeartAttack/ HadAngina
UCI Cleveland	Cleveland Clinic 临床数据	303	14	num (0-4)

3.2.2 数据预处理模块

数据预处理在 Hive 的 DWD 层完成 , 主要包括三类操作 :

(1) 数据清洗。去除重复记录 , 处理缺失值。Indicators of Heart Disease

(2020) 数据集中 Diabetic 字段存在 "Yes (during pregnancy)" 等特殊值 , 需要保留原始文本的同时生成二值标记。UCI 数据集的 ca 和 thal 两个字段中包含问号 (?) , 通过 CASE WHEN 替换为 NULL。

(2) 数据变换。STRING 类型的字段转换为精确类型——BMI 从 STRING 转换为 DECIMAL(6,2) , Smoking 等 Yes/No 字段映射为 1/0 的 INT 类型 , Sex 字段从 Male/Female 映射为 sex_code。目标变量统一为 risk_label : Indicators of Heart Disease (2020) 的 HeartDisease Yes→1 , Indicators of Heart Disease (2022 UPDATE) 的 HadHeartAttack/HadAngina→1 , UCI 的 num>0→1。

(3) 数据归约。三个数据集的字段不完全一致 , 通过 UNION ALL 将共有维度 (risk_label、age_band、sex_code、bmi、smoking_flag 等) 拼成一张 28 列的宽表 dwd_heart_feature_sample。BRFSS 调查数据缺少的临床指标字段填 NULL , UCI 缺少的生活习惯字段也填 NULL。每条记录多挂一个 source_dataset 字段标来源。

DWD 层共建立 5 张表 , 各表职责如表 3-2 所示。

表 3-2 DWD 层表结构

表名	字段数	清洗内容
dwd_heart_2020_clean	21	STRING→DECIMAL/INT ; Yes/No→1/0 ; 派生 risk_label、sex_code
dwd_heart_2022_clean	45	40 字段类型转换 ; HadHeartAttack OR

		HadAngina→risk_label
dwd_uci_cleveland_clean	17	?→NULL ; num>0→risk_label=1 ; 年龄→年龄段
dwd_uci_cost_clean	7	费用 STRING→DECIMAL ; 窗口函数生成 cost_rank
dwd_heart_feature_sample	28	三数据集 UNION ALL ; 共有维度对齐 ; 缺失字段 NULL

3.2.3 数据分析模块

ADS 层面向应用场景，对 DWD 层明细数据按各种维度做 GROUP BY 聚合。

一共 9 张聚合表，6 个分析维度，如表 3-3 所示。

表 3-3 ADS 层聚合表

表名	分析维度	聚合粒度
ads_heart_overview	总览	按数据集：样本数、阳性数、患病率
ads_heart_by_age	年龄	按数据集×年龄段：样本数、阳性数、患病率
ads_heart_by_sex	性别	按数据集×性别：样本数、阳性数、患病率
ads_heart_by_bmi	BMI	按数据集×BMI 分组：样本数、阳性数、患病率
ads_heart_lifestyle	生活习惯	按因素名×因素值：样本数、阳性数、患病率
ads_heart_comorbidity	共病史	按疾病名×是否患病：样本数、阳性数、患病率
ads_uci_clinical_risk	UCI 临床指标	按指标名×指标值：样本数、阳性数、患病率
ads_uci_cost_analysis	检查费用	按检查项：费用值、费用等级、排名
ads_model_metrics	模型指标	按模型名：准确率、精确率、召回率、F1、AUC

ADS 层的 SQL 统一使用 GROUP BY 做分组聚合。以 ads_heart_by_age 为例，

按 dataset_name 和 age_band 两个维度分组，COUNT(*) 统计样本数，

SUM(risk_label)统计阳性数，SUM(risk_label)/COUNT(*)计算患病率。

3.2.4 数据迁移模块

ADS 层的 9 张 Hive 表通过 Python 脚本同步到 MySQL。MySQL 中建了同名的 9

张表，字段类型做对应转换：Hive 的 STRING→MySQL 的 VARCHAR(64)，

BIGINT→BIGINT，DECIMAL(8,4)→DECIMAL(8,4)，字符集设为 utf8mb4。

同步脚本通过 PyHive 连接 Hive 读取 ADS 表全量数据，通过 PyMySQL 写入 MySQL。写入前先 TRUNCATE 目标表再批量 INSERT。ADS 表每张只有几十到几百行，全量同步耗时在秒级。

数据仓库的三层架构如图 3-4 所示。




图 3-4 数据仓库 ODS-DWD-ADS 三层架构

ETL 流程如图 3-5 所示，数据依次经过 HDFS 上传、ODS 建表、DWD 清洗、ADS 聚合、MySQL 同步五个阶段。




图 3-5 数据处理 ETL 流程

Hive 与 MySQL 的字段类型映射如表 3-4 所示。

表 3-4 Hive 与 MySQL 字段类型映射

Hive 类型	MySQL 类型	示例字段
STRING	VARCHAR(64)	dataset_name, age_band, sex_label
BIGINT	BIGINT	sample_count, positive_count
DECIMAL(8,4)	DECIMAL(8,4)	prevalence_rate, accuracy
STRING	VARCHAR(128)	feature_name, feature_label
DECIMAL(12,6)	DECIMAL(12,6)	importance (特征重要性)

3.3 预测模块设计

预测模块的输入是用户填写的 16 个健康指标字段，输出包括风险概率、风险等级和 Top-3 影响因素。模块架构分为三层：

用户交互层：前端提供表单界面接收输入，以卡片形式展示预测结果。16 个字

段全部为可选，缺失字段由训练时记录的默认值补全。

特征处理层：数值型字段（BMI、PhysicalHealth、MentalHealth、SleepTime）

做 StandardScaler 标准化；分类型字段（13 个）做 OneHotEncoder 独热编码。scikit-

learn 的 ColumnTransformer 将两路处理组合为 Pipeline，保证训练和推理逻辑一致。

模型推理层：加载预训练的逻辑回归模型文件（joblib 格式），调用

predict_proba 获取风险概率。概率 ≥ 0.67 为高风险、0.33-0.67 为中风险、0.33 为低

风险。通过模型系数矩阵计算各特征对当前预测结果的贡献度，取绝对值最大的三

个特征作为影响因素返回。每次预测结果写入 MySQL 的 PredictionRecord 表。

预测流程如图 3-6 所示。




图 3-6 在线预测流程图

3.4 前端框架模块设计

前端采用 Vue3 + Naive UI + ECharts 的组合。页面结构分为两种模式：

(1) 可视化大屏模式。全屏深色主题面板，集中展示患病率、年龄分布柱状

图、特征重要性排名、生活方式分析、UCI 临床指标、数据集规模对比和风险预测

统计等核心信息。大屏通过 CSS Grid 布局划分为多个区域，ECharts 图表设置 resize 监听实现自适应。

(2) 分页管理模式。左侧边栏加右侧内容区的布局。左侧菜单分为可视化大屏、数据分析、机器学习、数据治理、系统运维五个一级模块。数据分析下又分年龄分布、生活方式、临床指标、相关性、综合对比等二级页面。Vue Router 负责路由管理，Vuex (Pinia) 管理全局状态。

前端与后端通过 Axios 进行 HTTP 通信，采用 RESTful API 规范。请求拦截器自动附加 JWT 令牌，响应拦截器统一处理错误码。ECharts 图表的数据通过 API 异步获取后渲染，支持 loading 状态和错误提示。

系统功能结构如图 3-7 所示。



图 3-7 系统功能模块图

用例图如图 3-8 所示。




图 3-8 系统用例图

3.5 数据库设计

系统使用 MySQL 存储三类数据：ADS 聚合表（9 张，由 Hive 同步而来）、用

户账户表和预测记录表。ADS 表的结构已在 3.2.3 节介绍，此处说明业务表。

系统 E-R 图如图 3-9 所示。




图 3-9 系统 E-R 图

用户账户表采用 Django 内置的 auth_user 表，表结构如表 3-5 所示。

表 3-5 用户表（auth_user）结构

字段	类型	说明
id	INT	主键，自增
username	VARCHAR(150)	用户名
password	VARCHAR(128)	加密后的密码
email	VARCHAR(254)	邮箱
is_active	BOOL	账户是否启用
date_joined	DATETIME	注册时间

预测记录表用于保存每次在线预测的输入和输出，表结构如表 3-6 所示。

表 3-6 预测记录表（prediction_record）结构

字段	类型	说明
id	INT	主键，自增
user_id	INT	外键，关联 auth_user
probability	DECIMAL(6,4)	预测概率
risk_level	VARCHAR(16)	风险等级 (low/medium/high)
risk_label	VARCHAR(16)	中文标签 (低/中/高风险)
model_name	VARCHAR(64)	使用的模型名称
input_data	JSON	用户输入的 16 字段数据
created_at	DATETIME	预测时间

角色权限表用于定义系统角色和对应权限，表结构如表 3-7 所示。

表 3-7 角色权限表 (user_role) 结构

字段	类型	说明
id	INT	主键，自增
role_name	VARCHAR(32)	角色名称 (admin/user)
permissions	JSON	权限列表
description	VARCHAR(128)	角色描述

数据同步日志表用于记录 Hive 到 MySQL 的每次同步状态，表结构如表 3-8 所

示。

表 3-8 数据同步日志表 (sync_log) 结构

字段	类型	说明
id	INT	主键，自增
table_name	VARCHAR(64)	同步的 ADS 表名
sync_time	DATETIME	同步时间
row_count	INT	同步条数
status	VARCHAR(16)	状态 (success/failed)
error_msg	TEXT	失败时的错误信息

轮播图表用于管理首页和大屏的轮播展示内容，表结构如表 3-9 所示。

表 3-9 轮播图表 (rotation) 结构

字段	类型	说明
id	INT	主键，自增
image_url	VARCHAR(256)	图片 URL
link_url	VARCHAR(256)	跳转链接
sort_order	INT	排序序号
is_active	BOOL	是否启用

除业务表外，系统还需要保存 ADS 层同步后的主题分析结果。由于这些表来

自 Hive 离线聚合，MySQL 端只负责查询和展示，不在业务接口中直接修改。下面

列出系统中几个核心 ADS 表和模型表的物理结构。

表 3-10 ADS 总览表 (ads_heart_overview) 结构

字段	类型	说明
dataset_name	VARCHAR(64)	数据集名称
sample_count	BIGINT	样本总数
positive_count	BIGINT	阳性样本数
prevalence_rate	DECIMAL(8,4)	患病率
updated_at	DATETIME	同步更新时间

表 3-11 ADS 年龄分析表 (ads_heart_by_age) 结构

字段	类型	说明
dataset_name	VARCHAR(64)	数据集名称
age_band	VARCHAR(32)	年龄段
sample_count	BIGINT	样本数
positive_count	BIGINT	阳性样本数
prevalence_rate	DECIMAL(8,4)	患病率

表 3-12 ADS 生活习惯表 (ads_heart_lifestyle) 结构

字段	类型	说明
dataset_name	VARCHAR(64)	数据集名称
factor_name	VARCHAR(64)	因素名称，如 smoking、alcohol
factor_value	VARCHAR(64)	因素取值
sample_count	BIGINT	样本数
prevalence_rate	DECIMAL(8,4)	患病率

表 3-13 模型指标表 (ads_model_metrics) 结构

字段	类型	说明
model_name	VARCHAR(64)	模型名称
dataset_name	VARCHAR(64)	训练/验证数据集
accuracy	DECIMAL(8,4)	准确率
precision_score	DECIMAL(8,4)	精确率
recall_score	DECIMAL(8,4)	召回率
f1_score	DECIMAL(8,4)	F1 值
auc_score	DECIMAL(8,4)	AUC 值

表 3-14 特征重要性表 (model_feature_importance) 结构

字段	类型	说明
id	INT	主键，自增
model_name	VARCHAR(64)	模型名称
feature_name	VARCHAR(128)	特征字段名
feature_label	VARCHAR(128)	中文展示名
importance	DECIMAL(12,6)	重要性或贡献度

表 3-15 同步日志表 (sync_log) 结构

字段	类型	说明
id	INT	主键，自增
table_name	VARCHAR(64)	同步表名
start_time	DATETIME	开始时间
end_time	DATETIME	结束时间
row_count	INT	同步行数
status	VARCHAR(16)	success/failed
error_msg	TEXT	失败原因

数据库设计的核心原则是把离线分析结果和在线业务数据分开。ADS 表不承载

事务更新，适合按主题查询；业务表保存用户、权限、预测记录和日志，适合通过

Django ORM 进行增删改查。这样的设计既保留了 Hive 处理大数据的优势，也保

证了 Web 系统查询响应速度。

4 详细设计

4.1 大数据端设计

4.1.1 Hadoop 集群搭建

数据仓库运行在 Hadoop 分布式平台上。本系统采用 Docker 方式搭建 Hadoop 集群，包含 1 个 NameNode 和 2 个 DataNode，HDFS 副本数设为 2。Hive 3.x 作为数据仓库引擎安装在 NameNode 节点上，MetaStore 使用 MySQL 存储元数据。集群搭建完成后，通过 `hdfs dfs -put` 命令将三个 CSV 数据文件上传到 HDFS 的 `/user/heart_disease/raw/` 目录下。

Hive 配置中，`hive.exec.mode.local.auto` 设为 `true`，用于提升小规模数据集查询效率；`hive.cli.print.header` 设为 `true`，用于在 CLI 中显示列名。序列化工具选用 `OpenCSVSerde`，以正确处理 CSV 文件中包含逗号的字段值。

开发环境配置如表 4-1 所示。

表 4-1 开发环境配置

类别	工具/版本
操作系统	macOS / Ubuntu 22.04
后端框架	Django 4.2 + DRF 3.15
前端框架	Vue3 + Vite + Naive UI
图表库	ECharts 5
数据库	MySQL 8.0
大数据平台	Hadoop 3.x + Hive 3.x

ML 框架	scikit-learn 1.x
容器化	Docker Compose 2.x
编程语言	Python 3.10 / TypeScript

4.1.2 ODS 层实现

ODS 层用于保存未经清洗和转换的原始数据，以保留数据追溯能力。本层共建立 4 张 Hive 外部表，如表 4-2 所示。

表 4-2 ODS 层表结构

表名	字段数	数据来源	序列化方式
ods_heart_2020_raw	18	Indicators 2020 CSV	OpenCSVSerde
ods_heart_2022_raw	40	Indicators 2022 CSV	OpenCSVSerde
ods_uci_cleveland_raw	14	UCI Cleveland CSV	OpenCSVSerde
ods_uci_cost_raw	2	UCI 检查费用	分隔符(:)

ODS 表的所有字段类型统一设为 STRING。系统使用外部表 (EXTERNAL TABLE) 而非内部表，以避免删除 Hive 表时影响 HDFS 上的原始文件。以 ods_heart_2020_raw 为例，该表包含 heart_disease、bmi、smoking、alcohol_drinking、stroke、physical_health、mental_health、diff_walking、sex、age_category、race、diabetic、physical_activity、gen_health、sleep_time、asthma、kidney_disease、skin_cancer 共 18 个 STRING 字段。

建表后通过 LOAD DATA INPATH 将 HDFS 上的 CSV 文件加载到对应的 ODS 表中。加载过程不做任何转换，数据以原始格式进入 Hive。通过 SELECT COUNT(*)验证各表的记录数与原始 CSV 一致。

ODS 层建表以外部表为主，建表语句只描述字段和文件格式，不对业务含义做解释。以 Indicators of Heart Disease (2020) 数据为例，建表语句包含 18 个 STRING 字段，并指定 OpenCSVSerde 处理 CSV 转义字符。建表完成后，通过 LOAD DATA INPATH 把 HDFS 路径中的 CSV 文件挂载到 Hive 表目录下。

```
CREATE EXTERNAL TABLE ods_heart_2020_raw(heart_disease STRING,bmi
STRING,smoking STRING,alcohol_drinking STRING,stroke STRING,physical_health
STRING,mental_health STRING,diff_walking STRING,sex STRING,age_category
STRING,race STRING,diabetic STRING,physical_activity STRING,gen_health
STRING,sleep_time STRING,asthma STRING,kidney_disease STRING,skin_cancer
STRING) ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
STORED AS TEXTFILE;
```

ODS 层不进行清洗处理，主要目的是保留数据追溯能力。当 DWD 层字段转换结果异常时，可回到 ODS 层核对原始值。若 ODS 层直接覆盖或删除原始字段，将增加后续问题排查难度。

4.1.3 DWD 层实现

DWD 层承接 ODS 层的原始数据，主要完成异常数据清洗、数据类型转换和字段名称统一三类处理。处理完成后，数据形成可直接用于统计分析和模型训练的明细层数据。

清洗过程通过 HiveQL 的 INSERT OVERWRITE 语句实现。以 Indicators of

Heart Disease (2020) 数据为例，主要的清洗操作包括：（ 1 ） BMI 从 STRING 转为 DECIMAL(6,2) ；（ 2 ） Smoking、 AlcoholDrinking 等 Yes/No 字段通过 CASE WHEN 映射为 1/0 的 INT 类型；（ 3 ） Sex 字段从 Male/Female 映射为 1/0 的 sex_code ；（ 4 ） HeartDisease 字段映射为 risk_label (Yes→1 , No→0) ；（ 5 ） Diabetic 字段保留原始文本值 (diabetic_text) 同时生成二值标记 (diabetic_flag) 。

UCI Cleveland 数据集的主要问题在于缺失值处理。ca 和 thal 两个字段中存在问号 (?) ，本文通过 CASE WHEN 语句将其转换为 NULL。原始目标变量 num 包含 0 到 4 五个取值，本文将其转换为二分类标签：当 num>0 时认为样本存在心脏病风险，并将 risk_label 设置为 1。年龄字段按 10 岁为间隔进行分组，以便与 BRFSS 调查数据的年龄段字段进行对齐。

DWD 层的核心表为 dwd_heart_feature_sample。该表通过 UNION ALL 整合三个数据集中的共有维度，如 risk_label、age_band、sex_code、bmi 和 smoking_flag 等，形成 28 列统一宽表。BRFSS 调查数据中缺失的临床指标（如 trestbps、chol 等）填充为 NULL，UCI 数据集中缺失的生活习惯字段同样填充为 NULL。每条记录额外保留 source_dataset 字段，用于标识数据来源，并支持 ADS 层按数据集进行

分组统计。

DWD 清洗脚本按字段类型分为三类处理。第一类是数值字段，如 BMI、PhysicalHealth、SleepTime，通过 CAST 转换为 DECIMAL 或 INT；第二类是二值字段，如 Smoking、Stroke、KidneyDisease，通过 CASE WHEN 将 Yes/No 映射为 1/0；第三类是分组字段，如 AgeCategory 和 BMI 分组，用于后续统计展示。

在统一特征表 `dwd_heart_feature_sample` 中，BRFSS 调查数据和 UCI 临床数据的字段并不完全相同。为保证 UNION ALL 能够执行，系统先定义统一字段清单，再要求各数据源按相同顺序输出字段。数据源缺失的字段统一填充为 NULL，例如 BRFSS 调查数据缺少 `trestbps`、`chol`、`thalach` 等临床指标，UCI 数据缺少 `Smoking`、`AlcoholDrinking` 等生活习惯指标。

清洗完成后需要进行三类校验：第一，通过 `COUNT(*)` 核对清洗前后记录数，确认记录数量未异常减少；第二，检查 `risk_label` 取值是否限定为 0 或 1；第三，抽样查看 BMI、SleepTime 等数值字段是否存在异常范围。校验通过后，DWD 表进入 ADS 聚合流程。

4.1.4 ADS 层实现与数据迁移

ADS 层的 SQL 统一使用 GROUP BY 做分组聚合。以 `ads_heart_by_age` 为例，

按 dataset_name 和 age_band 两个维度分组，COUNT(*) 统计样本数，SUM(risk_label) 统计阳性数，SUM(risk_label)/COUNT(*) 计算患病率。

ads_heart_lifestyle 将吸烟、饮酒、运动、睡眠四个因素用 UNION ALL 拼成统一的 factor_name/factor_value 格式，每行输出一个因素值的统计结果。

ads_uci_clinical_risk 对 UCI Cleveland 的 10 个临床指标逐一做分组统计，每个指标的每个取值各输出一行。

ADS 层的聚合结果通过 Python 同步脚本迁移到 MySQL。脚本流程为：PyHive 连接 Hive → SELECT * FROM ads_xxx → TRUNCATE MySQL 目标表 → 批量 INSERT INTO。9 张表全部同步完成后，Django 后端查询 MySQL 即可获取分析数据，实现 Hive 离线分析和 MySQL 在线查询的解耦。

ADS 层以页面展示需求为导向进行建表设计，而非直接面向原始字段建表。前端图表所需的数据粒度在 ADS 层预先完成聚合，从而避免用户访问页面时执行复杂计算。年龄、性别、BMI 等图表对应的 SQL 结构较为相似，均按 dataset_name 和具体维度字段进行分组，并计算 sample_count、positive_count 和 prevalence_rate。

以年龄分析为例，ads_heart_by_age 的聚合语句为：SELECT source_dataset AS dataset_name, age_band, COUNT(*) AS sample_count, SUM(risk_label) AS positive_count, ROUND(SUM(risk_label)/COUNT(*),4) AS prevalence_rate FROM dwd_heart_feature_sample GROUP BY source_dataset, age_band;

同步脚本运行时按表顺序执行。先同步样本规模较小的总览表，确认 MySQL 连接正常后，再同步年龄、性别、BMI、生活习惯、共病和模型指标表。每张表同步前写入开始日志，同步成功后更新行数 and 状态；如果 SQL 执行失败，则捕获异常文本写入 error_msg 字段。

4.2 预测模型设计

4.2.1 特征工程

特征工程基于 DWD 层的 dwd_heart_2020_clean 表。数值型字段（BMI、PhysicalHealth、MentalHealth、SleepTime）做 StandardScaler 标准化，将均值调整为 0、标准差调整为 1。分类型字段（Smoking、AlcoholDrinking、Stroke、DiffWalking、Sex、AgeCategory、Race、Diabetic、PhysicalActivity、GenHealth、Asthma、KidneyDisease、SkinCancer 共 13 个）做 OneHotEncoder 独热编码，将每个类别值展开为一个二值列。

scikit-learn 的 ColumnTransformer 将两路处理组合为 Pipeline，保证训练和推理

逻辑一致。数据按 8:2 划分训练集和验证集，分层抽样保持正负样本比例一致，随机种子 42。

模型训练流程如图 4-1 所示。




图 4-1 模型训练流程

特征工程不仅影响模型精度，也影响线上预测接口的稳定性。训练阶段使用的 ColumnTransformer 会被整体保存到 joblib 文件中，线上预测时不重新编写编码逻辑，而是调用 Pipeline.transform 和 predict_proba。该方式能够保证 OneHotEncoder 的类别顺序、StandardScaler 的均值方差与训练阶段保持一致。

类别不均衡是心脏病预测数据中的主要问题。Indicators of Heart Disease

(2020) 数据中阳性样本占比约 8.6% , 若仅追求准确率 , 模型可能倾向于将多数样本判为阴性。本文在逻辑回归和 SGD 模型中设置 `class_weight='balanced'` , 使阳性样本在损失函数中获得更高权重 , 从而提升召回率。

模型评估时需要同时比较 Accuracy、Precision、Recall、F1 和 AUC。心脏病风险筛查更强调尽可能发现潜在高风险人群 , 因此 Recall 和 AUC 比单纯准确率更具参考价值。

4.2.2 模型训练与评估

训练了四种模型 : 逻辑回归 (`class_weight=balanced`)、SGD 线性分类器 (`loss=log_loss`)、随机森林 (250 棵树) 和 Extra Trees (300 棵树)。以 AUC 为首要选择标准。

表 4-3 列出了 Indicators of Heart Disease (2020) 数据集上四种模型的评估结果。

表 4-3 Indicators 2020 模型评估结果

模型	准确率	精确率	召回率	F1	AUC
逻辑回归	0.704	0.233	0.783	0.359	0.821
SGD	0.754	0.259	0.708	0.379	0.801
随机森林	0.898	0.591	0.123	0.203	0.788
Extra Trees	0.876	0.350	0.198	0.253	0.777




图 4-2 Indicators 2020 四种模型指标对比

逻辑回归模型 AUC 最高 (0.821) ，召回率为 78.3% ，因此被选为最终模型。

随机森林准确率较高 (89.8%) ，但召回率较低 (12.3%) ，说明在阳性率仅为 8.6% 的数据集中，该模型更倾向于将样本判为阴性。心脏病筛查场景更关注高风险人群识别能力，因此高召回率更为重要。

表 4-4 为 UCI Cleveland 数据集的结果，逻辑回归 AUC 达到 0.967，准确率 86.9%。临床指标的预测效果远好于自报告调查数据。

表 4-4 UCI Cleveland 模型评估结果

模型	准确率	精确率	召回率	F1	AUC
逻辑回归	0.869	0.813	0.929	0.867	0.967
随机森林	0.885	0.839	0.929	0.881	0.950
SGD	0.803	0.700	1.000	0.824	0.945
Extra Trees	0.852	0.806	0.893	0.847	0.929




图 4-3 UCI Cleveland 模型指标对比

4.2.3 特征重要性与模型选用

图 4-4 和图 4-5 分别展示了两个数据集上的特征重要性排名。BRFSS 调查数据中年龄相关特征占据前几位；UCI 数据集中主要血管数目（ca）和胸痛类型（cp）最重要。




图 4-4 Indicators 2020 特征重要性排名




图 4-5 UCI Cleveland 特征重要性排名

综合两个数据集的结果，本文选择基于 Indicators of Heart Disease (2020) 数据集训练的逻辑回归模型作为系统在线预测模型。该数据集的输入字段 (BMI、年龄段、吸烟等) 均为用户可自行填写的健康指标，无需依赖临床检查。模型评估指

标和特征重要性通过 Python 脚本写入 ADS 层的 `ads_model_metrics` 和 `ads_model_feature_importance` 表，并在同步到 MySQL 后供前端展示。

4.3 多维数据分析

基于前文构建的 ADS 聚合表，本节从年龄、性别、生活习惯、BMI、共病史和睡眠六个维度对心脏病患病率分布进行分析。相关统计结果均由 Hive 执行 GROUP BY 聚合生成，并同步至 MySQL 后由前端通过 ECharts 进行可视化展示。

`ads_heart_by_age` 表按照数据集和年龄段两个维度进行统计。Indicators of Heart Disease (2020) 数据集的年龄分布结果如图 4-6 所示。18 至 24 岁年龄组的患病率不足 1%，55 至 59 岁年龄组约为 8%，80 岁以上年龄组超过 20%。结果表明，年龄与心脏病患病率之间存在明显正相关关系，且患病率随年龄增长呈现较快上升趋势。




图 4-6 各年龄段心脏病样本分布

ads_heart_by_sex 表显示，男性患病率约为 10.5%，女性患病率约为 6.8%，男性患病率明显高于女性。该差异可能与雌激素的心血管保护作用、男性吸烟比例较高等因素有关。具体对比结果如图 4-7 所示。




图 4-7 性别与心脏病患病率

ads_heart_lifestyle 表将吸烟、饮酒、运动三个因素统一为 factor_name/

factor_value 格式输出。吸烟人群患病率为 11.4%，非吸烟人群为 7.0%；有运动习惯人群为 7.7%，无运动习惯人群为 11.7%。饮酒因素的统计结果显示，适量饮酒人群患病率低于不饮酒人群，该现象可能与健康人群更倾向适量饮酒的选择偏差有关。

图 4-8 展示了各因素的对比结果。




图 4-8 生活习惯因素与心脏病患病率

ads_heart_by_bmi 表将 BMI 分为偏瘦(18.5)、正常(18.5-24)、超重(24-28)和肥胖(≥ 28)四组。肥胖组患病率约 10%，正常组约 7%。图 4-9 展示了 BMI 的分布情况。




图 4-9 BMI 分布与心脏病

ads_heart_comorbidity 表用于分析共病史与心脏病患病率之间的关系。统计结果显示，有中风史人群的患病率约为 29%，无中风史人群约为 7%，两者差异接近 4 倍。糖尿病人群患病率约为 18%，肾病人群患病率约为 23%。上述结果说明共病史与心脏病风险之间存在较强关联，具体对比见图 4-10。




图 4-10 共病史与心脏病患病率

sleep_metric 字段的统计结果显示，睡眠时间不足 6 小时和超过 8 小时的人群患病率均高于睡眠时间为 6 至 8 小时的人群，整体呈现 U 形分布。该结果与既有流行病学研究中关于睡眠时长和心血管风险关系的结论基本一致，如图 4-11 所示。




图 4-11 睡眠时长与心脏病患病率

4.4 后端接口设计

后端采用 Django REST Framework 的 ViewSet + Serializer 分层架构，核心接口如表 4-5 所示。

表 4-5 主要 API 接口

接口路径	方法	功能描述
/api/health	GET	服务健康检查
/api/auth/login	POST	用户登录，返回 JWT 令牌
/api/auth/register	POST	用户注册
/api/dashboard/overview	GET	总览指标（样本数、患病率）
/api/analysis/age	GET	年龄维度分析数据
/api/analysis/lifestyle	GET	生活习惯和共病维度分析
/api/analysis/clinical	GET	UCI 临床指标分析
/api/analysis/comparison	GET	数据集综合对比
/api/model/metrics	GET	模型评估指标和特征重要性
/api/predict	POST	在线心脏病风险预测
/api/predict/history	GET	预测历史记录查询
/api/admin/sync-log	GET	数据同步日志（管理员）
/api/admin/users	GET	用户管理列表（管理员）

后端分层设计遵循 Django REST Framework 的标准模式。Model 层通过 Django ORM 定义数据库表结构，每个 ADS 表和业务表对应一个 Model 类，Meta.db_table 指定 MySQL 表名。Serializer 层负责 Model 实例与 JSON 之间的序列化和反序列化，分析类接口使用 ModelSerializer 自动映射，预测接口使用自定义 Serializer 定义校验规则。ViewSet 层每个功能模块对应一个类，分析类继承 ReadOnlyModelViewSet 只提供查询操作，预测 ViewSet 自定义 create 方法处理推理逻辑。权限控制通过 permission_classes 配置，管理员接口设置 IsAdminUser 权限。URL 路由通过 DRF

的 DefaultRouter 自动注册。

预测接口的字段校验规则如表 4-6 所示。后端在 Serializer 层完成类型转换和范围校验，只有校验通过的数据才会进入模型推理流程。

表 4-6 预测接口字段校验规则

字段	校验规则	异常处理
BMI	$10 \leq \text{BMI} \leq 80$ ，可为空	超出范围返回 400
AgeCategory	必须属于固定年龄段枚举	非法枚举返回 400
Sex	Male/Female 二选一	缺失时使用训练默认值
Smoking	Yes/No 二选一	非法值返回 400
SleepTime	$0 \leq \text{SleepTime} \leq 24$	超出范围返回 400
PhysicalHealth	$0 \leq \text{天数} \leq 30$	超出范围返回 400
MentalHealth	$0 \leq \text{天数} \leq 30$	超出范围返回 400

接口异常处理规则如表 4-7 所示。系统把可预期错误和系统错误区分处理，前者返回明确中文提示，后者记录日志后返回统一错误信息。

表 4-7 接口异常处理规则

异常类型	触发场景	处理方式
参数错误	字段类型错误或枚举值非法	返回 400 和字段级错误信息
未登录	请求头缺少 JWT 令牌	返回 401 并提示重新登录
权限不足	普通用户访问管理员接口	返回 403
模型未加载	joblib 文件缺失或损坏	返回 500 并写入系统日志
数据为空	ADS 表暂无同步数据	返回空数组并在页面提示暂无数据
数据库异常	MySQL 连接失败或 SQL 执行失败	捕获异常并记录 error_msg

Django 接口按模块划分路由：analysis 负责分析图表数据，model 负责模型指标和特征重要性，predict 负责在线预测与历史记录，admin 负责同步日志、用户管理和模型维护。这样的路由划分与前端菜单结构保持一致，便于定位接口问题。

4.5 前端框架设计

前端基于 Vue3 Composition API 构建，主要技术组件包括：

Vue Router 负责页面路由管理。配置了路由守卫（beforeEach），未登录用户自动跳转登录页；管理员页面通过 meta.requiresAdmin 标记，普通用户访问时重定向到首页。路由采用懒加载（dynamic import），减少首屏资源体积。

Pinia 替代 Vuex 作为全局状态管理方案。定义了 useUserStore（用户登录状态、角色信息）和 useAnalysisStore（缓存分析数据，避免重复 API 请求）两个 Store。分析页面切换时，如果 Store 中已有对应维度的数据则直接渲染，不再重复请求后端。

ECharts 集成方面，封装了 useChart 组合式函数，统一管理图表实例的创建、更新和销毁。图表组件通过 props 接收数据和配置，内部使用 watch 监听数据变化自动重绘。柱状图、折线图、饼图、雷达图和 ROC 曲线图各封装为独立组件。

Axios 封装方面，创建 axios 实例并配置 baseURL、超时时间和拦截器。请求拦截器从 Pinia 的 userStore 中读取 JWT 令牌附加到 Authorization 头；响应拦截器统一处理 401（令牌过期）、403（权限不足）和 500（服务器错误）。

CSS 布局方面，大屏模式使用 CSS Grid 定义多个网格区域，每个图表占据指

定的 grid-area。分页管理模式使用 Naive UI 的 NLayout + NMenu 组件构建侧边栏导航。

前端页面按业务域拆分为五组路由：dashboard 用于可视化大屏，analysis 用于年龄、生活习惯、临床指标和综合对比，model 用于模型指标和特征重要性，predict 用于在线预测，admin 用于用户、日志和同步管理。每个页面只负责渲染自身业务数据，公共请求逻辑放在 api 目录中统一封装。

预测页面的交互流程为：用户填写表单后点击开始预测，页面先执行前端基础校验，再调用/api/predict 接口。接口返回后，页面右侧展示风险概率、风险等级和影响因素 Top3，下方预测历史表格自动刷新。若接口返回 400 错误，表单项附近显示具体错误；若返回 401，路由守卫跳转到登录页。

为了提升图表页面体验，ECharts 组件在 mounted 阶段初始化实例，在 watch 中监听数据变化，在 beforeUnmount 中销毁实例。窗口大小变化时触发 resize，保证大屏模式和分页模式都能正常自适应。

5 系统展示与测试

5.1 系统展示

本系统采用浏览器/服务器架构开发模式，前端基于 Vue3、Naive UI 和 ECharts 构建，后端基于 Django REST Framework 提供 API 服务。系统页面围绕数据可视化、数据概览、综合对比、模型评估和风险预测五类功能展开，页面数据来源于 ADS 层同步到 MySQL 后的聚合结果。

5.1.1 可视化大屏

可视化大屏用于集中展示系统核心指标，包括总样本数、心脏病阳性样本数、总体患病率、年龄高风险区间、模型 AUC 和主要特征重要性。页面通过 ECharts 渲染柱状图、饼图、折线图和雷达图，适合作为系统演示时的首页入口。



图 5-1 可视化大屏页面

由图 5-1 可知，系统将多维分析结果集中展示在同一页面中。顶部统计卡片给出总样本量、阳性样本数和整体患病率，中部区域展示年龄、性别、BMI 等维度的分布情况，右侧区域展示模型指标和特征重要性，便于用户快速了解数据总体特征。

5.1.2 数据概览页面

数据概览页面主要展示三个数据集的基本信息和清洗后的统计结果。页面上方展示 Indicators of Heart Disease (2020) 数据集、Indicators of Heart Disease (2022 UPDATE) 数据集和 UCI Cleveland 三个数据集的记录数、字段数、阳性样本占比和数据来源，下方展示各数据集之间的样本规模对比。



图 5-2 数据概览页面

图 5-2 展示了数据概览页面的运行效果。系统将数据集元信息、样本规模、目标变量分布和数据质量检查结果置于同一页面中，使用户能够直观比较不同数据源之间的差异，并为后续数据分析和模型训练提供基础依据。

5.1.3 综合对比分析页面

综合对比分析页面用于展示年龄、性别、BMI、生活习惯、共病史和临床指标等多个维度的统计结果。页面通过筛选条件控制数据集来源，用户可以在同一页面中对不同数据集的患病率趋势进行横向比较。



图 5-3 综合对比分析页面

图 5-3 展示了系统的综合对比分析页面。页面左侧为筛选条件和指标选择区域，右侧为图表展示区域。通过折线图、柱状图和雷达图的组合，系统能够同时呈现不同维度之间的差异，便于分析心脏病风险因素的分布规律。

5.1.4 模型性能对比页面

模型性能对比页面展示逻辑回归、SGD 线性分类器、随机森林和 Extra Trees 四类模型的训练评估结果。页面重点展示 Accuracy、Precision、Recall、F1 和 AUC 五项指标，其中 AUC 和召回率是心脏病风险筛查场景中的重点评价指标。



图 5-4 模型性能对比页面

图 5-4 展示了模型性能对比页面的运行效果。系统以柱状图和指标卡片的形式展示不同模型的性能差异，便于比较模型在分类准确性、召回能力和综合判别能力上的表现。根据测试结果，逻辑回归模型在 AUC 和召回率方面表现较稳定，因此被选为在线预测模块的默认模型。



图 5-5 ROC 曲线对比

ROC 曲线用于描述分类阈值变化时真正率和假正率之间的关系。图 5-5 展示了不同模型的 ROC 曲线对比结果，曲线越靠近左上角表示模型区分能力越好。结合 AUC 数值可以看出，逻辑回归和 SGD 线性模型在样本不均衡条件下具有较稳定的分类表现。

5.1.5 风险预测页面

风险预测页面提供 BMI、年龄段、性别、吸烟、饮酒、运动习惯、睡眠时长、身体健康天数、精神健康天数、中风、糖尿病、哮喘、肾病、皮肤癌等输入字段。

用户提交后，后端使用已保存的 scikit-learn Pipeline 进行特征预处理和模型推理。

预测结果包含三部分：第一是风险概率，保留四位小数；第二是风险等级，按照 0.33 和 0.67 两个阈值划分为低风险、中风险和高风险；第三是影响因素 Top3，根据当前样本在模型系数上的贡献度计算获得。

系统将每次预测的输入 JSON、风险概率、风险等级、模型名称和创建时间写入 prediction_record 表。用户可以查看个人预测历史，管理员可以在后台查看接口调用记录和模型文件状态。

5.2 系统测试

5.2.1 功能测试

本文对系统主要功能进行了逐项测试，测试结果如表 5-1 所示。

表 5-1 功能测试用例及结果

测试项	测试内容	预期结果	实际结果
用户登录	输入正确工号和密码	登录成功，跳转首页	通过
用户注册	填写用户名、密码和邮箱	注册成功，自动登录	通过
权限控制	普通用户访问管理员接口	返回 403 禁止访问	通过
数据总览	进入总览页面	显示三个数据集的样本数和患病率	通过
年龄分析	查看年龄分析图表	柱状图和饼图正确渲染	通过
生活习惯分析	查看各因素患病率	六个因素的分组柱状图正确	通过
临床指标分析	选择 UCI 数据集	展示 10 个临床指标的分组统计	通过
综合对比	查看三数据集对比	柱状图和雷达图正确	通过
模型指标查询	查看模型对比	四种模型的五项指标正确显示	通过
在线预测	填写 16 字段提交	返回风险概率和等级	通过
预测-缺失字段	只填 BMI 和年龄段	缺失字段自动补默认值，正常返回结果	通过
预测-异常输入	BMI 填入负数	返回参数校验错误提示	通过
预测历史	查看历史记录	按时间倒序展示预测记录	通过
大屏展示	切换到大屏模式	全屏展示，图表自适应	通过
Docker 部署	docker compose up	前后端和 MySQL 正常启动	通过

全部 15 项功能测试用例均通过，系统各模块功能完整，接口运行正常。

除表 5-1 的功能测试外，本文还对预测接口进行了样例输入测试。测试时构造

低风险、中风险和高风险三组输入，观察系统返回的概率区间和风险等级是否符合阈值规则。

表 5-2 预测样例测试结果

样例	主要输入	预测概率	风险等级	结果
样例 1	BMI=21.6，25-29 岁，不吸烟，有运动	0.18	低风险	通过

样例 2	BMI=27.4，50-54 岁，吸烟，睡眠 6 小时	0.46	中风险	通过
样例 3	BMI=31.2，65-69 岁，吸烟，有中风史	0.74	高风险	通过
样例 4	仅填写年龄段和 BMI，其余为空	0.33	中风险	通过
样例 5	BMI=-1，年龄段非法	拒绝请求	参数错误	通过

预测样例测试表明，接口能够正确处理完整输入、部分缺失输入和异常输入。

缺失字段会进入默认值补全流程，异常字段会在 Serializer 校验阶段被拦截，不会进入模型推理。

5.2.2 性能测试

对系统的关键性能指标进行了测试，结果如表 5-3 所示。

表 5-3 性能测试结果

测试项	测试方法	结果	是否达标
预测接口响应	单次调用/api/predict	平均 87ms	达标 (<100ms)
分析接口响应	单次调用/api/analysis/age	平均 32ms	达标 (<500ms)
页面首屏加载	Chrome DevTools Network	1.4s	达标 (<2s)
ECharts 渲染	Chrome Performance 面板	230ms	达标 (<300ms)
并发预测	wrk -c10 -d30s /api/predict	QPS=45， P99=210ms	可接受
数据同步耗时	9 张 ADS 表全量同步	3.2s	可接受

预测接口的耗时主要集中在特征预处理阶段，尤其是 OneHotEncoder 转换过程；

模型推理本身耗时较短。测试结果显示，页面首次加载时间为 1.4 秒，后续页面切换响应较快；ECharts 图表渲染耗时约 230 毫秒，能够满足系统交互需求。在 10 并发压力测试条件下，预测接口 QPS 为 45，P99 延迟为 210 毫秒，整体性能能够满足本系统的使用场景。

为了进一步验证页面兼容性，使用不同浏览器和分辨率打开系统核心页面，测试结果如表 5-4 所示。

表 5-4 浏览器兼容性测试

环境	测试页面	显示结果	结论
Chrome 124 / 1920×1080	可视化大屏	图表完整显示	通过
Edge 124 / 1440×900	数据概览页面	布局正常，无横向滚动	通过
Firefox 125 / 1366×768	风险预测页面	表单和结果卡片正常	通过
Safari / 1440×900	模型对比页面	ECharts 正常渲染	通过

兼容性测试结果说明，系统在主流桌面浏览器上均能正常运行。由于本系统主要用于毕业设计展示和后台数据分析，重点适配桌面端场景，移动端仅保证基本浏览。

5.2.3 安全测试

对系统的安全机制进行了验证，结果如表 5-5 所示。

表 5-5 安全测试结果

测试项	测试方法	预期结果	实际结果
JWT 令牌过期	使用过期令牌调用 API	返回 401 未授权	通过
无令牌访问	不带 Authorization 头调用 API	返回 401 未授权	通过
密码加密	查看数据库 password 字段	BCrypt 加密，不可逆	通过
SQL 注入	预测接口输入含 SQL 的字符串	被 Django ORM 参数化查询拦截	通过
XSS 攻击	输入含 script 标签的文本	被 Vue 模板自动转义	通过
越权访问	普通用户调用/api/admin/users	返回 403 禁止访问	通过

全部 6 项安全测试通过。JWT 认证机制和 BCrypt 密码加密确保了用户身份安全；

Django ORM 的参数化查询和 Vue 模板的自动转义分别从后端和前端两个层面防御

了注入攻击；角色权限隔离保证了管理员接口不被普通用户越权访问。

结 论

本文围绕心脏病健康数据分析与预测任务，完成了数据仓库构建、多维统计分析、机器学习模型训练和 Web 系统开发四个方面的工作。在数据处理方面，系统整合三份公开数据集，并基于 Hive 构建 ODS-DWD-ADS 三层数据仓库；经过清洗和标准化处理后，形成 9 张 ADS 聚合表，覆盖年龄、性别、BMI、生活习惯、共病史和 UCI 临床指标六个分析维度。在模型构建方面，Indicators of Heart Disease (2020) 数据集上的逻辑回归模型 AUC 达到 0.8207，召回率为 78.30%，在各模型中综合表现较优；在 UCI Cleveland 数据集上，同一模型 AUC 达到 0.9665。在系统实现方面，前端采用 Vue3 和 ECharts 实现可视化大屏及分页分析界面，后端采用 Django REST Framework 提供 RESTful 查询和在线预测接口，并通过 Docker Compose 完成容器化部署。

本文仍存在一定不足。首先，Indicators of Heart Disease (2020) 数据集中阳性样本占比仅为 8.6%，类别不均衡问题较为明显，导致模型精确率仅为 23.31%。其次，

当前数据仓库以离线批处理为主，尚未接入实时数据流。最后，预测模块主要输出

风险概率和风险等级，对单次预测结果的可解释性支持仍不充分。

后续研究可从三个方面进一步改进：一是针对样本不均衡问题引入 SMOTE 过采样、

Focal Loss 等方法；二是在现有 Hive 离线处理流程之外增加 Spark Streaming 等实

时计算组件；三是引入 SHAP 等可解释性方法，为单个预测结果提供更细粒度的特

征贡献说明。

致 谢

在本论文完成过程中，首先衷心感谢指导老师的悉心指导。选题阶段，老师结合数据科学与大数据技术专业特点，建议从公开医疗健康数据集入手，先完成数据仓库构建，再进一步开展统计分析和预测模型设计，为本课题确定了清晰的研究路线。在后续 SQL 建表、Django 接口调试和 ECharts 图表展示等工作中，老师多次提出具体而有效的修改意见，使论文和系统实现均得到不断完善。

同时，感谢大学四年课程学习为本课题提供的知识基础。数据结构、数据库原理、机器学习、大数据技术等课程中的相关内容，在本系统的数据处理、表结构设计、模型训练和平台搭建过程中均发挥了重要作用。通过本次毕业设计，课堂知识得以在较完整的工程实践中进一步巩固和应用。

感谢同学们在环境配置和系统调试过程中给予的帮助，尤其是在 Hadoop 集群搭建、Docker 网络配置和开发环境排查等方面提供了有益支持。

最后，感谢家人在学习和生活上的关心与支持，使本人能够专注完成毕业设计和论

文写作。在此一并致以诚挚谢意。

参 考 文 献

- [1] Detrano R, Janosi A, Steinbrunn W, Pfisterer M, Schmid J J, Sandhu S, Guppy K H, Lee S, Froelicher V. International application of a new probability algorithm for the diagnosis of coronary artery disease[J]. The American Journal of Cardiology, 1989, 64(5): 304-310.
- [2] Mohan S, Thirumalai C, Srivastava G. Effective heart disease prediction using hybrid machine learning techniques[J]. IEEE Access, 2019, 7: 81542-81554.
- [3] 梁靖涵;许亚杰.基于机器学习算法的心脏病预测诊断模型研究[J].现代信息技术,2022:4.
- [4] 李楠楠.基于神经网络算法建立心血管疾病预测模型[J].信息系统工程,2022:4.
- [5] 朱宵彤;庞春颖;朱涵.基于深度学习的心血管疾病预测模型[J].计算机应用,2021:5.
- [6] 吕婷婷;丁子建;袁亦方;林剑平;王贵锦;张萍.深度学习在心电图自动诊断和预测心血管疾病中的应用[J].中国心血管杂志,2021:4.
- [7] 左维.心血管疾病危险人群风险预测分级与心血管疾病的相关性研究[J].吉林医学,2021:4.
- [8] 林在宁;杨文杰;陈修洁.基于 Hadoop 的网站大数据分析系统设计[J].北京印刷学院学报,2022:4.
- [9] 王金元;王宇;张亚松;林昊;龚致富;李盼;安新艳.基于 Hadoop 的分布式财务异常数据分析系统设计[J].信息技术,2022:6.
- [10] 卢金龙.基于 Hadoop 生态圈的数据分析平台设计[J].金融电子化,2022:2.
- [11] 宋柯萱.基于 Hadoop 的大数据分析与优化略论[J].电脑知识与技术,2021:3.
- [12] 吴静.基于改进随机森林的苹果分类系统设计[J].陇东学院学报,2023:7.
- [13] 聂云丽,高国忠.基于随机森林的页岩气“甜点”分类方法[J].油气藏评价与开发,2023:15.
- [14] 刘文昌,魏赞,袁浩轩.基于 SMOTE 和 gcForest 的医疗小样本数据分类研究[J].物联网学报,2023:18.
- [15] 董佳.融合采样算法的信贷不平衡数据分类研究[J].商情,2023:4(41-44).
- [16] 陈静雯,张鹏鹏,徐思语.基于机器学习的呼吸道疾病预测可视化系统[J].物联网技术,2023:3.
- [17] 范梓豪,杨楚雯.基于 Vue 的气象信息可视化大屏的设计与实现[J].气象水文海洋仪器,2023:3.
- [18] 张业男.基于农业数据的可视化大屏教学案例研究[J].牡丹江教育学院学报,2023:4.

- [19] 郭尚志;章光裕;唐玉玲.基于机器学习的医疗大数据分析与临床应用[J].电脑知识与技术,2022:2.
- [20] 刘璐;蔡迎;张向阳;孙玮;杜思铭;王佳.医疗大数据分析技术在临床医学中的应用[J].中华医学图书情报杂志,2021:5.
- [21] 医疗数据分析中隐私保护方法研究[D].山东科技大学,2020.