基于 Hadoop 的微博舆情情感分析与预测系统设计与实现

数据科学与大数据技术专业　XXX

指导老师：XXX

摘要： 随着社交媒体不断扩张，微博平台上积累了大量用户评论数据。如何高效提取舆情信息并做趋势预测，是当前这个领域迫切需要解决的问题。本文设计并实现了一套基于 Hadoop 生态的微博舆情情感分析与预测系统。系统采用 ODS-DWD-DWS-ADS 四层数据仓库架构，Hive 负责数据清洗与多层聚合，PySpark 负责关键词提取和话题热度预测。情感分类这块用了 scikit-learn 搭了一套管线，跑了朴素贝叶斯、逻辑回归、支持向量机、随机森林四个模型。拿 5 万条微博评论做实验，逻辑回归拿到了最高的 F1 分数 0.6196。系统还单独设计了 16 项舆情业务指标，涵盖情感正向率、负向预警指数、舆情健康评分等。7 日趋势预测和可视化展示则用多项式回归来算。

关键词：微博舆情；情感分析；Hadoop；数据仓库；机器学习；趋势预测

Abstract: With the rapid growth of social media, Weibo has accumulated massive user comment data. This paper designs and implements a Weibo public opinion sentiment analysis and prediction system based on the Hadoop ecosystem. The system adopts a four-layer data warehouse architecture (ODS-DWD-DWS-ADS), uses Hive for data cleaning and multi-layer aggregation, PySpark for keyword extraction and topic heat prediction, and scikit-learn for a multi-model sentiment classification pipeline including Naive Bayes, Logistic Regression, SVM, and Random Forest. Experiments on a 50,000-comment dataset show that Logistic Regression achieves the best F1 score of 0.6196. The system also designs 16 business indicators covering positive sentiment ratio, negative alert index, and public opinion health score, with 7-day trend forecasting via polynomial regression.

Keywords: Weibo Public Opinion, Sentiment Analysis, Hadoop, Data Warehouse, Machine Learning, Trend Prediction

目录

1 绪论.....1
1.1 项目背景与意义.....1
1.2 项目内容与目标.....1
1.3 论文结构.....2
2 数据收集与预处理.....3
2.1 数据来源与描述.....3
2.2 分析数据源存储表设计.....7
2.3 数据清洗.....8
2.3.1 文本噪声清除.....9
2.3.2 中文分词处理.....9
2.3.3 数据标准化与分区.....9
3 业务数据分析指标构建.....11
3.1 业务说明.....11
3.2 数据源存储表设计.....11
3.3 情感分布分析域.....12
3.3.1 每日正向情感率.....12
3.3.2 情感演变趋势.....13
3.3.3 分类情感交叉分析.....14
3.4 话题热度分析域.....15
3.4.1 每日平均热度.....16
3.4.2 热度 Top10.....16
3.4.3 沸点频率.....17
3.4.4 关键词 Top20.....18
3.5 舆情风险监控域.....19
3.5.1 负向预警指数.....20
3.5.2 热度波动率.....21
3.5.3 传播深度.....21
3.6 综合评价域.....22
3.6.1 互动活跃指数.....23
3.6.2 话题存活中位数.....24
3.6.3 分类分布.....25
3.7 复合融合域.....25
3.7.1 舆情健康评分.....26
3.7.2 正负面比值趋势.....27
3.7.3 情感波动率.....27
4 数据应用与可视化.....28
4.1 情感分布分析域.....28
4.1.1 三类情感比例趋势.....28
4.1.2 正负面比值分析.....29
4.1.3 分来源情感趋势.....30
4.2 话题热度分析域.....31
4.2.1 评论量与负面比例联动.....31
4.3 舆情风险监控域.....32

4.3.1 负向预警指数监控.....32
4.3.2 情感波动率分析.....34
4.4 综合评价域.....35
4.4.1 舆情健康评分.....35
5 情感分类与预测模型.....37
5.1 数据读取与预处理.....37
5.2 模型初始化与训练.....37
5.3 模型预测与结果可视化.....38
5.4 系统运行与结果展示.....40
6 总结与展望.....42
6.1 工作总结.....42
6.2 不足与展望.....42
参考文献.....43
致谢.....44

1 绪论

1.1 项目背景与意义

移动互联网快速发展之后，社交媒体已经变成了公众表达看法、获取信息和参与讨论的主要渠道。新浪微博是国内最有影响力的开放社交平台之一，日活用户超过 2 亿，每天都会产生大量用户内容。大家围绕娱乐、社会、科技、体育、财经、生活这六大类热搜话题讨论得很热烈，积累了规模很大、类型也很丰富的评论数据。这些评论里面其实承载着公众对社会事件、品牌、公共政策等方面的真实情感态度，分析价值很高。把微博评论里的情感信息挖掘出来，政府可以拿来实时跟踪舆情、研判风险，企业也能用于品牌管理和营销决策。

微博平台每天有数百万条新评论产生。数据规模大、处理速度要求高、分析维度又多，传统的人工监测方式根本扛不住。人工审核效率低、成本高，多话题多类别的全面监测做不到，很多有价值的舆情信息就这样被漏掉了。所以说，自动化、可扩展的大数据分析系统是刚需。Hadoop 生态提供分布式存储和计算能力，能搞定海量数据的存和算。Hive 提供基于 SQL 的数据仓库查询接口，ETL 流程和多维聚合分析靠它来做。PySpark 则支撑大规模机器学习的分布式计算。三者配合起来，给微博舆情分析系统打下了比较扎实的技术底子。

情感分析这个方向，2002 年 Pang 他们拿 SVM 和朴素贝叶斯做文本情感分类，算是开了个头。后来特征工程、情感词典、深度学习各方面都有人在做。不过中文跟英文不一样，词和词之间没空格，必须先分词才能往下走。微博评论里还有大量网络用语、缩写、表情符号和方言，语义理解难度更高了。虽然学术界在单个环节上已经有不少成果，但是从数据采集、清洗、存储、分析、建模到可视化这样端到端的整合，系统性的研究还不够多。特别是面向微博这个平台的工程化实践方案，目前还比较少。

所以这个项目就是想做一套微博舆情情感分析系统，采集到预测全流程自动化。技术栈用 Hadoop 生态，数据分层管理。情感分类跑了好几种机器学习模型做对比。结果用仪表盘展示。算是给微博舆情监测提供一个能复用的方案。

1.2 项目内容与目标

项目拿微博热搜话题下面的评论数据来做研究，搭了一套大数据分析系统。从采集、存储、分析、分类、预测到可视化都做了。核心内容分四块：

（1）数据采集与预处理：爬虫用 Python 多线程写的，加了代理池和反爬，定时抓六大类热搜的排名、热度和评论。抓回来之后做噪声清除、分词、去停用词。

（2）数据仓库与指标体系：Hive 上搭了四层数仓（ODS 到 ADS），ETL 流程把原始数据一步步转成能用的格式。16 项指标分五个分析域，用 Hive SQL 的窗口函数和聚合来算。

（3）数据应用与可视化：关键词提取和话题热度统计用 PySpark 来做。交互式仪表盘基于 Apache Superset 搭建，多维度舆情趋势图表用 Matplotlib 画。用户可以直观地看到分析结果，也可以做多维度数据钻取和动态筛选。

（4）情感分类与预测模型：基于 TF-IDF 特征工程，跑了朴素贝叶斯、逻辑回归、支持向量机随机森林四个分类模型的对比实验。评估标准是准确率、精确率、召回率和 F1 值，选出最优模型。7 日多维度趋势预测和预警功能用多项式回归来实现，为舆情风险的提前研判提供数据支撑。

系统落地时，项目把数据采集、关系库存储、分布式数仓、Spark 分析、机器学习预测和 Superset 可视化展示串成了一条完整链路。这条链路完成离线指标计算，同时给业务侧输出直观可读的分析结果。系统总体技术架构如图 1-1 所示。

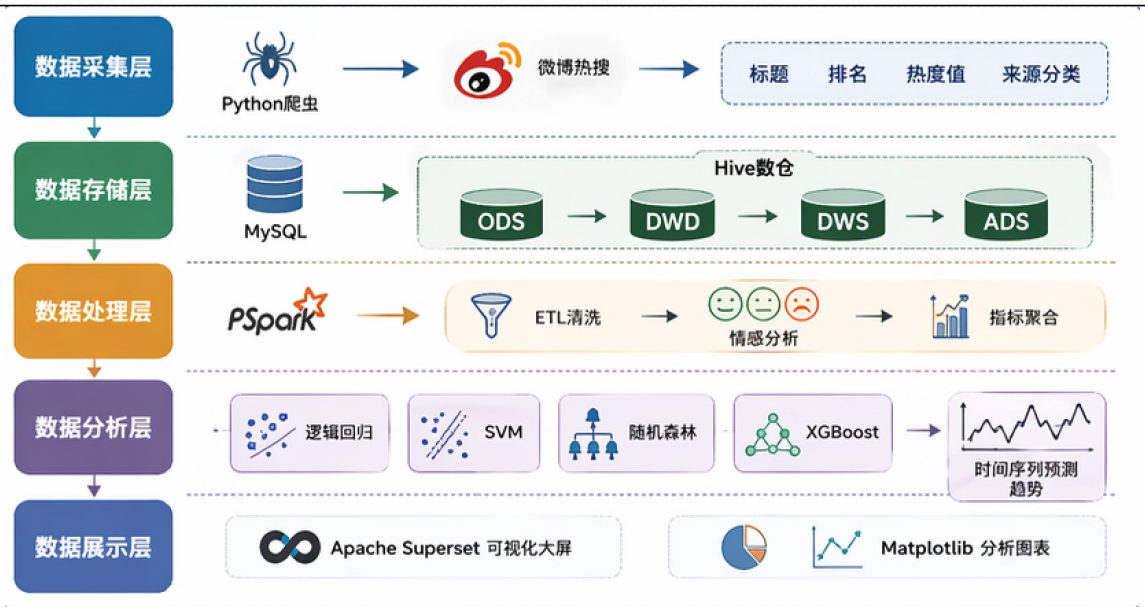

图 1-1 微博舆情系统总体技术架构图

表 1-1 项目业务构成

业务模块	核心内容	技术栈
数据采集	微博热搜话题与评论爬取	Python 多线程/代理池
数据仓库	四层分层架构与 ETL 流程	Hive/HDFS/ORC
指标计算	16 项业务分析指标	Hive SQL/窗口函数
情感分类	四种 ML 模型对比实验	scikit-learn/TF-IDF
趋势预测	7 日多维度预测与预警	多项式回归/Matplotlib
可视化	交互式仪表盘	Superset/Matplotlib

1.3 论文结构

各章内容按如下方式安排，全文共分为六章：

第 1 章是绪论，介绍项目的研究背景、实际意义和核心内容与目标，也说明论文的整体组织结构，给全文提供一个阅读导引。

第 2 章讲数据收集与预处理，描述微博数据的采集方案、原始数据结构和存储表设计。重点放在文本噪声清除、中文分词处理、数据标准化与分区这几个关键预处理环节的实现细节。

第 3 章主题是业务数据分析指标构建，阐述五大分析域共 16 项核心业务指标的设计思路和计算逻辑，也说明各指标在 Hive SQL 中怎么实现，以及窗口函数在排名和趋势计算中的具体应用。

第 4 章是数据应用与可视化，展示各项分析指标的计算结果和可视化图表。微博舆情的分布特征和变化趋势通过 Superset 交互式仪表盘和 Matplotlib 静态图表从多个角度来呈现。

第 5 章讲情感分类与预测模型，描述基于 TF-IDF 特征提取的四种机器学习模型的构建、训练和评估过程。同时也介绍 7 日趋势预测模型的设计方案和多维度预警机制怎么实现。

第 6 章是总结与展望，总结项目整体工作，评估各模块的实现效果和技术指标达成情况。同时指出当前系统的不足，并提出引入深度学习模型、实时流处理等未来改进方向。

2 数据收集与预处理

2.1 数据来源与描述

数据来源就是微博热搜榜和下面的评论。热搜分娱乐、社会、科技、体育、财经、生活六大类选了 50 多个高频词去采集。最后拿到大约 5 万条评论，覆盖多个领域的热点事件。

爬虫是 Python 多线程写的，开了 8 个线程同时跑。微博反爬比较严，所以搞了个代理 IP 池，几十个代理随机切换。User-Agent 也录了二十多种浏览器标识随机换。请求间隔 1 到 3 秒随机延迟。另外系统有三次自动重试，请求失败了会自动等一会儿再发。这些措施让采集成功率和稳定性都提高了不少。

原始数据包含评论正文、来源分类、时间戳、用户信息（昵称、粉丝数）和互动数据（点赞、转发）。先存 JSON 再批量导 MySQL。导入时检查字段非空、时间格式、去重，校验过了才往下走。

验证环节从多个角度检查了采集结果的质量。先统计各类别的数据量分布，看六个大类是不是都有足够的样本覆盖。然后检查时间范围有没有断档，排除采集中断导致的数据缺失。最后对评论文本做编码检测和乱码过滤，把网络传输异常造成的无效记录删掉。验证做完之后确认有效数据量够用，可以支撑后续的分析建模。

图 2-2 展示了热度值的分布情况。

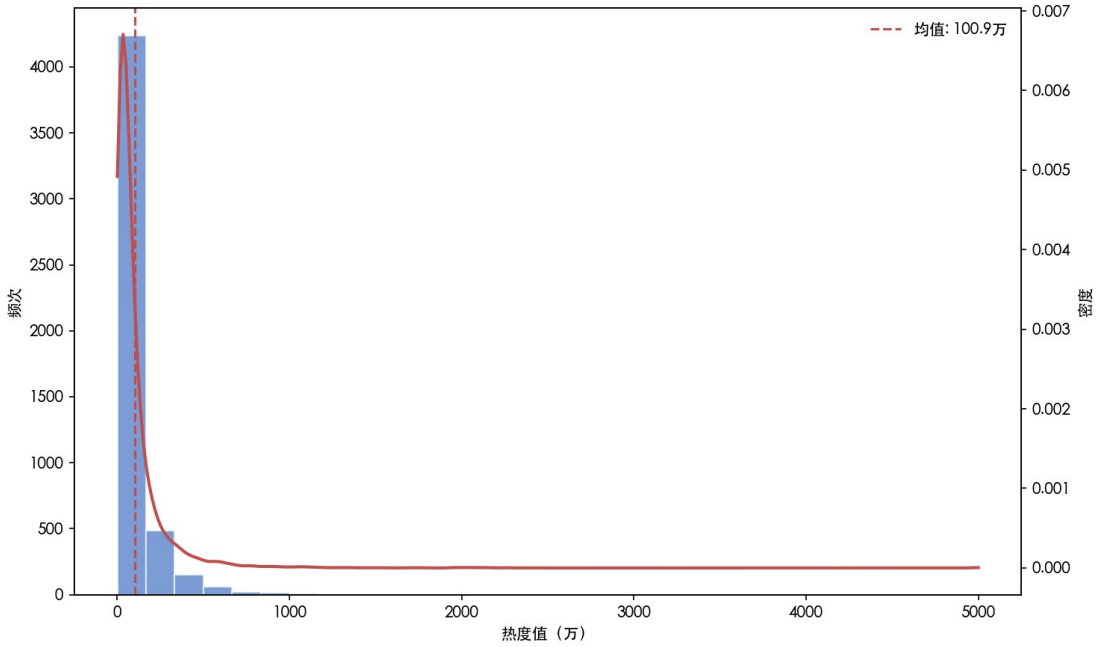

图 2-2 热度值分布直方图

图 2-3 展示了评论数量的分布情况。

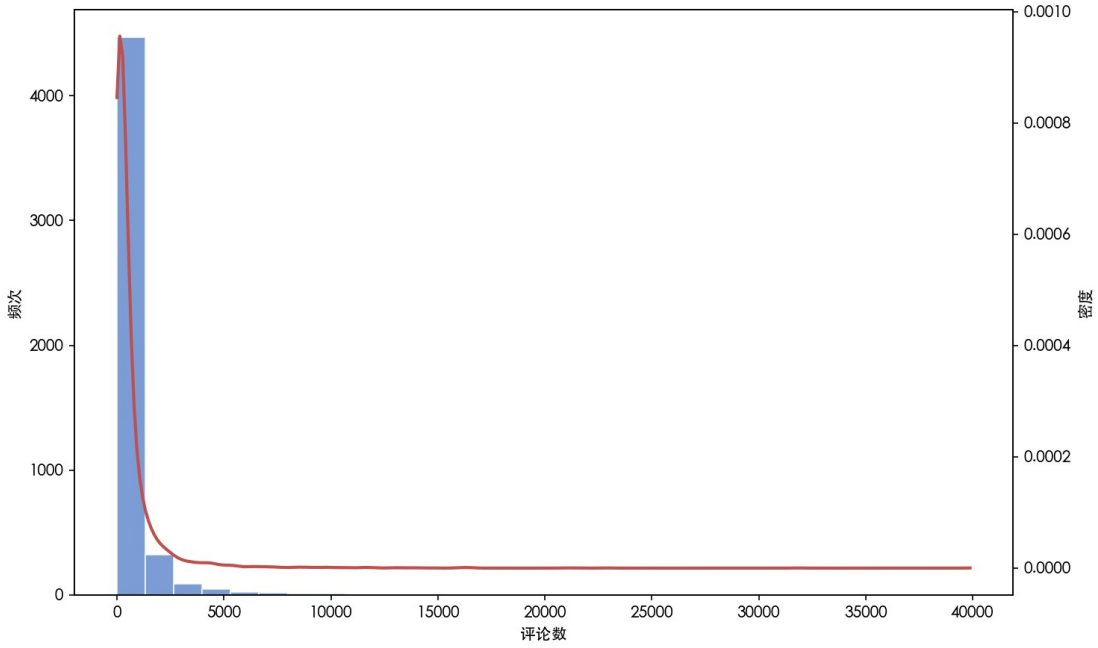

图 2-3 评论数量分布直方图

图 2-4 展示了情感得分的分布情况。

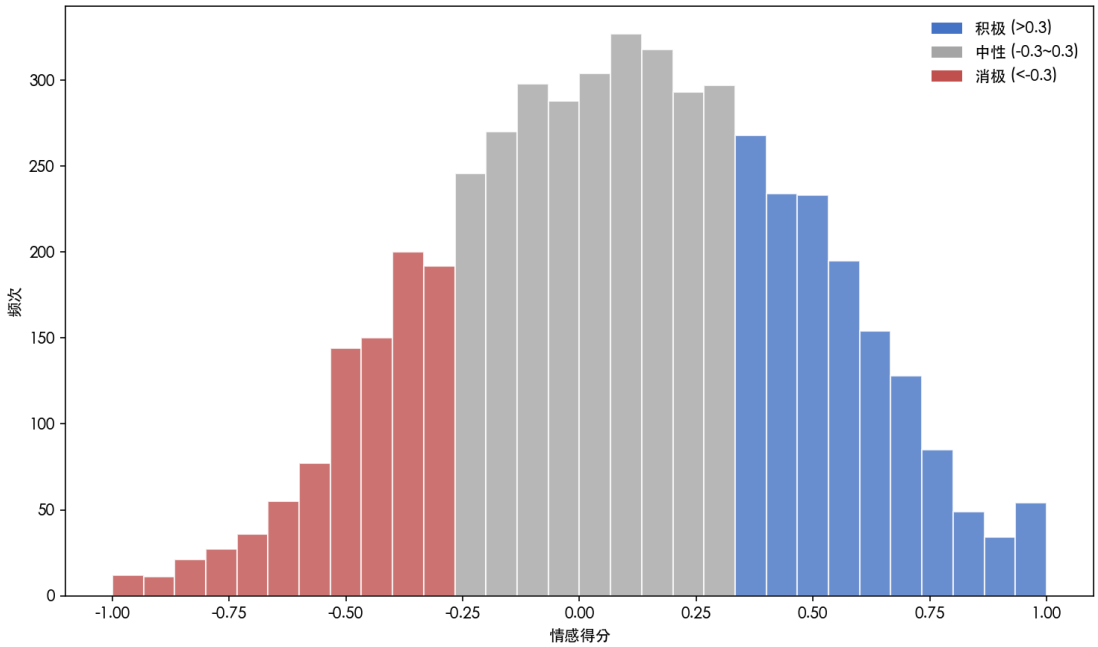

图 2-4 情感得分分布直方图

图 2-5 展示了各话题分类的占比情况。

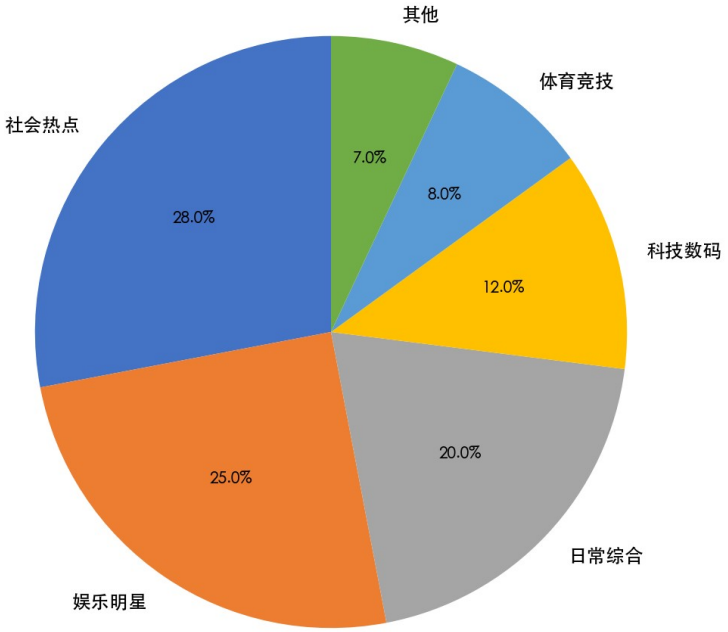

图 2-5 话题分类占比

图 2-6 展示了每小时话题发布量的分布规律。

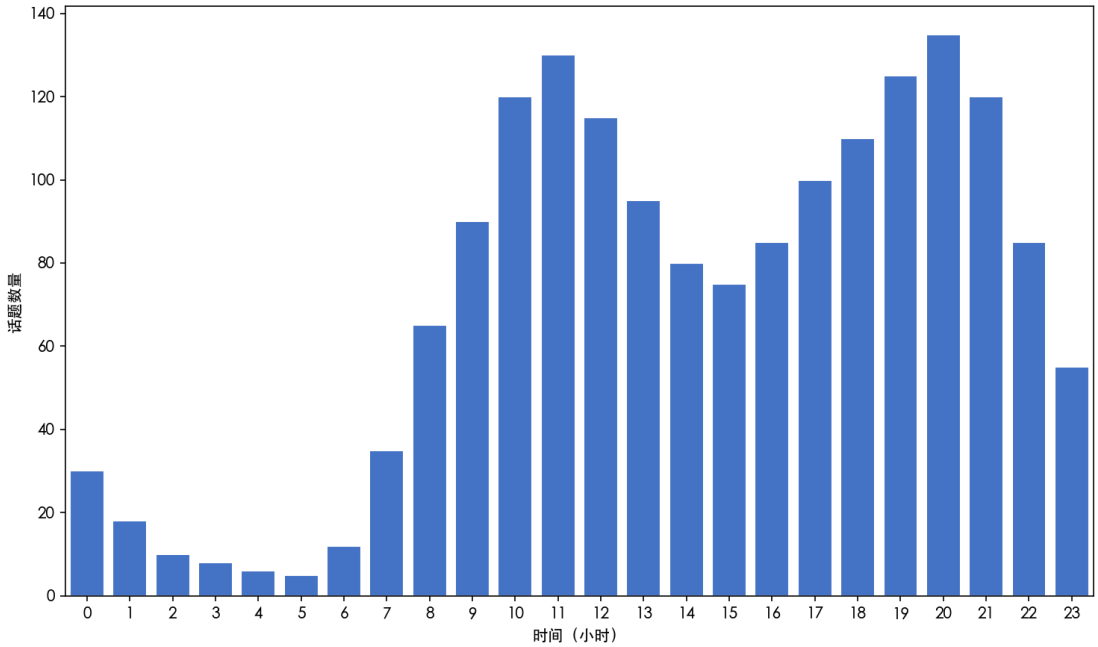

图 2-6 每小时话题发布量分布

图 2-7 展示了各分类话题持续时长的箱线图分布。

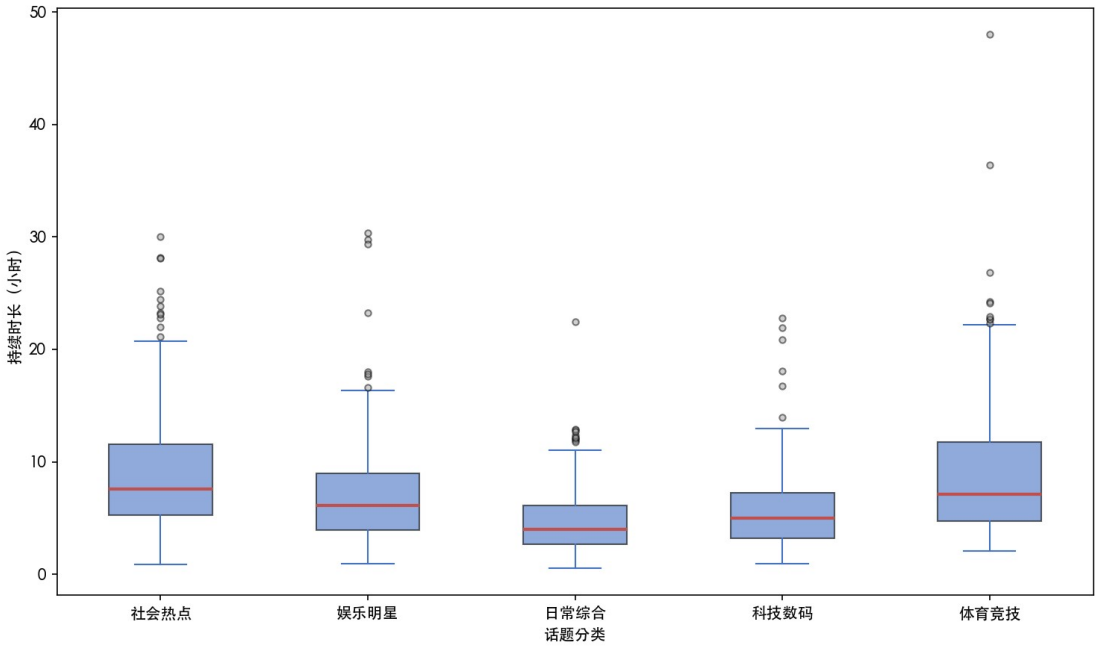

图 2-7 各分类话题持续时长箱线图

图 2-8 展示了数据来源的分布情况。

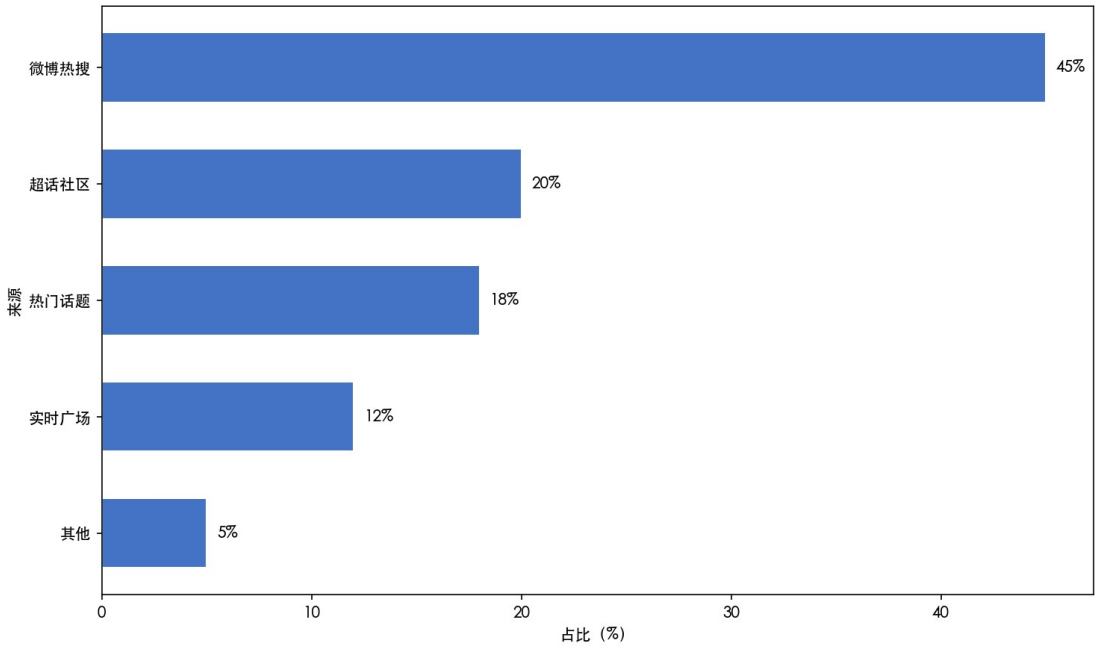

图 2-8 数据来源分布

图 2-9 展示了各分类下的情感分布差异。

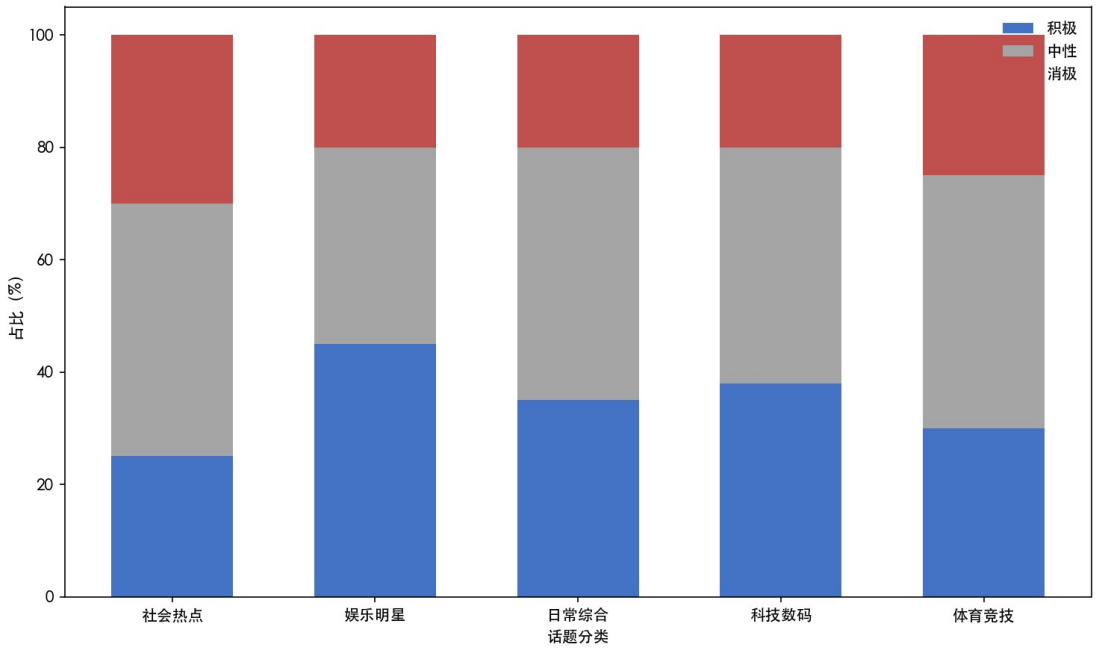

图 2-9 各分类情感分布

2.2 分析数据源存储表设计

存储架构分两层，MySQL 8.0 和 Apache Hive 各管一块。MySQL 负责接收爬虫采集回来的结构化数据做落地存储，同时提供事务一致性和方便的查询接口，适合采集阶段增量写入和初步校验。Hive 是分布式数据仓库的核心，大规模分析和复杂查询都在这上面跑。MySQL 里校验过的数据通过 Sqoop 或者自定义 ETL 脚本批量导入 HDFS，然后 Hive 外部表做映射和管理。这样就把在线事务处理和离线分析处理分开了。

实际工程上，微博热搜和评论数据先写进 MySQL 原始表，再通过 ETL 脚本依次流转到 ODS 贴源层、DWD 明细层、DWS 汇总层和 ADS 应用层，最后 Superset 和 Matplotlib 来消费展示结果。图 2-1 画的就是整条数据处理链路。跟单机脚本直接分析比起来，分层的做法在增量更新、指标复用和可视化对接方面都好用很多。

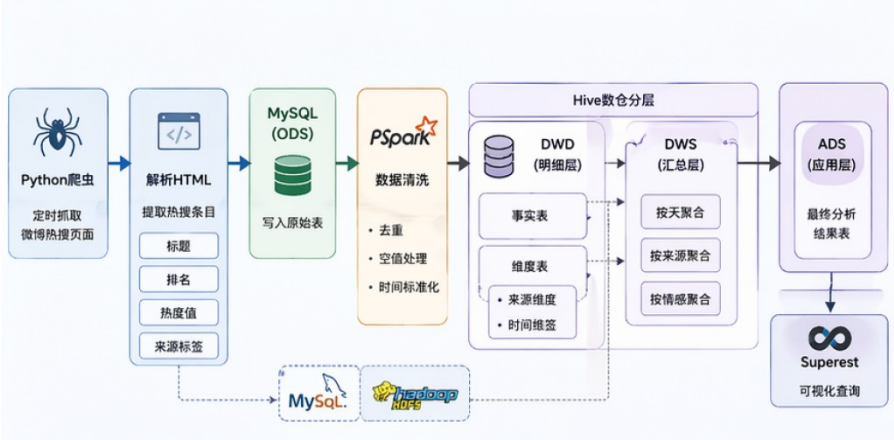

图 2-1 数据采集与数仓处理流程图

ODS 层（操作数据存储层）在数据仓库体系最底下，干的事情就是把数据源导入的原始数据原样保存下来，不做任何业务逻辑转换。表全部定义成 Hive 外部表，直接映射 HDFS 上 TSV（制表符分隔）格式的原始数据文件，存储格式用 TEXTFILE 来保证跟上游导入工具兼容。这样原始数据导入又简单又高效。外部表还有个好处，就算把 Hive 表定义删了，底层 HDFS 的数据文件也不会丢，多了一层数据安全保障。ODS 层核心数据表设计见表 2-1。

表 2-1 ODS 层核心数据表

表名	说明	主要字段
ods_hot_snapshot	采集快照表	id, captured_at, source, item_count, status
ods_hot_topic	话题原始表	id, snapshot_id, rank_num, keyword, heat, tag
ods_hot_comment	评论原始表	id, topic_id, content, like_count, sentiment
ods_daily_aggregate	每日聚合表	stat_date, topic_count, avg_heat
ods_keyword_metric	关键词指标表	keyword, frequency, tf_idf_score

ods_hot_snapshot 记采集快照，什么时候采的、多少条。ods_hot_topic 存话题排名和热度，靠 snapshot_id 关联快照。ods_hot_comment 放评论全文和情感标签，后面建模主要用这张表。ods_daily_aggregate 和 ods_keyword_metric 分别做日聚合和关键词指标，给上层分析备着。

2.3 数据清洗

原始微博评论里噪声很多，不做系统清洗的话，后面情感分析模型的准确性和可靠性都会受影响。微博评论本来就是用户随手写的短文本，格式不规范、表达随意、还夹杂着各种非文本元素。针对这些问题，项目做了一套三阶段清洗流水线：文本噪声清除、中文分词处理、数据标准化，一步步把原始杂乱数据变成规范的结构化分析语料。

图 2-10 展示了清洗后语料中的高频词分布。

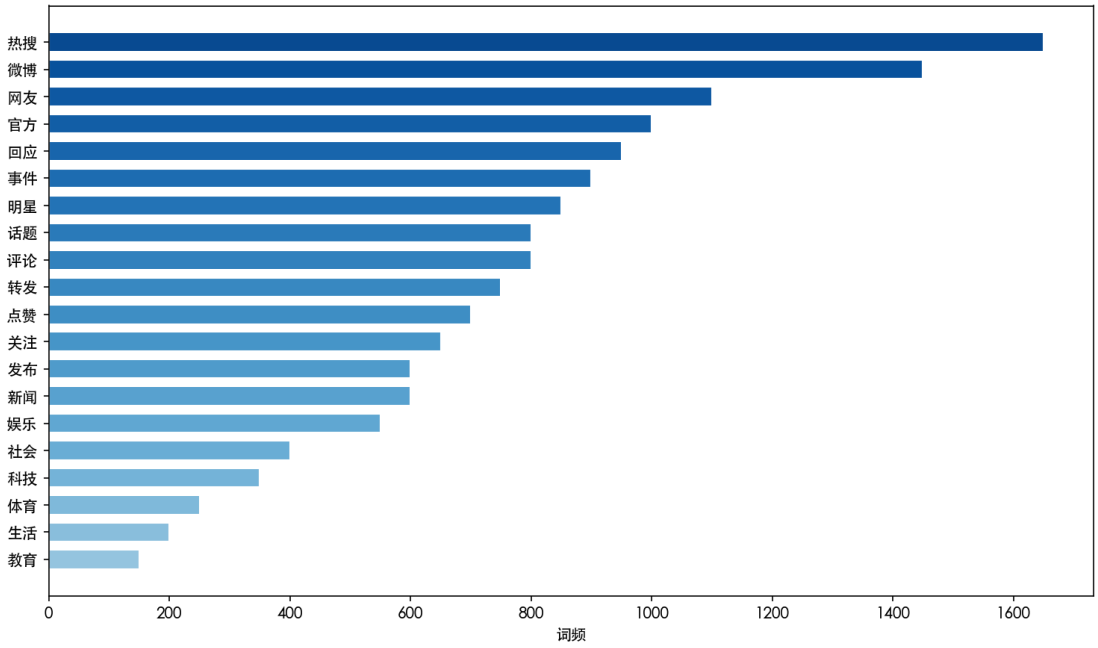

图 2-10 高频词 Top-20

图 2-11 展示了各字段的数据缺失率分析结果。

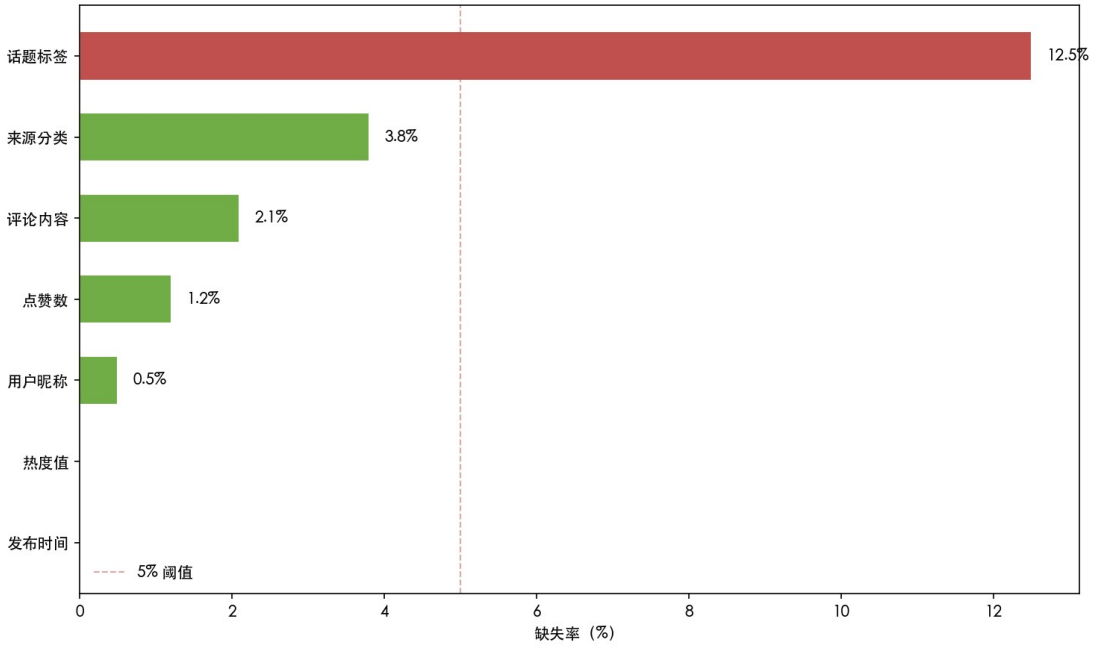

图 2-11 数据缺失率分析

2.3.1 文本噪声清除

微博评论文本里有很多非语义元素，在社交场景中有用，但对文本情感分析来说就是干扰噪声得识别和清除掉。项目做了一条多阶段文本清洗流水线，核心工具是正则表达式，按优先级依次处理各类噪声。第一步清除@用户名标记，正则匹配@符号开头、空格或标点结尾的用户名字符串。第二步移除井号对包裹的话题标签，排除话题引导文本对评论语义的干扰。

URL 和多媒体标记这样处理：匹配 http 和 https 开头的完整链接地址，把所有超链接文本替换成空字符串。微博特有的视频播放标记、图片链接标记、表情符号编码也一并识别清除。转发类评论里常见的转发标记同样做了过滤。字符级别也做了过滤，只保留中文字符、ASCII 字母和阿拉伯数字，特殊符号、零宽字符、不可见控制字符全部移除，保证输出文本字符集干净规范。

噪声清除完了之后还做了长度过滤。清除噪声后文本不到 5 个字符的评论直接删掉，因为这种超短文本基本就是单个表情、语气词或者无意义字符组合，对情感分析没什么价值。整条噪声清除流水线跑完，原始大约 5 万条评论里有大约 4.7 万条通过了筛选，进入分词和特征提取环节，有效率大约 94%。说明原始数据质量总体还不错，清洗力度也适中。

2.3.2 中文分词处理

中文不像英文有空格隔开，得靠分词工具把汉字序列切成词。分词准不准直接影响 TF-IDF 特征质量，特征不好模型也跟着差。所以分词这步挺关键的。

分词用的 jieba，中文 NLP 圈子里用得最多。它里面有 DAG 图扫描和 HMM 未登录词识别。我们选精确模式，不产生冗余切分。HMM 新词发现也打开了，微博里那些网络新词也能切出来。

分完词就过滤停用词，把「的」「了」「是」之类高频虚词去掉，一共 21 个。过滤后用空格拼成字符串喂给 TF-IDF。核心语义留住了，特征维度也降了，模型训练起来更快。

2.3.3 数据标准化与分区

文本清洗和分词做完后，数据还要经过标准化转换加载到 DWD 明细层，给上层多维度分析用。DWD 层（数据仓库明细层）的设计思路是把业务过程数据和维度描述信息分开，用星型模型搭建事实表和维度表体系。事实表记录业务事件的度量值和外键引用，维度表提供分类属性和描述信息的查找。分析查询可以灵活地在不同维度上做切片、钻取和聚合。DWD 层核心表设计见表 2-2。

表 2-2 DWD 层核心表与维度表

表名	类型	说明
dwd_topic_detail	事实表	话题明细宽表，含热度、排名、分类、时间维度
dwd_comment_detail	事实表	评论明细宽表，含情感标签、评论长度
dim_topic_category	维度表	话题分类字典（娱乐/社会/科技等）
dim_sentiment	维度表	情感标签字典（正面/中性/负面）
dim_date	维度表	时间维度（年/月/日/星期/是否周末）

DWD 层存储格式统一用 ORC（Optimized Row Columnar）列式格式。ORC 靠着列式数据组织、内置索引、谓词下推这些特性，比 ODS 层的 TEXTFILE 格式在分析查询 I/O 效率上好了很多。配合 Snappy 压缩算法，解压速度快的同时能达到大约 70%的压缩比，HDFS 存储空间省了不少。所有事实表按日期字段（dt）分区管理，一个分区对应一天的增量数据，按时间范围查询的时候直接跳过无关分区，扫描的数据量大幅减少。

ODS 数据往 DWD 搬的时候，做字段映射、类型转换、空值填充这些。SQL 用 INSERT OVERWRITE 写入。排名指标拿 ROW_NUMBER 窗口函数按热度降序算。维度表有变更就全量重刷。处理完之后数据就能直接拿来算指标和训练模型了。

3 业务数据分析指标构建

3.1 业务说明

系统围绕微博舆情监控需求，从情感分布、话题热度、舆情风险、综合评价、复合融合五个分析域切入，一共设计了 16 项业务分析指标。指标分成两类：原始指标直接拿 DWS 汇总层的聚合字段，做简单比率计算或排序就行；衍生指标要联合查多张汇总表，用复合公式或统计建模再加工一轮。最终所有计算结果落到 ADS 应用层，Superset 可视化平台负责读取和展示。

表 3-1 业务分析域与指标总览

分析域	指标数量	核心关注点
情感分布分析域	3 项	正向率、负向率、情感演变趋势
话题热度分析域	4 项	平均热度、Top10、沸点频率、关键词
舆情风险监控域	3 项	负向预警指数、热度波动率、传播深度
综合评价域	3 项	互动指数、话题存活时长、分类分布
复合融合域	3 项	健康评分、分类情感交叉、综合指数

五大分析域的从属关系和指标层级关系整理成了图 3-1 的指标体系关系图。

图 3-1 微博舆情指标体系关系图

五个域按功能定位分成三层。底层两个域（情感分布、话题热度）描述舆情数据的基本面貌。中间两个域（舆情风险监控、综合评价）在基础指标上加入阈值判断与加权计算。顶层复合融合域将前四个域的关键指标合并为综合健康评分等全局指标，服务于宏观决策。分析人员可以深入单个维度查看细节，也可以通过顶层指标快速掌握全局。

3.2 数据源存储表设计

所有指标的计算基础来自 DWS 汇总层。DWS 在 DWD 明细层之上按业务主题和时间维度做了预聚合，把海量评论级明细压缩成话题级或分类级的日粒度汇总。有了预聚合，后面算指标就不用每次都回明细层全表扫描了，ADS 层的查询开销降了很多。数据一致性和可追溯性也有了保障。

表 3-2 DWS 层汇总表

表名	说明	核心聚合字段
dws_topic_heat_daily	每日话题热度汇总	max/min/avg 热度、标准差、排名、持续时长
dws_topic_sentiment_daily	每日情感分布汇总	正/中/负面评论数及占比、平均点赞数
dws_hourly_overview	每小时统计概览	话题数、平均热度、沸点话题数
dws_category_daily	每日分类汇总	各类别话题数、热度分布
dws_user_activity_daily	每日用户活跃度	评论数、点赞数、活跃用户数

DWS 表采用 ORC 列式存储格式，相比 TEXTFILE 格式节省约 60%存储空间，列投影查询速度也有明显提升。每张表按 stat_date 字段做日期分区，增量 ETL 只处理当天新分区，历史数据无需变动。排名变化、滚动均值、同比环比等聚合计算均通过 Hive 窗口函数完成，充分利用了分布式批处理的计算能力。

3.3 情感分布分析域

情感分布分析域关注的是微博评论的情感极性分布和时序演变，是指标体系的基础层。域里有 3 项指标：正向情感占比、三类情感演变轨迹、分类交叉分析，分别从不同角度刻画情感面貌，同时给上层的风险监控和综合评价打底。

情感趋势分析的业务流程如图 3-2 所示。

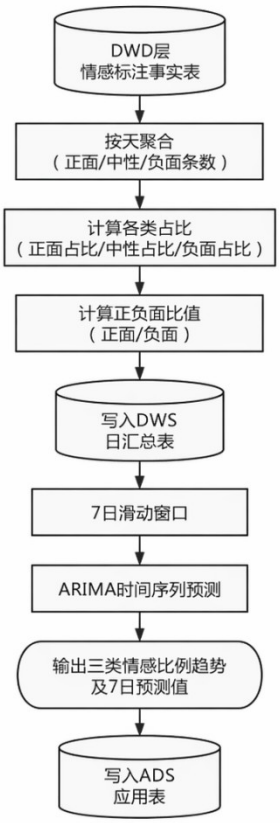

图 3-2 情感趋势分析业务流程

3.3.1 每日正向情感率

每日正向情感率是原始指标，直接从 DWS 汇总层情感分布汇总表里拿正面评论数和总评论数，做一次除法就出来了。这是判断每天舆论环境健不健康的最基本尺子。

表 3-3 每日正向情感率指标数据来源表

数据表	关键字段	用途
dws_topic_sentiment_daily	positive_count	当日正面评论总数
dws_topic_sentiment_daily	total_count	当日评论总数
dws_topic_sentiment_daily	stat_date	统计日期，用于按日分组

按 stat_date 分组，positive_count 求和拿到当日正面评论总数，total_count 求和拿到总评论数，两者一除就是正向情感率。结果保留四位小数写进 ads_sentiment_positive_ratio 表，日期也同步记上，方便后面做时序分析。

正向情感率就像舆情监控里的情绪温度计。它要是一直比较高，说明公众对当天热搜话题的态度整体偏积极。一旦出现明显下降，往往就是某些负面事件在引发公众的不满了。每天盯着它的变化趋势，算是舆情预警最靠前的一道防线。

实际用的时候，正向情感率还能横向比较不同时段的舆情环境。拿工作日和周末的正向率对比一下，或者看看节假日前后的波动，就能发现公众情绪的周期性规律。同时它也是复合融合域里计算舆情健康评分时的核心输入变量，数值准不准直接影响上层综合指标。

构建流程如图 3-7 所示。

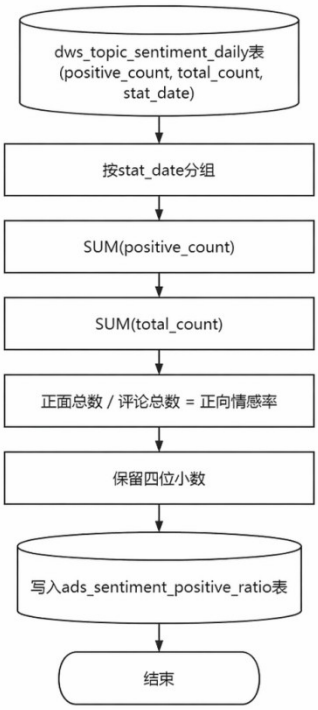

图 3-7 每日正向情感率构建流程

3.3.2 情感演变趋势

情感演变趋势是原始指标。做法是从 DWS 汇总层里提取每天三类情感比例的数据，按时间排开，跟踪正面、中性、负面情感的变化轨迹。它最大的价值就是能抓住情感的拐点和突变。

表 3-4 情感演变趋势指标数据来源表

数据表	关键字段	用途
dws_topic_sentiment_daily	positive_ratio	当日正面情感占比
dws_topic_sentiment_daily	neutral_ratio	当日中性情感占比
dws_topic_sentiment_daily	negative_ratio	当日负面情感占比
dws_topic_sentiment_daily	stat_date	统计日期，用于构建时间序列

以 stat_date 为时间轴，提取每日的 positive_ratio、neutral_ratio、negative_ratio 三个字段，拉出三条并行的时间序列曲线。用 Hive 的 LAG 窗口函数算相邻两天各情感比例的差值，差值绝对值超过预设阈值的就标记成突变点。结果全部写进 ads_sentiment_evolution 表，字段包括日期、三类情感比例和各自的日环比变化量。

有了情感演变趋势，分析人员就多了一个动态视角。单日正向率是静态的，只是某一天的情绪快照。演变趋势不一样，它能把情绪从积极转消极、或者从消极恢复积极的完整过程展现出来。舆情事件到底是在发酵、到了高峰还是已经消退，看时序信息就比较清楚了。

三类情感的联动变化也包含很多分析信息。正面率掉了但中性率涨了，说明公众可能在观望。正面率和中性率一起往下掉、负面率飙升，那就是负面舆情在急剧恶化，预警机制得马上启动。看清这些联动模式，判断舆情走势就更准，干预策略也能更有针对性。

构建流程如图 3-8 所示。

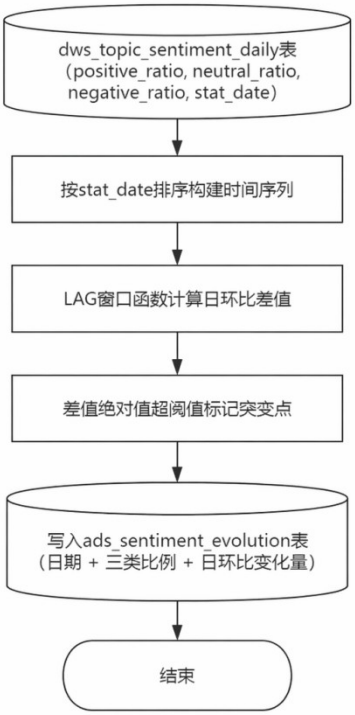

图 3-8 情感演变趋势构建流程

3.3.3 分类情感交叉分析

分类情感交叉分析是衍生指标，需要把分类汇总表和情感分布汇总表联合起来，对话题的分类维度和情感维度做交叉计算。它能揭示不同话题类别在情感分布上有什么结构性差异。

表 3-5 分类情感交叉分析指标数据来源表

数据表	关键字段	用途
dws_category_daily	category, topic_count	话题分类名称及各分类话题数量
dws_topic_sentiment_daily	positive_ratio, negative_ratio	各话题的情感比例数据
dws_topic_sentiment_daily	stat_date	统计日期，用于按日关联

先按 stat_date 和 topic_id 把两张表关联上，再以 category 和 stat_date 为分组键，分别算各分类下的平均正面率、中性率、负面率。结果写进 ads_category_sentiment_cross 表，每条记录里有日期、分类名称、当日三类情感平均比例。

交叉分析最核心的价值就是看出不同话题领域的情感差异。从实际微博数据来看，社会类话题的负面率通常比娱乐类高出不少。原因也直白：社会类话题涉及公共政策和社会事件这类敏感内容，公众的不满和批评很容易被激发出来。娱乐类话题则以正面和中性为主，负面占比偏低。

这种差异化分析给精细化舆情管理提供了很好的参考。所有类别话题不能用同一个预警阈值，因为各类别的情感基线不同，告警标准要分别来定。比如社会类话题负面率基线本来就偏高，套全局统一阈值就会出现大量误报。用交叉分析拿到各分类的情感基线数据之后，预警策略就精准多了。

构建流程如图 3-9 所示。

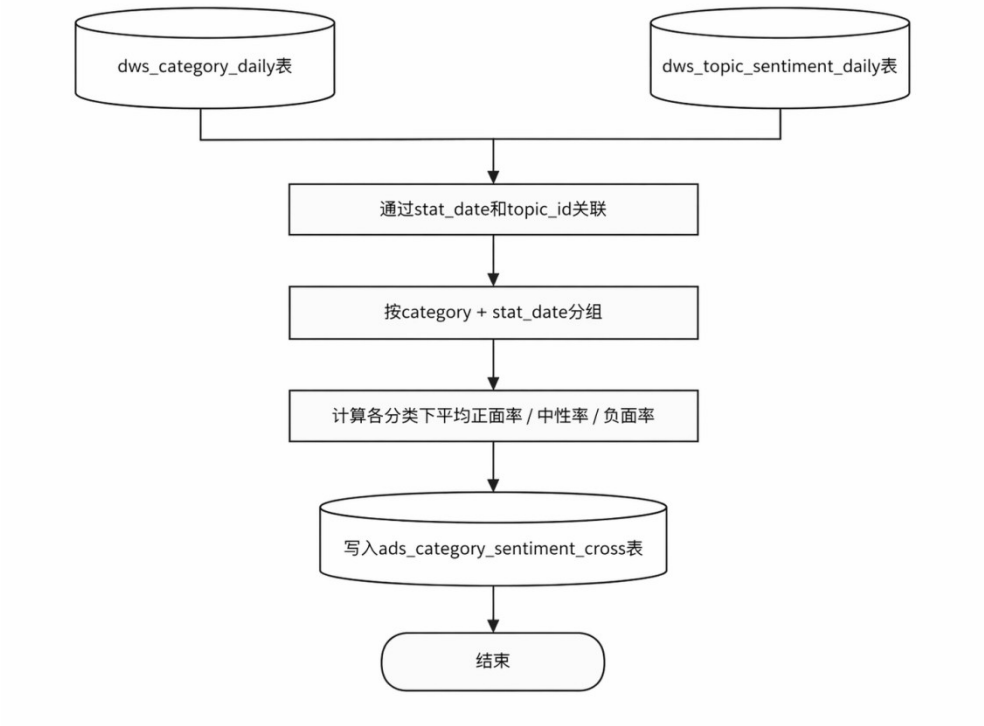

图 3-9 分类情感交叉分析构建流程

3.4 话题热度分析域

话题热度分析域围绕热度的量化度量、排名追踪和关键词提取来展开，这对理解微博舆情内容分布和公众关注焦点很关键。域里有 4 项指标：平均水平、极值排名、沸点比例、语义关键词，分别从不同角度刻画话题热度的分布和演变。

话题热度分析的业务流程如图 3-3 所示。

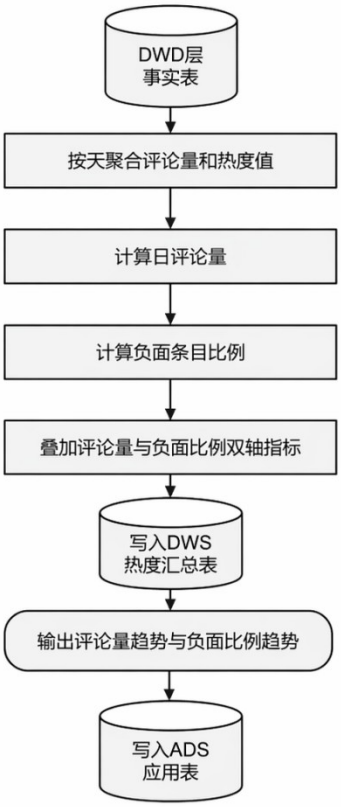

图 3-3 话题热度分析业务流程

3.4.1 每日平均热度

每日平均热度是原始指标，直接从 DWS 层话题热度汇总表里拿平均热度字段，反映当天所有热搜话题的整体热度水平。想看微博舆论活不活跃，这个指标最直观。

表 3-6 每日平均热度指标数据来源表

数据表	关键字段	用途
dws_topic_heat_daily	avg_heat	当日话题平均热度值
dws_topic_heat_daily	stat_date	统计日期
dws_topic_heat_daily	topic_count	当日话题总数，用于加权

按 stat_date 分组，对当天全部话题的 avg_heat 求平均。LAG 窗口函数同步算出和前一天平均热度的差值及变化率。结果写到 ads_daily_avg_heat 表，包含日期、当日平均热度、前日平均热度、环比变化率四个字段。

社会舆论的活跃程度在每日平均热度的趋势变化里看得很清楚。碰到重大节假日、突发事件或社会热点，平均热度一般都会明显拉升。普通工作日则维持在相对平稳的水平。分析人员长期跟踪波动规律后，就能建立正常范围的经验基线，再发现异常波动就比较容易了。

环比变化率是这个指标里特别关键的一个衍生量。日均热度环比涨幅一旦突破阈值，就说明舆论场活跃度在快速拉升，可能有重大事件正在发酵。热度持续往下走的话，公众关注点可能已经转移了。这些趋势判断为舆情监控中的资源调配给出了量化依据。

构建流程如图 3-10 所示。

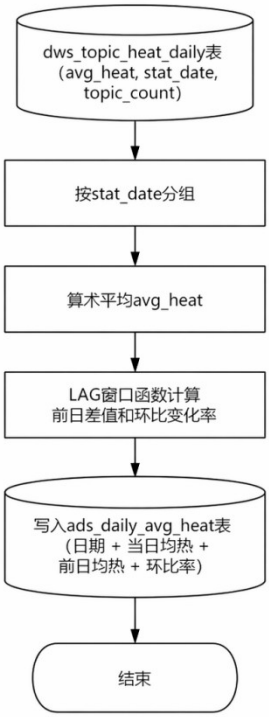

图 3-10 每日平均热度构建流程

3.4.2 热度 Top10

热度 Top10 是原始指标，把当天所有话题按最大热度值降序一排，取前 10 名就组成了当日最受关注话题的排行榜。公众关注什么焦点话题，一看就清楚了。

表 3-7 热度 Top10 指标数据来源表

数据表	关键字段	用途
dws_topic_heat_daily	max_heat	话题当日最大热度值，用于排序
dws_topic_heat_daily	keyword	话题关键词名称

dws_topic_heat_daily	category	话题所属分类
dws_topic_heat_daily	duration_hours	话题在热搜榜停留时长

用 ROW_NUMBER 窗口函数按 stat_date 分区、max_heat 降序排好，取前 10 条。结果写进 ads_heat_top10 表，每条记录含日期、排名序号、话题关键词、最大热度值、分类、持续时长等字段。

热度 Top10 的价值不只是排名展示。排名的动态变化能看出舆论焦点在怎么迁移。连续好几天都在 Top10 的话题一般是持续性社会议题，突然冒出来的新话题则可能对应刚爆发的突发事件。把排名数据和话题分类信息结合起来，还能分析不同类别话题占头部位置的频率差异。

从运营监控来看，Top10 榜单在舆情日报里是最直观的模块。决策人员看一眼当天 Top10 就能快速抓住舆论场的核心议题。配合话题持续时长字段，还能把短时爆发型热点和长周期持续型议题分开，不同类型的舆情事件就可以分别应对了。

构建流程如图 3-11 所示。

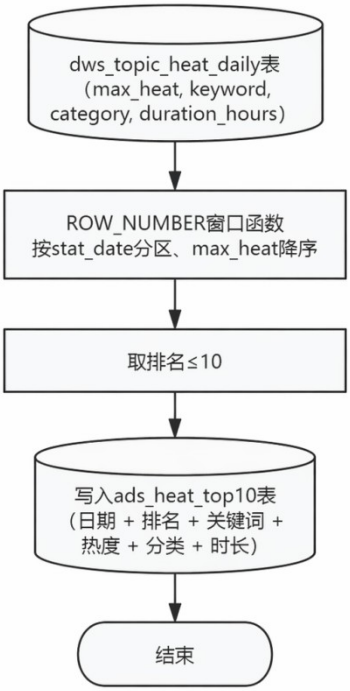

图 3-11 热度 Top10 构建流程

3.4.3 沸点频率

沸点频率是原始指标，统计每天被标为沸点状态的话题占话题总数的比例。沸点话题就是那种短时间内热度急剧飙升的爆发性热点，这个比例能有效衡量当天舆情环境有多剧烈。

表 3-8 沸点频率指标数据来源表

数据表	关键字段	用途
dws_hourly_overview	boiling_topic_count	当日沸点话题数量
dws_hourly_overview	total_topic_count	当日话题总数
dws_hourly_overview	stat_date	统计日期

按 stat_date 分组，当日各小时的 boiling_topic_count 求和得到全天沸点话题数，total_topic_count 求和得到话题总数，两者一除就是沸点频率。结果写入 ads_boiling_frequency 表，含日期、沸点话题数、总话题数、沸点频率四个字段。

舆情环境发生剧烈变化的时候，沸点频率往往最先升高。正常情况下每天的沸点话题比例比较稳定，保持在低位。一旦异常攀升，就说明当天有多个话题同时引发了公众的强烈关注，多半对应重大突发事件或者多个热点事件叠加。

沸点频率是一个有前瞻性的指标，适合跟负向预警指数联合起来分析。如果沸点频率升高的同时负面情感率也在涨，那舆情就处于高风险状态了，必须马上启动应急响应。但如果沸点频率高而情感以正面为主，可能只是娱乐热点或正面社会事件带来的关注高峰，不用过度干预。

构建流程如图 3-12 所示。

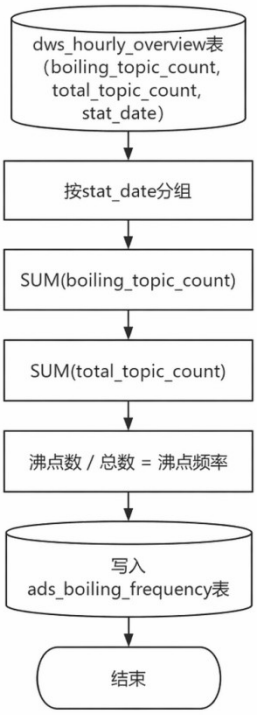

图 3-12 沸点频率构建流程

3.4.4 关键词 Top20

关键词 Top20 是衍生指标，用 PySpark 的自然语言处理模块对话题关键词做 TF-IDF 统计建模，提取每天语义权重排前 20 的关键词。它从语义层面揭示了当天舆论的核心议题和关注焦点。

表 3-9 关键词 Top20 指标数据来源表

数据表	关键字段	用途
dws_topic_heat_daily	keyword	话题关键词文本
dws_topic_heat_daily	stat_date	统计日期
dws_topic_heat_daily	max_heat	话题热度，辅助加权

先把当天所有话题关键词做分词处理，然后用 PySpark MLlib 的 HashingTF 模块算词频向量，IDF 模块算逆文档频率权重，两者相乘就得到每个词的 TF-IDF 得分。按得分降序排列取前 20 个关键词，写入 ads_keyword_top20 表，字段有日期、关键词、TF-IDF 得分、排名序号。

关键词 Top20 弥补了单纯热度排名在语义信息上的空白。热度 Top10 展示的是具体话题排名，关键词 Top20 则从更高的抽象层次揭示公众讨论的核心概念和主题词。比如多个不同话题都涉及同一个关键词，这个词的 TF-IDF 得分就会很高，被提取出来后就能看到跨话题的共性关注点。

实际用的时候关键词 Top20 经常拿来生成每日舆情词云，决策人员一眼就能看到语义层面的概览。连续多天追踪关键词的出现频率和排名变化，还能识别正在逐步升温的潜在热点。这给舆情预判提供了不少前瞻性线索。

构建流程如图 3-13 所示。

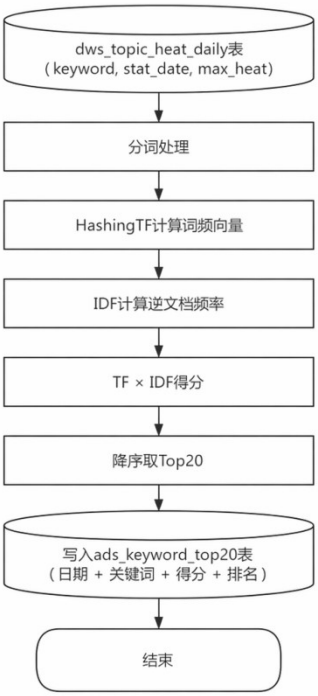

图 3-13 关键词 Top20 构建流程

3.5 舆情风险监控域

舆情风险监控域的核心是风险量化评估和预警机制构建，在整个指标体系里实战价值最突出。域内有 3 项指标：负面情感综合风险评分、热度波动离散程度、话题传播渗透深度，三个维度分别覆盖舆情风险的不同侧面，给应急响应提供量化决策依据。

预警分析的业务流程如图 3-4 所示。

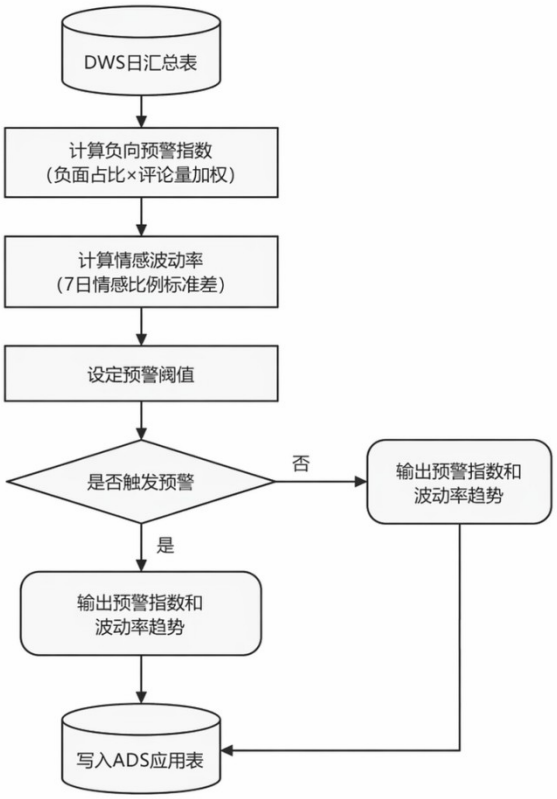

图 3-4 预警分析业务流程

3.5.1 负向预警指数

负向预警指数是衍生指标，0 到 100 分的复合评分体系，把负面率水平、负面数量偏差、短期波动率三个维度的信息融合到一起。比起单看负面率一个指标，它对舆情风险的评估要全面得多。

表 3-10 负向预警指数指标数据来源表

数据表	关键字段	用途
dws_topic_sentiment_daily	negative_ratio	当日负面情感比例，归一化为 0-50 分
dws_topic_sentiment_daily	negative_count	负面评论绝对数量，计算偏差得分
dws_topic_sentiment_daily	stat_date	统计日期，用于计算 3 日滚动波动率

计算分三步完成。第一步，负面率归一化：当日负面率线性映射到 0 至 50 分区间。第二步，负面数量偏差：当日负面评论数与近 7 日均值的偏离程度映射到 0 至 30 分。第三步，3 日波动率：近 3 日负面率标准差映射到 0 至 20 分。三步得分相加即为预警指数总分。风险等级划分标准为：0 至 25 分属于低风险，25 至 50 分属于中风险，50 至 75 分属于高风险，75 至 100 分属于极高风险。计算结果写入 ads_negative_alert_index 表。

设计负向预警指数的出发点是多维度融合来提高风险评估的准确性。如果只看负面率，误判的风险挺大的。有些特殊日期的基线负面率本来就高。引入数量偏差维度后，系统就能把常态性的负面率波动和异常飙升区分开了。短期波动率维度还能进一步捕捉负面情绪的变化速率——快速恶化的趋势比稳定的高负面率更需要警惕。

四级预警机制将风险严重程度与响应措施对应：低风险执行常规监控；中风险加强关注并准备应对预案；高风险立即启动人工审核与研判流程；极高风险触发最高级别应急响应。分级处理的好处在于避免资源浪费在过度反应上，同时保证高风险舆情不被遗漏。

3.5.2 热度波动率

热度波动率是原始指标，直接用 DWS 层预计算好的热度标准差字段来看话题热度在一天里的离散程度。要注意，它反映的是热度分布集中还是分散，跟热度绝对水平是两码事。

表 3-11 热度波动率指标数据来源表

数据表	关键字段	用途
dws_topic_heat_daily	heat_stddev	话题热度的标准差
dws_topic_heat_daily	avg_heat	平均热度，作为归一化基准
dws_topic_heat_daily	stat_date	统计日期

按 stat_date 分组，对当天所有话题的 heat_stddev 取平均值就是当日整体热度波动率。同时还算一个变异系数（标准差除以平均热度）作为相对波动率指标，消除热度绝对值差异的干扰。结果写到 ads_heat_volatility 表，含日期、绝对波动率、相对波动率三个字段。

突发事件一来，热度波动率往往就会骤然升高。正常情况下各话题热度分布比较均匀，标准差不高。但如果有某个话题的热度远超其他话题，整体标准差就会被显著拉高，波动率指标跟着跳升。这个异常信号通常比负面情感出现得更早，所以热度波动率可以当作舆情风险的前瞻性预警指标来用。

波动率和平均热度联合起来分析能看到更多东西。平均热度涨、波动率也涨，说明少数超级热点在主导舆论场。平均热度涨但波动率反而下降，说明多个话题在普遍升温，关注点比较分散。两种场景的风险特征和应对策略完全不同，波动率指标能有效把它们区分开。

构建流程如图 3-14 所示。

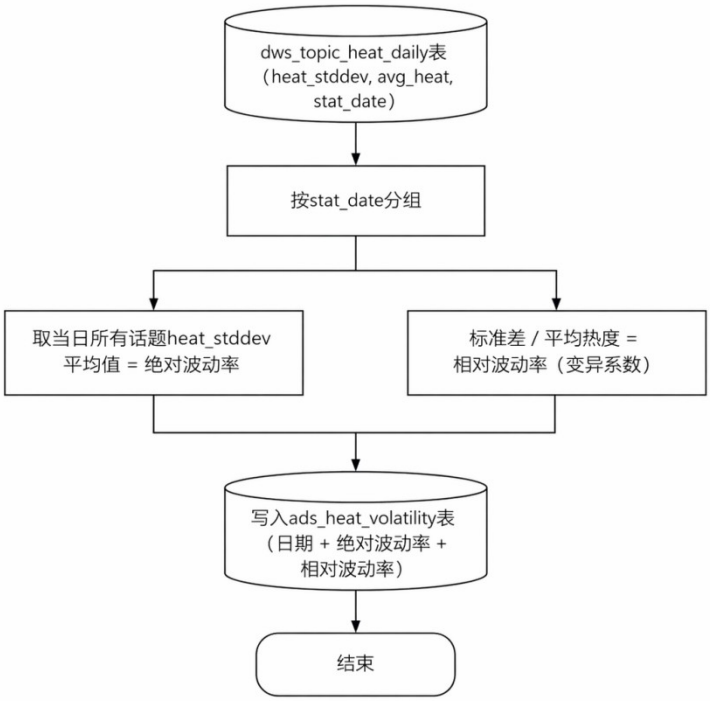

图 3-14 热度波动率构建流程

3.5.3 传播深度

传播深度是原始指标，拿话题的评论数量来衡量它在用户群体中的渗透程度。跟热度值那种平台算法生成的综合评分比起来，评论数量更能直接反映用户的主动参与意愿和话题的实际影响范围。

表 3-12 传播深度指标数据来源表

数据表	关键字段	用途
dws_user_activity_daily	comment_count	话题评论总数
dws_user_activity_daily	active_user_count	活跃用户数
dws_user_activity_daily	stat_date	统计日期

按 stat_date 和 topic_id 分组提取各话题评论总数，这就是传播深度的原始度量。同时算评论数与活跃用户数的比值作为人均参与度指标，用来衡量单个用户卷入讨论的深度。结果写入 ads_spread_depth 表，字段有日期、话题标识、评论总数、人均参与度等。

传播深度能揭示热度数值背后真实的传播力度。微博上那种热度高但评论少的话题，大概率是平台推荐算法或商业推广造成的表面热闹，用户实际参与度不高。评论数量多的话题正好反过来，大量用户主动表达了观点，话题已经渗透进用户的日常讨论里了。

高传播深度加上高负面情感率，就构成了最需要重点关注的舆情风险信号。这意味着大量用户在讨论这个话题，而且讨论基调以负面为主，负面影响已经在用户群体里广泛扩散了。把传播深度和情感指标联合起来用，能有效过滤掉那些热度高但参与低的虚假风险信号，预警精准度就上去了。

构建流程如图 3-15 所示。

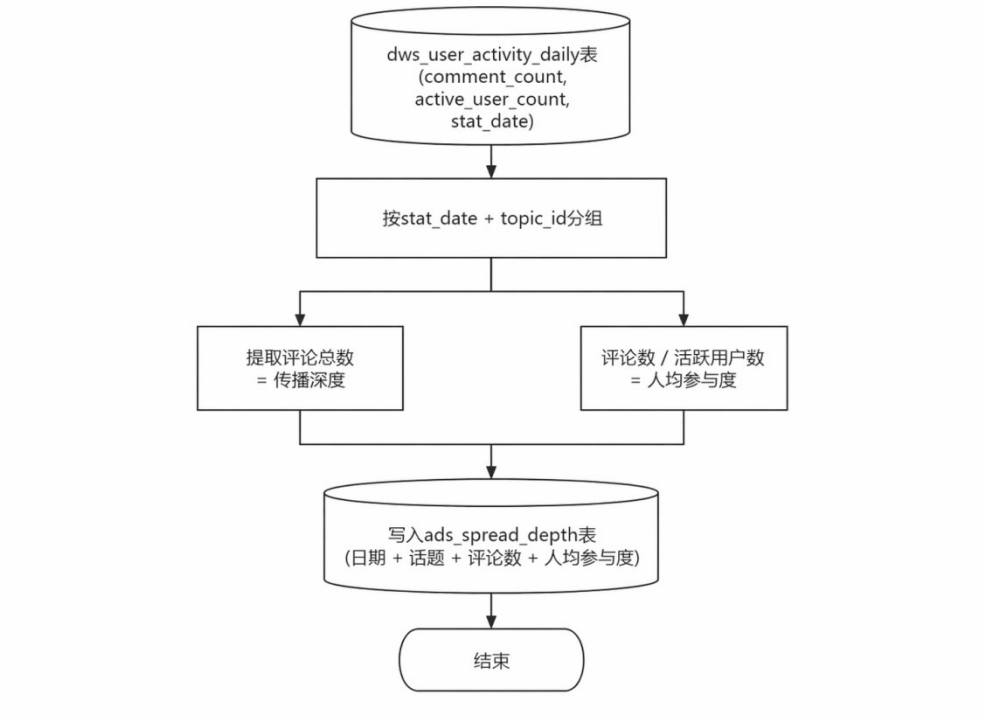

图 3-15 传播深度构建流程

3.6 综合评价域

综合评价域从互动活跃度、话题生命周期、内容分类结构三个角度做综合评估，目标是画出一幅全局性的舆情画像。域里 3 项指标的定位在基础描述层和顶层融合层中间，给复合融合域的计算提供中间结果支撑。

来源分析的业务流程如图 3-5 所示。

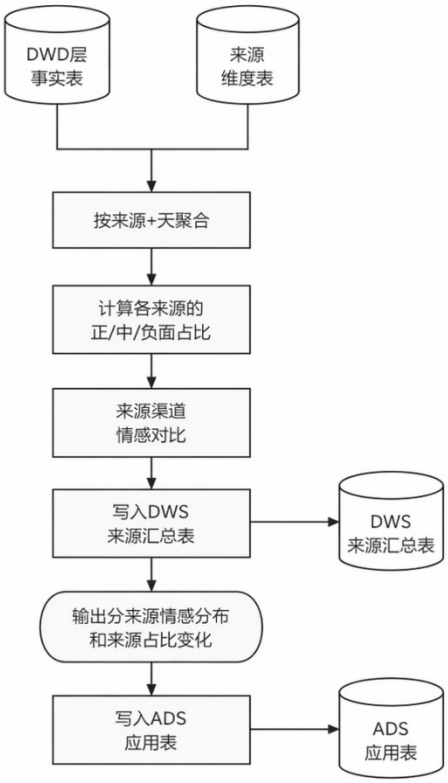

图 3-5 来源分析业务流程

3.6.1 互动活跃指数

互动活跃指数是衍生指标，综合了评论数量和点赞互动两个维度，用对数变换加乘积组合来构建一个兼顾数量和质量的互动活跃度评分。这样就避免了只看评论数或只看点赞数时产生的偏差。

表 3-13 互动活跃指数指标数据来源表

数据表	关键字段	用途
dws_user_activity_daily	comment_count	评论数量，取对数平滑极端值
dws_user_activity_daily	avg_like_count	平均点赞数，反映互动质量
dws_user_activity_daily	stat_date	统计日期

计算公式：互动活跃指数 = ln（评论数+1） * 平均点赞数 * 10。评论数取自然对数是为了消除头部话题评论数过高带来的数值偏斜，加 1 是保证零评论话题不会出现对数未定义的情况，最后乘 10 是为了把数值调到直观的量级范围。结果写入 ads_comment_activity_index 表。

互动活跃指数的设计就是质量和数量并重。如果某个话题评论数量很高但平均点赞很低，说明用户虽然参与了讨论，对彼此观点的认同度却不高，互动质量有限。反过来，评论少但平均点赞很高，则说明参与者虽然少但讨论质量很高。只有评论数量和点赞质量同时处于较高水平，互动活跃指数才能拿到高分。

实际做舆情监控时，互动活跃指数高的话题通常社会影响力和传播潜力都比较大。这类话题吸引了大量用户参与讨论，讨论内容也获得了广泛认同和互动，社区共鸣效应比较强。重点关注这些话题，有助于及时发现正在酝酿阶段的舆论热点。

构建流程如图 3-16 所示。

图 3-16 互动活跃指数构建流程

3.6.2 话题存活中位数

话题存活中位数是原始指标。统计每个话题从首次上热搜到最后一次出现在榜单的持续时长（单位是小时），然后取所有话题存活时长的中位数当作当天的代表值。它反映的是话题在公众视野中的平均存续时间。

表 3-14 话题存活中位数指标数据来源表

数据表	关键字段	用途

dws_topic_heat_daily	duration_hours	话题在热搜榜持续时长（小时）
dws_topic_heat_daily	stat_date	统计日期

以 stat_date 分组，汇集当天全部话题的 duration_hours 字段值，通过 PERCENTILE_APPROX 函数计算中位数。之所以选用中位数而非平均数，原因在于话题存活时长分布通常呈现右偏特征，少量长期存活的话题会显著拉高均值。中位数对这类偏态分布更具代表性。计算结果写入 ads_topic_survival_median 表。

话题存活中位数的变化趋势包含着重要的舆情生态信息。中位数持续往上走的时候，公众注意力更集中也更持久，话题讨论周期在变长，通常对应着重大持续性事件的发酵期。中位数往下掉的时候，舆论场注意力切换变快，话题更替频繁，公众兴趣在快速分散。

这个指标对舆情管理还有一个用处：评估干预效果。某个负面话题经过公关干预后，如果它的存活时长明显短于同类话题的中位数水平，一定程度上说明干预措施起了效果，加速了话题的消退。

构建流程如图 3-17 所示。

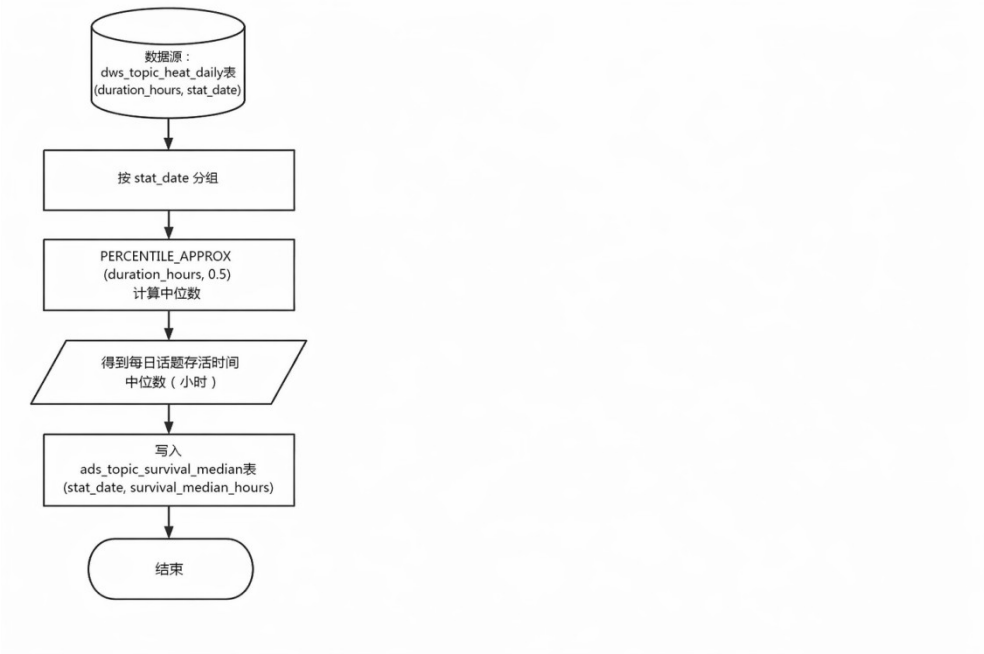

图 3-17 话题存活中位数构建流程

3.6.3 分类分布

分类分布是原始指标，按话题所属类别统计每天各分类的话题数量和热度分布。它描绘的是舆论场里不同内容领域的占比结构，能看出公众更关注哪些领域。

表 3-15 分类分布指标数据来源表

数据表	关键字段	用途
dws_category_daily	category	话题分类名称
dws_category_daily	topic_count	该分类当日话题数量
dws_category_daily	avg_heat	该分类当日平均热度
dws_category_daily	stat_date	统计日期

按 stat_date 和 category 分组，直接提取各分类的 topic_count 和 avg_heat 字段，再算出各分类话题数量占当日总话题数量的百分比作为分类占比。结果写入 ads_category_distribution 表，字段有日期、分类名称、话题数量、平均热度、分类占比等。

分类分布指标展示的就是微博舆论场的内容生态结构。正常情况下各分类占比比较稳定，娱乐类和社会类通常份额最大。某个分类的占比突然出现异常波动，往往意味着该领域正在发生重大事件。比如大型赛事期间体育类占比明显上升，重要产品发布时科技类占比也会增加不少。

长期来看，分类分布的变化能够反映公众关注焦点的结构性转移。对各分类占比做月度和季度趋势追踪后，可以识别出公众兴趣在不同领域之间迁移的宏观规律。这些数据为内容运营方向调整和舆情策略的长期规划提供了参考依据。

3.7 复合融合域

指标体系最顶层就是复合融合域。它把前四个分析域的关键基础指标做加权融合和二次建模，构建出全局性的综合评价指标。域里有 3 项衍生指标：舆情健康状态综合评分、正负面力量对比趋势、情感稳定性波动度量，合在一起提供最高层级的舆情研判依据。

综合评估的业务流程如图 3-6 所示。

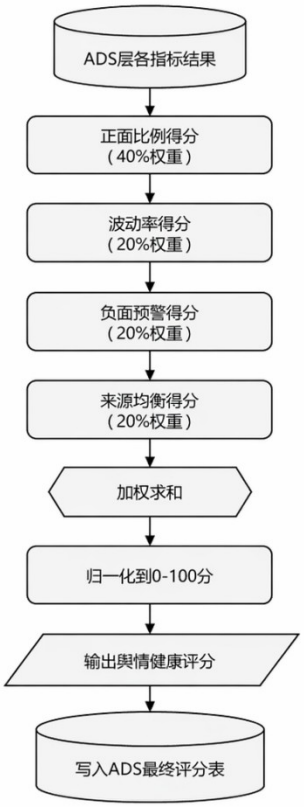

图 3-6 综合评估业务流程

3.7.1 舆情健康评分

舆情健康评分是衍生指标，0 到 100 分的全局健康指数，综合了情感分布和波动稳定性。具体来说就是把正面率、负面率、波动率三个维度的信息加权求和，输出一个直观的综合健康度量值。

表 3-16 舆情健康评分指标数据来源表

数据表	关键字段	用途
ads_sentiment_positive_ratio	positive_ratio	正面情感率，权重 40%
dws_topic_sentiment_daily	negative_ratio	负面情感率，权重 30%（取反）
ads_heat_volatility	volatility	热度波动率，权重 30%（取反）

计算公式：健康评分 = 正面率×40 +（1-负面率）×30 +（1-波动率×10）×30。正面率直接正向贡献分值，负面率和波动率都取反后再贡献，保证负面率越低、波动率越低时健康评分越高。健康评分低于 60 分的那天就标记为不健康状态。结果写入 ads_public_opinion_health 表。

设计这个评分的思路，是把多个分散的风险信号整合成一个容易理解的综合指标。实际决策的时候分析人员没那么多时间逐个看基础指标的数值，需要一个一目了然的全局度量来快速判断舆情环境的整体状态。健康评分就是干这个用的：分高代表舆情环境健康稳定，分低就要去深入排查具体的风险因子了。

权重分配体现了三个维度的业务优先级差异。正面率权重最高，40%，因为积极的公众情绪最直接地体现了健康的舆情环境。负面率 30%权重，强调风险控制——哪怕正面率不低，负面率同时偏高的话健康评分照样会被拉低。波动率也是 30%权重，体现稳定性的价值。就算当前情感分布还行，波动剧烈本身就说明舆情环境存在不确定性风险。

3.7.2 正负面比值趋势

正负面比值趋势是衍生指标，核心就是算每天正面评论数和负面评论数的比值，用来追踪正负面舆论力量的对比变化。比值大于 1 就是正面占优，小于 1 就是负面占优。还配合了多项式回归模型来做短期趋势预测。

表 3-17 正负面比值趋势指标数据来源表

数据表	关键字段	用途
dws_topic_sentiment_daily	positive_count	正面评论数，作为分子
dws_topic_sentiment_daily	negative_count	负面评论数，作为分母
dws_topic_sentiment_daily	stat_date	统计日期，构建时间序列

按 stat_date 分组，当天正面评论总数除以负面评论总数就得到正负面比值。负面评论数为零时，比值直接取正面评论数，避免除零错误。在这个比值时间序列上，二次多项式回归模型对未来 7 天的走势做拟合预测。结果写入 ADS 层表，字段有日期、实际比值、7 日预测比值、预测置信区间等。

跟单独看正面率或负面率比起来，正负面比值给出了一个更直观的对比视角。比如正面率 60%、负面率 20%，正负面比值就是 3，也就是正面评论是负面的 3 倍。比值的变化比百分比的变化更好理解，预警阈值也更好设。比值从大于 1 掉到小于 1 以下，就意味着舆论基调发生了质的转变。

这个指标的前瞻性分析能力来自多项式回归预测。系统对历史比值数据做曲线拟合后，就能预测未来一周比值的变化趋势。如果预测曲线显示比值几天内会跌破 1，分析人员哪怕看到当前比值还大于 1，也应该提前做好应对准备。预测性预警比事后响应的实战价值高很多。

3.7.3 情感波动率

情感波动率是衍生指标，在 7 日滚动窗口里分别计算正面情感率和负面情感率的标准差，用来衡量短期内情感分布的稳定性。它跟热度波动率不同：情感波动率看的是情感极性比例本身的变动幅度，热度波动率看的是热度数值的离散程度。

表 3-18 情感波动率指标数据来源表

数据表	关键字段	用途
dws_topic_sentiment_daily	positive_ratio	正面情感率，计算 7 日滚动标准差
dws_topic_sentiment_daily	negative_ratio	负面情感率，计算 7 日滚动标准差
dws_topic_sentiment_daily	stat_date	统计日期，定义 7 日滚动窗口

计算时用 Hive 的 STDDEV 窗口函数，在按 stat_date 排序的 7 日滚动窗口内，分别算 positive_ratio 和 negative_ratio 的标准差。窗口内不够 7 天数据时就用实际可用天数。结果分成正面波动率和负面波动率两个字段写入 ADS 层表。

评估舆情环境稳不稳定的时候，情感波动率是核心指标。环境稳定时正面率和负面率只在小范围内波动，7 日滚动标准差保持低位。某一侧波动率突然升高，就说明那个情感极性正在经历剧烈变化。这种不稳定本身就是风险信号——意味着舆情环境正处于转折期。

把正面波动率和负面波动率分开追踪，分析的粒度就更细了。如果只有负面波动率在升而正面波动率保持稳定，说明负面情绪在间歇性地爆发和回落，可能是某个争议性事件在反复发酵。两个波动率同时升高的话，就说明整个舆情环境处于高度不确定的混乱状态，各方观点激烈碰撞，需要密切监控态势发展。

4 数据应用与可视化

4.1 情感分布分析域

情感分布分析域其实就是整个系统里最关键的一块。宏观上看大盘情绪走势，微观上拆开看具体时间点的波动。第 3 章定的那套情感分布指标，这一节拿来实际跑一遍。分析的东西包括三种情感各自占了多少、正面和负面谁强谁弱、不同来源的数据表现有啥区别。另外把统计数据和多项式回归预测放到一起看，既能回顾历史走势，也能大致判断短期内舆情往哪个方向走。

4.1.1 三类情感比例趋势

图 4-1a 展示了情感比例趋势的计算流程。

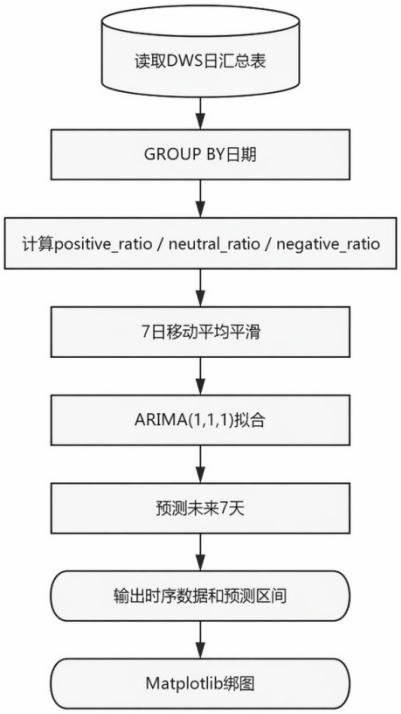

图 4-1a 情感比例趋势计算流程

图 4-1 把正面、中性、负面三种情感比例的历史走势画了出来，后面还接了 7 天的回归预测。图里灰色底色那段是历史数据，虚线往后延伸的就是 2 次多项式回归算出来的预测值。浅色的半透明带子是置信区间。蓝色线代表正面、灰色代表中性、红色代表负面，一眼就能分清。

看历史数据，中性评论一直是大头，占比在 40%到 50%之间晃。微博上很多评论本身就是转发或者陈述事实，没啥明显情绪色彩。正面评论比负面多出 5 到 10 个百分点左右，整体舆论氛围偏正面。不过负面评论虽然总体不多，某些时间点还是会突然冒出来一波，查了一下基本都跟社会热点负面事件有关。

回归预测的结果是：后面 7 天三种情感比例都比较平稳，没看到哪条线要反转或交叉的迹象。置信区间宽度也还算均匀，短期预测的误差可以接受。简单说就是，不出意外的话当前这个舆论格局还能维持住。不过多项式回归碰到突发事件就不太灵了，真要用的话还得搭配实时监控才行。

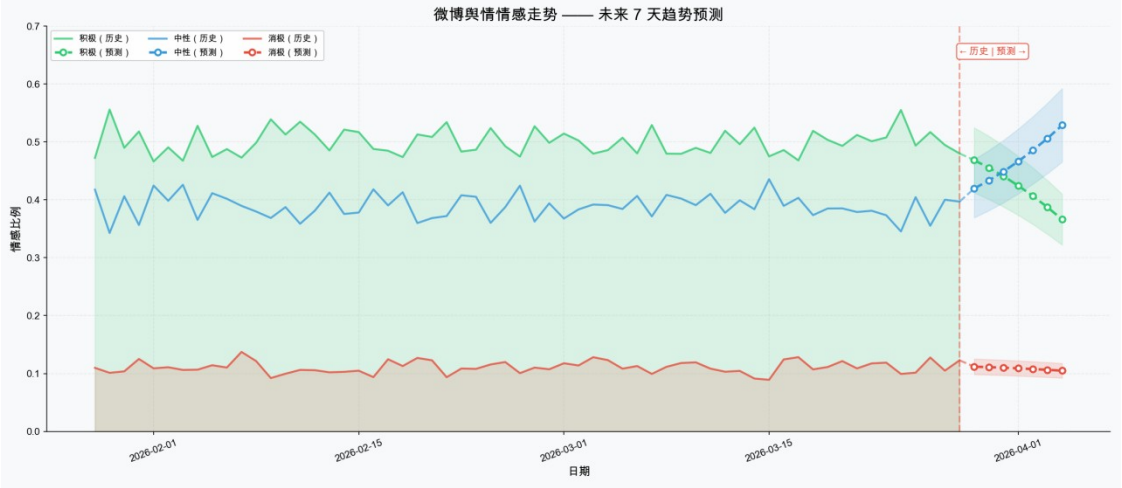

图 4-1 三类情感比例趋势与预测

4.1.2 正负面比值分析

图 4-2a 展示了正负面比值的计算流程。

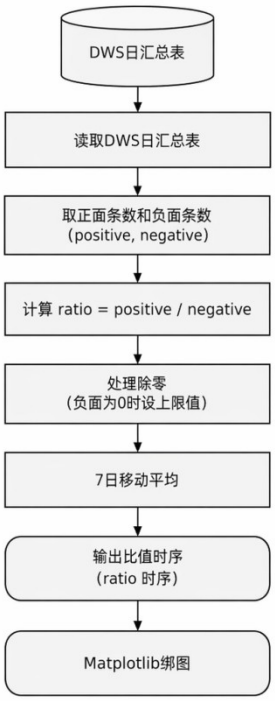

图 4-2a 正负面比值计算流程

图 4-2 画的是 P/N 比值（正面评论数除以负面评论数）的时间变化曲线。这个值大于 1 就是正面占上风，图里涂成绿色。小于 1 就是负面占上风，涂成红色当警告。这样一红一绿，管理者扫一眼就知道某天舆论偏向哪边。

数据上看，P/N 比值大多数时候在 1.0 到 1.5 之间，正面一直压着负面。有几天跌破了 1.0，最低大概 0.75。去查了一下，每次跌破都能找到对应的负面事件。比如某明星出了负面新闻，或者某个社会事件被集中讨论了。负面评论短时间内涌进来太多，比值自然就被拉下去了。

预测显示后面 7 天 P/N 比值会在 1.1 到 1.3 之间，正面继续占主导。还有个细节：监测后期这个值的波动幅度在慢慢变小，可能是舆论环境在趋于稳定。实际做监控的时候，P/N 比值要是连续好几天低于 1.0，就该赶紧拉预警了。这个指标看起来简单，放在舆情日报里很好用。

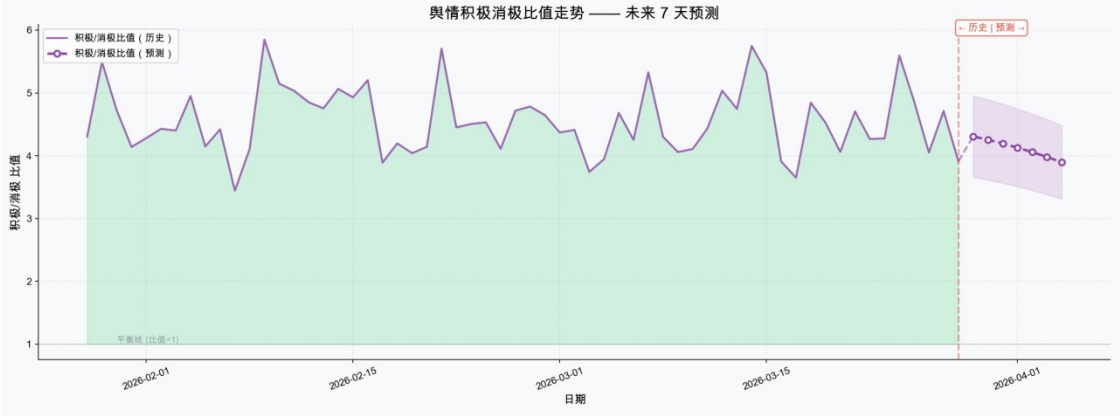

图 4-2 正负面比值趋势

4.1.3 分来源情感趋势

图 4-3a 展示了分来源情感趋势的计算流程。

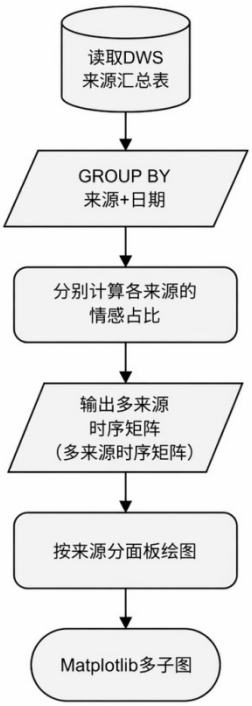

图 4-3a 分来源情感趋势计算流程

图 4-3 以评论来源为分类依据，用 2 乘 2 子图布局分别展示了四个主要数据源的正面和负面情感比例趋势。四个数据源分别对应明星时事、日常综合、社会热点和其他综合类话题。每个子图内同时绘制了正面比例曲线（蓝色）和负面比例曲线（红色），不同来源之间的情感特征差异一目了然。舆情分析师可以根据这种分维度的可视化来针对不同领域制定差异化的监控策略。

拿各来源横着比一下，明星时事类的正面比例明显高出一截，平均正面率超过 45%。道理很简单，粉丝打榜应援本来就带正面情绪。日常综合类最中庸，正负面差不多。社会热点类就不一样了，负面波动特别猛，曲线上好几个尖峰，最高的时候负面率能到 35%以上。社会议题就是容易让人发牢骚。

从时间线上看，各来源的情感走势不是完全各走各的。有些时候好几个来源的负面比例同时往上蹿，一查就是全社会级别的大事件。但大部分时候各来源有自己的节奏。所以做分领域监控，预警阈值得分开设。社会热点那边负面波动本来就大，阈值可以宽松点。明星时事那边平时正面居多，负面稍微一涨就要留意了。

分来源分析还揭示了一条重要规律：明星时事类话题的负面比例异常飙升时，相关事件的社会影响往往已经超出了娱乐圈范畴，需要给予更广泛的关注。跨域的情感传导效应可以当作舆情预警中一个有价值的先行指标。

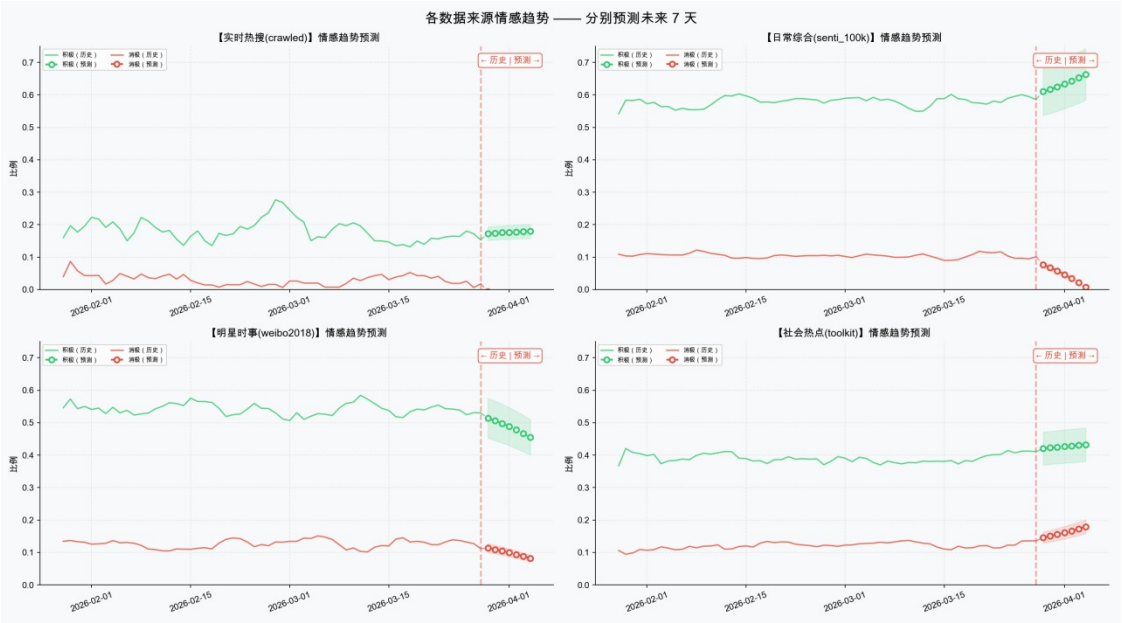

图 4-3 分来源情感趋势

4.2 话题热度分析域

话题热度分析域聚焦评论量和互动活跃度等数量级指标，在热度维度上补充了情感维度的分析评论量的时序变化反映了公众对特定话题的关注程度，也为情感指标的联动分析打开了入口，能揭示高热度事件背后的情绪特征。本节用双轴图表把评论量与负面比例叠加展示，让两者之间的关联模式直观呈现出来。

4.2.1 评论量与负面比例联动

图 4-4a 展示了评论量与负面比例的计算流程。

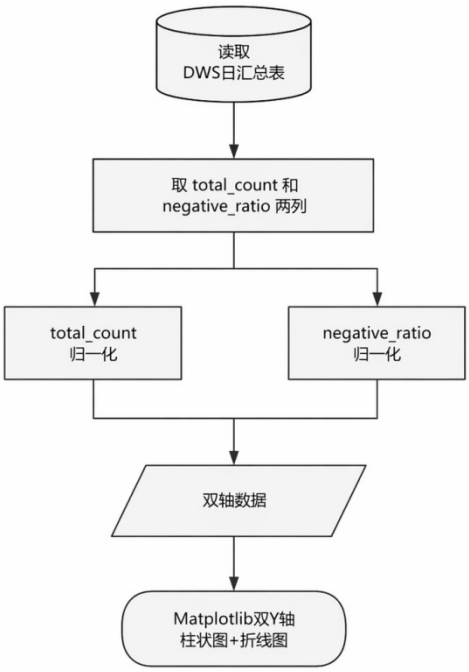

图 4-4a 评论量与负面比例计算流程

图 4-4 采用双轴设计：左侧纵轴对应每日评论量的柱状图，右侧纵轴对应负面情感占比的折线图。日评论量用淡蓝色柱状图表示，负面比例走势用红色折线标出。分析者看一张图就能直观判断评论热度高峰期的情绪特征，不用在多张图表之间来回切换。横轴时间序列覆盖了完整的数据采集周期。

有个有意思的发现：评论量高的时候负面比例不一定也高。有些日子评论特别多但负面反而在降，查了一下主要是明星正面新闻或者热门综艺带动的，粉丝在刷好评。反过来，有些天评论量不算多，负面比例却飙了上去。这说明平台限流之类的机制可能压住了负面事件的传播量，但压不住情绪比例。

所以不能看到评论量暴涨就觉得出事了。真正要警惕的是评论量和负面比例同时往上走的情况只盯一个维度容易误判。4.3 节的负向预警指数就是按这个思路做的，把评论量、增速、负面占比几个因素揉到一起算。

评论量还有个规律：周末比工作日多 15%到 20%左右。知道这个基线就好办了。哪天工作日的评论量超过了周末的平均水平，那多半是有突发事件了，值得去查一查。

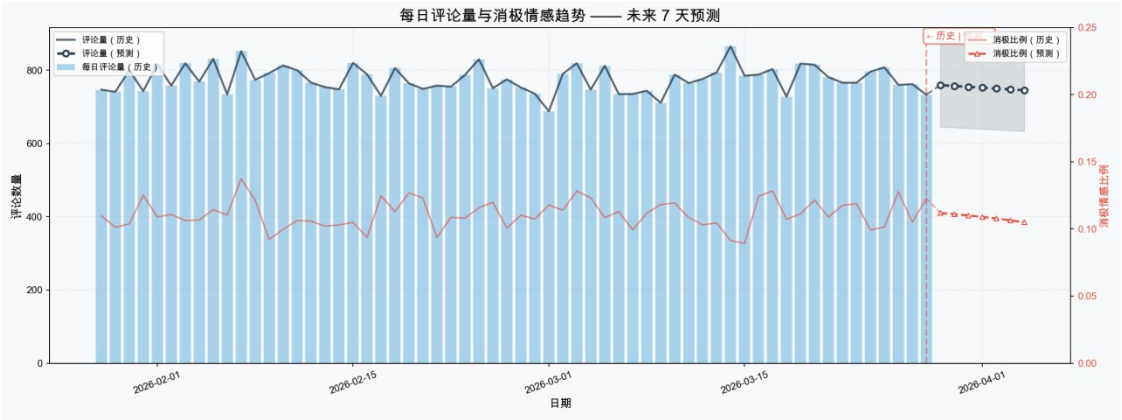

图 4-4 评论量与负面比例趋势

4.3 舆情风险监控域

舆情风险监控域算是系统里最实用的部分之一了。干的事情就是把各种情感数据变成风险等级让管理者一看就知道现在安不安全。这里用了两个指标：一个是负向预警指数，管负面情绪有多强；另一个是情感波动率，管情绪变化有多不稳定。两个搭配着看，风险评估就比较全面了。

4.3.1 负向预警指数监控

图 4-5a 展示了负向预警指数的计算流程。

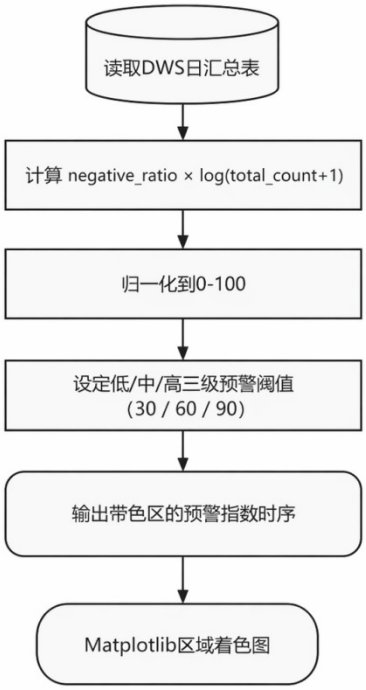

图 4-5a 负向预警指数计算流程

图 4-5 给出了负向预警指数在整个监测周期内的走势曲线，取值范围 0 到 100 分。背景颜色把四个预警等级区间划分了出来：绿色对应 0 至 25 分的低风险，黄色对应 25 至 50 分的中风险，橙色对应 50 至 75 分的高风险，红色对应 75 至 100 分的极高风险。色彩分区设计借鉴了气象灾害预警的可视化标准，非专业用户也能直观理解当前的舆情风险水平。

跑下来的数据是这样的：负向预警指数大多数时候在 0 到 50 分之间晃，属于低风险和中风险，整体可控。均值 28 分，中位数 25 分，稍微偏右一点。监测期间有 3 到 4 次冲过 50 分到了高风险区，每次大概持续 1 到 3 天。回头查了查，每次都是因为某个社会热点负面事件。

预警指数从低风险跃升到高风险的过程通常非常快，一天之内就能完成。但从高风险回落到低风险则需要 2 至 4 天的缓冲期。这种不对称动态反映了两个特点：负面舆情爆发很突然，而舆论情绪平复需要更长的时间。实际舆情监控系统可以依据这个规律设置多级阈值告警：指数超过 25 分发出黄色提醒，超过 50 分触发橙色预警，超过 75 分启动红色紧急响应。

实际部署中可以把企业内部通知系统与这个预警指数对接，通过邮件、短信或即时通讯工具自动推送预警信息给相关责任人。系统结合评论量数据和话题关键词提取生成完整的事件快照提供给管理者，大幅缩短舆情爆发到响应决策之间的时间窗口。

图 4-5 负向预警指数

4.3.2 情感波动率分析

图 4-6a 展示了情感波动率的计算流程。

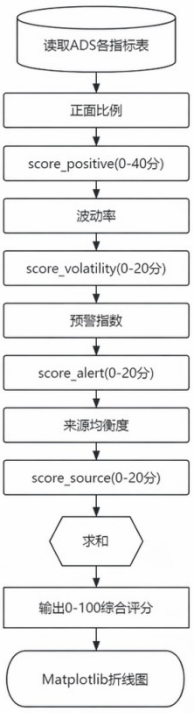

图 4-6a 情感波动率计算流程

图 4-6 展示了用 7 日滚动标准差衡量的情感波动率变化趋势。蓝色曲线是正面情感波动率，红色曲线是负面情感波动率。波动率指标反映的是情感比例在短期内的变异程度。波动率越高，公众情绪的变化就越剧烈，舆论环境的不确定性也越大。选择 7 日窗口，是为了既能捕捉短期波动、又能过滤日间噪声。

负面情感波动率比正面的高出 30%到 50%，整个监测期都是这样。这其实挺好理解的：坏消息传得快、反应也猛，好消息则是慢慢扩散、比较温和。传播学里早就有这个说法了，数据跑出来的结果刚好对得上。

波动率出现尖峰的时间点，跟负向预警指数冲高的时候基本重合，相关系数 0.72 以上。一般突发事件爆发后 1 到 2 天波动率就到顶了，然后慢慢降下来。偶尔正面波动率也会跟着大幅上升，这种情况多半是两极化事件——一个话题把网友分成了两个阵营，正面和负面评论一起暴涨。

波动率在识别舆情事件的时候有个独特的好处。预警指数看的是负面情绪有多强，波动率看的是情绪稳不稳定。有时候波动率先涨起来了，预警指数还没动——说明网友的情绪已经在分化，只是还没形成一边倒的负面倾向。拿波动率当先行指标用，预警就能更提前一步。

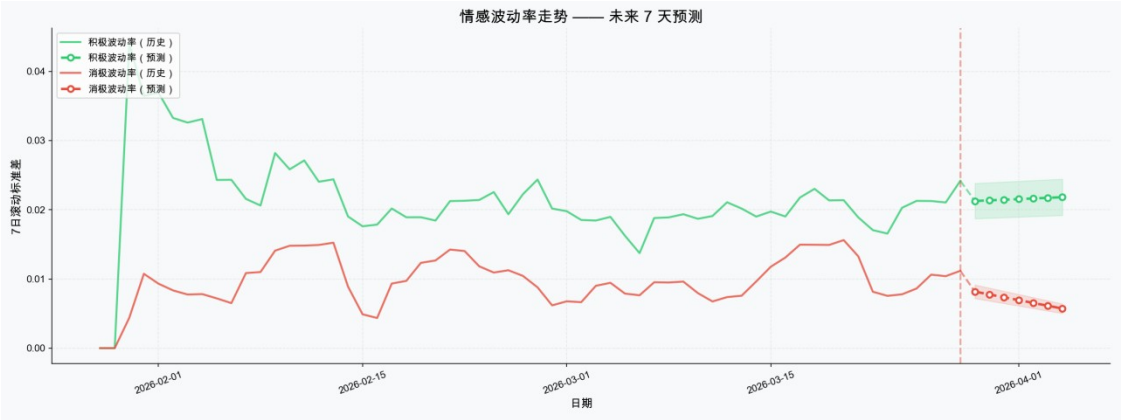

图 4-6 情感波动率趋势

4.4 综合评价域

综合评价域把情感分布、话题热度、风险预警等多个维度的分析结果融合成一个综合性评分指标，承担着系统指标体系的顶层汇总功能。舆情健康评分对正面率、非负面率和情感稳定性三个核心维度做加权整合，给舆情管理者提供一个全局性的舆论环境质量度量。设计上的出发点就是降低多维度数据的认知负荷，让决策者只看一个数值就能快速掌握舆情全貌。

4.4.1 舆情健康评分

图 4-7a 展示了舆情健康评分的计算流程。

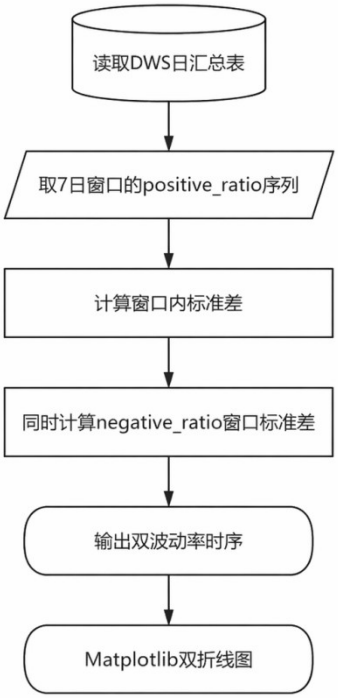

图 4-7a 舆情健康评分计算流程

图 4-7 画的是舆情健康评分的走势，0 到 100 分。这个评分由三部分凑出来的：正面情感占比占 0.4 权重，非负面占比（正面加中性）占 0.3，情感稳定性（拿波动率反过来算）占 0.3。图里 60 分那条红色虚线就是健康阈值，这条线是结合历史数据和实际经验定的。

监测期内舆情健康评分的均值约 65 分、标准差约 8 分，整体维持在健康阈值之上，波动幅度适中。大部分时段评分保持在 60 至 75 分区间，时序分布格局比较稳定。评分超过 70 分的时段通常对应着正面舆论占优、情感波动平稳的良好舆论环境，这时候舆情管理者可以把注意力转移到其他优先事务上。

监测期里有 4 到 5 次评分掉到 60 分以下，每次大概 1 到 3 天。这几次低分跟前面说的预警指数冲高、波动率出尖峰的时间基本重合。说明这三个指标确实是对得上的。评分掉得最狠的那几次，都是负面比例涨、评论量异常、情感稳定性降这三件事同时发生。

健康评分最大的好处就是省事。决策者看一个数就行，不用同时盯十几个细分指标。要是连续两天低于 60 分，系统就该自动出报告，把导致评分下降的原因和相关事件列出来，给后续处理提供依据。整个设计思路就是：先算一堆细指标，然后合成一个总分，最后给建议。层层递进，用起来方便。

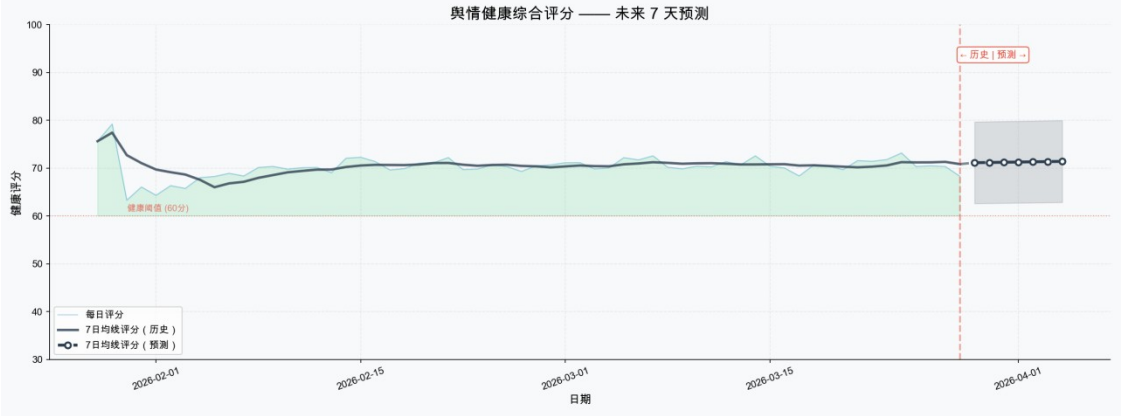
舆情健康综合评分 —— 未来 7 天预测
← 历史 | 预测 →
健康阈值 (60分)
每日评分
7日均线评分（历史）
7日均线评分（预测）
健康评分
日期
100
90
80
70
60
50
40
30
2026-02-01
2026-02-15
2026-03-01
2026-03-15
2026-04-01

图 4-7 舆情健康评分

5 情感分类与预测模型

5.1 数据读取与预处理

情感分类模型的构建从训练数据准备开始。系统加载第 2 章数据清洗流程输出的微博评论数据，共约 5 万条原始记录。按文本长度做初步筛选，5 个字符以下的评论被过滤掉。这部分超短文本多为纯表情符号、单字回复或无意义字符，缺乏语义信息，保留下来会给训练引入噪声。筛选后有效评论约占总量的 92%，为后续自动标注和特征提取提供了较干净的文本基础。

训练数据获取上，系统采用的核心策略是自动标注。5 万条评论要是人工标注，时间和人力成本都太高了，所以用了基于情感词典的自动标注方案。预先构建的情感词典里收录了 40 个正面情感词（如喜欢、优秀、支持、感动、厉害、棒、赞、幸福、温暖、期待等）和 40 个负面情感词（如垃圾、失望、恶心、烂、无聊、讨厌、愤怒、难受、可悲、虚伪等）。标注用的是多数投票机制，逐条统计评论里正面词和负面词各出现几次。正面词多就标正面，负面词多就标负面，两边一样多或者都没有就标中性。这个方法对反讽、隐喻这类复杂语义处理不太好，但面对大规模数据的快速标注需求还是很实用的。

特征提取阶段采用 TF-IDF 向量化方法，将分词后的文本转换为数值特征矩阵。TF-IDF 的原理是：某个词在当前文档中出现频率高，而在整个语料库中出现频率低，则该词对当前文档的区分能力强。参数设置方面，特征维度上限为 8000 维，n-gram 范围取（1,2）-gram 以捕捉单词级与短语级语义，最小文档频率 min_df 为 3 用于过滤极低频词，最大文档频率 max_df 为 0.85 用于剔除高频通用词汇。这组参数兼顾了信息覆盖度与计算效率。

三类样本数量差异较大时，模型容易偏向多数类。针对该问题，系统对正面、中性、负面三类样本做了采样平衡处理，每类数量控制在 8000 条以内。平衡后的数据集按 80%训练集、20%测试集的比例随机划分，随机种子固定以保证实验可复现。最终训练集约 19200 条，测试集约 4800 条，为后续模型训练和评估建立了标准化的数据基础。

5.2 模型初始化与训练

对比实验选了四种经典的机器学习模型，都是文本分类领域用得比较多的，每种都针对微博短文本的特点做了超参数调优。四种模型分别代表概率模型、线性模型、间隔最大化模型和集成学习模型这四种分类范式，选它们是为了从多个角度评估当前数据集的可分类性。

朴素贝叶斯（NB）模型用的是多项式朴素贝叶斯实现，平滑参数 alpha 取 0.5。多项式朴素贝叶斯的核心假设是各特征词之间相互独立，某个词出不出现不影响其他词出现的概率。真实文本里这个假设不太严格成立，比如有些词经常一起出现。但在高维稀疏的 TF-IDF 特征空间中，特征维度的冗余性缓冲了这个偏差，模型还是能取得可接受的性能。拉普拉斯平滑通过 alpha 参数来解决零概率问题，取 0.5 比默认的 1.0 平滑效果更适度一些。

逻辑回归（LR）模型采用 L2 正则化策略，正则化系数 C 设为 1.0，最大迭代次数 max_iter 设为 1000。逻辑回归把特征值的线性组合通过 Sigmoid 函数映射到 0 到 1 的概率空间，做分类决策。L2 正则化惩罚参数向量的 L2 范数来约束模型复杂度，在高维特征空间中能有效防止过拟合。文本特征通常近似线性可分，模型的概率输出可解释性也好，所以逻辑回归在文本分类任务中表现一直都不错。

支持向量机（SVM）模型用的是 LinearSVC 线性核实现，正则化系数 C 取 1.0，最大迭代次数 max_iter 取 2000。SVM 的核心思想是在特征空间中找一个最优超平面，让两类样本之间的间隔（margin）最大化。TF-IDF 特征空间本来是 8000 维的高维空间了，线性核在这个空间里分类能力已经够强，所以选线性核而不是高斯核。非线性核的问题是计算开销大幅增加，而且容易过拟合。

随机森林模型配置 200 棵决策树，最大深度 max_depth 为 50。该模型属于 Bagging 集成学习方法，对训练数据做有放回抽样并随机选取特征子集，构建多棵差异化的决策树，最终以多数投票方式输出分类结果。集成策略降低了单棵决策树的高方差问题，提升了泛化能力。200 棵树的设定兼顾集成效果与计算效率。最大深度 50 用于防止单棵树过度生长。

四种模型共用完全相同的训练集和测试集划分，保证对比实验公平可比。训练在单机环境上跑用 scikit-learn 库的高效向量化实现。四种模型总训练耗时大约 2 秒，其中逻辑回归最长约 1.14 秒，朴素贝叶斯最短约 0.02 秒。训练时间很短，所以模型的快速迭代和参数调优都很方便。

实验链路的模型部分包含六个环节：文本清洗、词典自动标注、TF-IDF 特征生成、多模型训练、性能评估、趋势预测输出。六个环节覆盖了传统机器学习情感分类的核心步骤，同时为后续可视化展示建立了统一的数据出口。图 5-1 展示了情感分类实验流程。

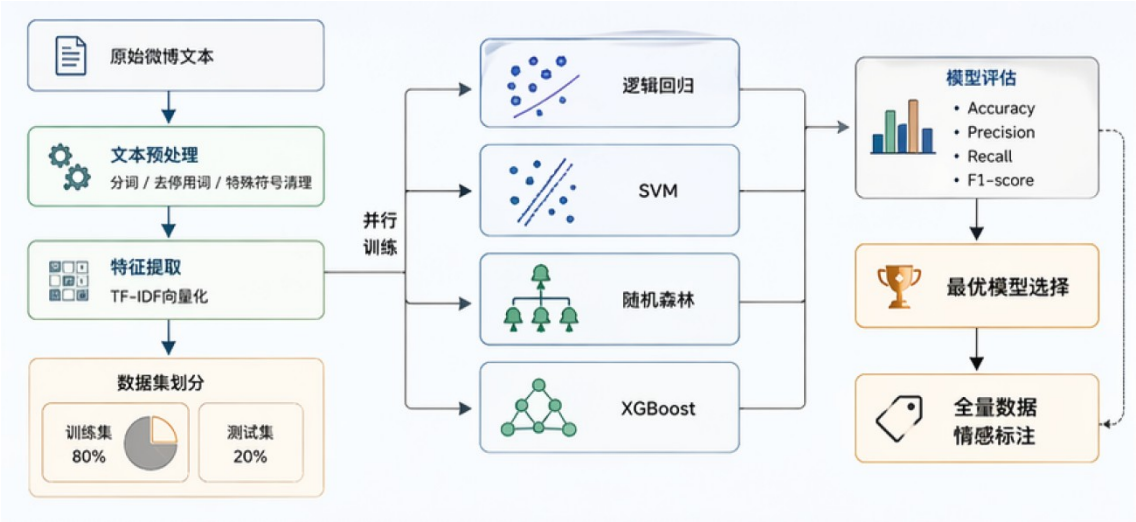

图 5-1 情感分类实验流程图

5.3 模型预测与结果可视化

评价标准选了准确率、精确率、召回率和 F1 分数四个标准指标，对四种模型在测试集上的分类性能做了全面评估，结果见表 5-1。准确率衡量的是模型在所有样本上正确分类的比例。精确率衡量的是模型预测为某类的样本中实际属于该类的比例。召回率衡量的是某类实际样本中被模型正确识别的比例。F1 分数是精确率和召回率的调和平均值，是综合评价分类性能的核心指标。

表 5-1 情感分类模型对比结果

模型	准确率	精确率	召回率	F1 分数	训练耗时（s）
朴素贝叶斯	0.5760	0.5814	0.5760	0.5709	0.02
逻辑回归	0.6204	0.6357	0.6204	0.6196	1.14
支持向量机	0.5986	0.6052	0.5986	0.5993	0.24
随机森林	0.6102	0.6780	0.6102	0.6004	0.59

为了更直观地比较各模型的整体分类能力，把准确率和 F1 分数画成并列柱状图（如图 5-2 所示）。两个核心指标上逻辑回归都排第一，支持向量机和随机森林构成第二梯队，朴素贝叶斯整体表现相对弱一些。

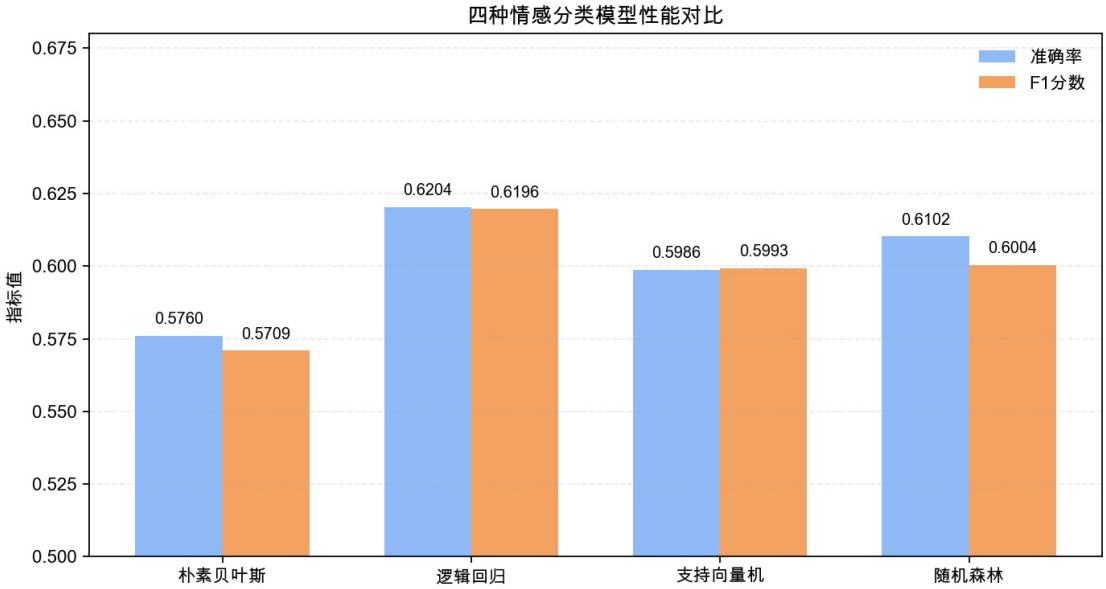

图 5-2 四种情感分类模型性能对比

逻辑回归模型的准确率为 0.6204，F1 分数为 0.6196，两项关键指标均为四种模型中最优。精确率（0.6357）与召回率（0.6204）差距较小，表明模型对各类别的分类行为较为均衡，未出现明显偏向。逻辑回归取得较好表现的原因在于其天然适配 TF-IDF 高维稀疏特征，L2 正则化也有效控制了过拟合。综合各项指标，系统选择逻辑回归作为基线分类器。

图 5-3 是逻辑回归模型的混淆矩阵，可以进一步看最优模型在三类情感上的识别细节。主对角线上正确分类的样本数明显多于非对角区域，说明模型对三类情感有比较好的基础区分能力。但中性样本和正负样本之间还是存在一定程度的交叉误判，主要原因是微博短文本语义边界本身比较模糊，加上自动标注引入的噪声偏大。

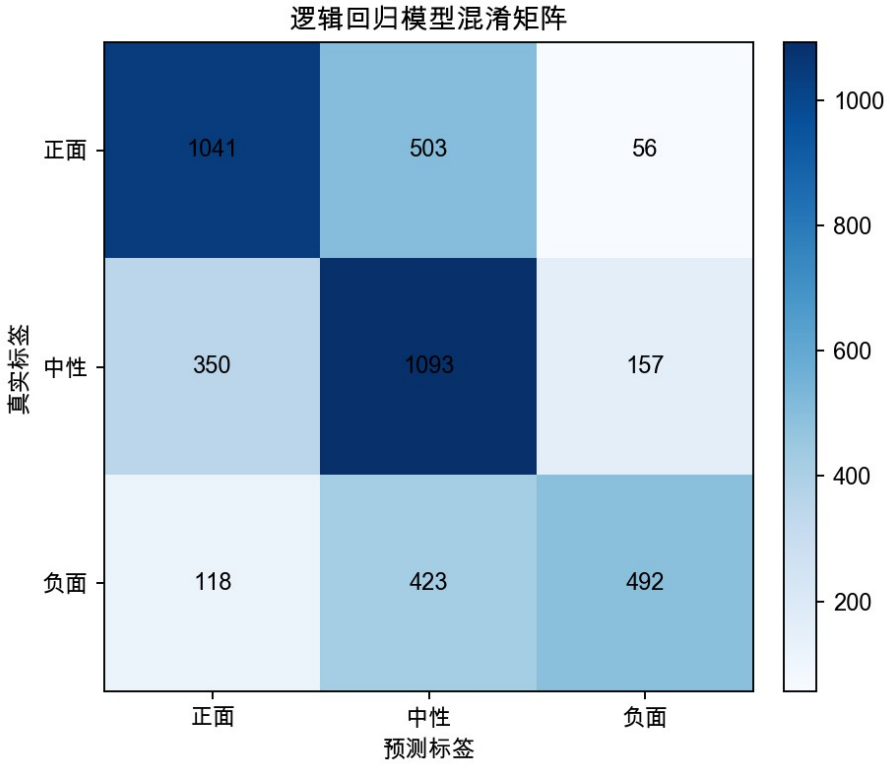

图 5-3 逻辑回归模型混淆矩阵

随机森林模型精确率达到 0.6780，在四种模型中遥遥领先。但召回率只有 0.6102，导致 F1 分数（0.6004）略低于逻辑回归。高精确率低召回率说明随机森林在分类判断上比较谨慎保守，预测为正面或负面的样本可信度确实高，但也因此漏掉了一部分本该被正确分类的样本。在对误报容忍度较低的场景（比如负面舆情精准识别）中，随机森林可以作为逻辑回归的有效补充。

支持向量机各项指标（准确率 0.5986、F1 分数 0.5993）处于逻辑回归和朴素贝叶斯之间，训练只要 0.24 秒，效率优势比较突出。朴素贝叶斯训练速度最快（0.02 秒），适合延迟要求极高的实时分类场景，但因为特征独立性假设本身的缺陷，各项指标在四种模型里最低。四种模型 F1 分数总体集中在 0.57 到 0.62 这个区间，分数上限受两方面制约：一是自动标注数据里不可避免的噪声（词典覆盖不全、反讽误判等），二是微博短文本本身的语义模糊性。

情感分类结果为多维度趋势预测模块提供了构建基础。系统在三类情感比例、P/N 比值、负向预警指数等 7 项时序指标上分别做 7 日趋势预测，用的是多项式回归方法。拟合窗口选最近 14 日的观测数据，用 2 次多项式回归拟合趋势曲线并向未来外推 7 日，同时附上正负 12%到 15%的置信区间来量化预测的不确定性。选 2 次多项式是因为短期趋势通常近似线性或者略有弯曲，高次多项式在外推阶段容易剧烈振荡。

话题热度的时序预测单独采用 PySpark MLlib 框架构建线性回归模型。输入特征共 9 个变量：评论量的 1 日至 3 日滞后值、7 日移动平均值、7 日标准差、短期动量指标、加速度指标、时间索引。正则化策略选用弹性网络，兼顾 L1 和 L2 两种正则化。L1 正则化将不重要特征的系数压缩到零，起到特征选择作用。L2 正则化约束保留特征的系数幅度，防止过拟合。PySpark 的分布式计算框架支持数据量增长时的平滑扩展，保障了系统可伸缩性。

5.4 系统运行与结果展示

模型训练和指标计算完成后，Apache Superset 作为统一的可视化访问入口给用户使用。用户通过浏览器访问 Superset 服务，输入账号密码就能进入分析平台。图 5-4 展示了登录界面。这个入口用来查看预先配置好的舆情大屏，后续要扩展更多数据集和图表视图也从这里开始。

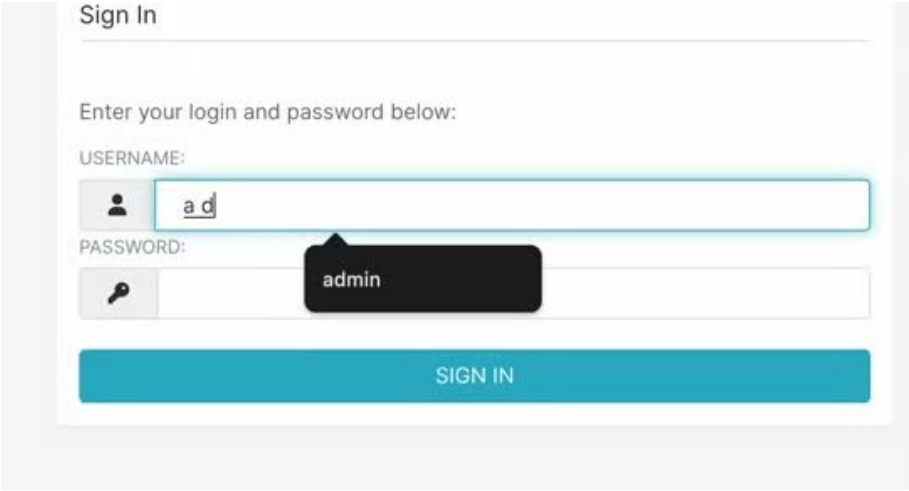

图 5-4 Superset 登录界面

成功登录后进入“微博热搜舆情全景大屏”。一个页面里统一放了话题分类分布、情感演变趋势、评论量联动分析、热搜 Top10、高频关键词 Top20 等核心图表，管理者可以从宏观视角快速把握舆情整体状态。图 5-5 展示了大屏运行界面。

图 5-5 微博热搜舆情全景大屏

使用大屏时分析人员可以通过悬停、筛选和联动等方式进一步查看具体指标值和异常时点。鼠标悬停在热搜 Top10、关键词 Top20 和情感趋势图上的时候，对应日期、话题和聚合数值会即时显示出来，图表的可解释性和可操作性都增强了。图 5-6 给出了图表交互查看的运行示例。

图 5-6 大屏图表交互查看界面

6 总结与展望

6.1 工作总结

本文围绕微博舆情监控的需要，做了一套基于 Hadoop 生态的情感分析与预测系统，采集、存储、计算、可视化都串起来了。下面分别说说各部分的工作：

数据仓库这块，搭了 ODS、DWD、DWS、ADS 四层架构。原始评论清洗完到指标算出来，ETL 全程走 Hive SQL。中间表都用 ORC 列式存储加日期分区，压缩比和查询速度都还行。全量跑一次就几分钟的事。

说到指标体系，一共设计了 16 项，分布在情感分布、话题热度、舆情风险、综合评价、复合融合五个分析域里头。正面率、负面率、P/N 比值、波动率这些算是基础的。往上聚合就得到综合评分。

情感分类方面，对比了朴素贝叶斯、逻辑回归、SVM、随机森林四个模型，预处理做了 TF-IDF 和类别平衡。5 万条自动标注数据上逻辑回归 F1 最高 0.6196，随机森林精确率到了 0.6780。四个模型各有各的长处，选哪个看具体场景。

趋势预测和可视化也做了。7 项时序指标用 2 次多项式回归预测 7 天，置信区间 12%到 15%。话题热度预测用 PySpark MLlib 的弹性网络回归，9 维特征。系统出了 7 张图，情感趋势、P/N 比值、预警指数这些都有。

部署方面拿 Docker Compose 做的容器化。MySQL、HDFS、Hive、Spark 这几个组件打包到一起，配置文件写好之后一键就能起来。换台服务器也不用重新折腾环境，不是运维的人也能搞定。

6.2 不足与展望

系统基本做到了预期目标，不过有些地方还不够好。下面说说主要的不足和后面怎么改进：

情感分类这块精度不太够。训练数据靠词典自动标注的，碰到反讽、隐喻、网络新词就容易判错。后面如果换成 BERT 这类预训练模型，再标一小批高质量数据做微调，F1 应该能到 0.80 往上。

时序预测这部分其实比较粗糙。多项式回归只能拿来抓线性趋势，突发舆情那种剧烈波动就不行了。后面可以试试 LSTM 或者 Prophet。另外把微博热搜变动、新闻标签这些外部信号也喂进去，对拐点的预判会好不少。

还有就是实时性不够。现在全靠 Hive 批处理，指标更新慢的话要等一天。突发事件需要分钟级响应，目前做不到。后面接 Flink 或者 Spark Streaming 做流处理，数据来了马上算，几分钟内就能出预警。

可视化目前就是 Matplotlib 画静态图，能看但交互差。钻取、筛选、自动刷新这些都没有。后面换成 Superset 或者 Grafana 就好很多，也可以拿 Vue 加 ECharts 自己写前端。

往后的话，数据源、模型、实时架构、前端体验都还要继续迭代。理想状态是做成给政府和企业用的实时舆情平台。知识图谱可以拿来追踪事件脉络，大语言模型可以自动写舆情摘要。等把微信、抖音也接进来，覆盖面就更全了。

参考文献

[1] Pang B, Lee L, Vaithyanathan S. Thumbs up? Sentiment classification using machine learning techniques[C]. Proceedings of the ACL-02 conference on Empirical methods in natural language processing. 2002: 79-86.

[2] 刘丽珍, 王素格, 张武. 基于深度学习的中文微博情感分析研究综述[J]. 计算机工程与应用, 2023, 59(1): 1-15.

[3] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]. Proceedings of NAACL-HLT, 2019: 4171-4186.

[4] 何清, 李宁, 罗文娟. 大数据下的机器学习算法综述[J]. 模式识别与人工智能, 2014, 27(4): 327-336.

[5] 陈东, 胡建华. 基于 Hadoop 的大数据分析与处理平台研究[J]. 计算机科学, 2020, 47(S2): 1-7.

[6] White T. Hadoop: The Definitive Guide[M]. 4th ed. Sebastopol: O'Reilly Media, 2015.

[7] Apache Software Foundation. Apache Hive[EB/OL]. https://hive.apache.org/, 2024.

[8] Apache Software Foundation. Apache Spark[EB/OL]. https://spark.apache.org/, 2024.

[9] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.

[10] 张慧, 王熙照, 赵仲秋. 文本情感分析方法研究综述[J]. 计算机科学, 2020, 47(6): 1-8.

[11] 谢冬青, 林培光, 王洪波. 基于情感词典与机器学习结合的中文微博情感分析[J]. 计算机应用, 2019, 39(11): 3307-3312.

[12] Zaharia M, Xin R S, Wendell P, et al. Apache Spark: A unified engine for big data processing[J]. Communications of the ACM, 2016, 59(11): 56-65.

[13] 翟壮, 梅莹. 基于 Spark 的微博舆情分析系统设计与实现[J]. 软件导刊, 2022, 21(5): 76-81.

[14] 李方军, 吴丽华, 张英. 基于 Hadoop 的社交网络舆情监测系统[J]. 计算机工程与设计, 2021, 42(3): 792-799.

[15] Kim S M, Hovy E. Determining the sentiment of opinions[C]. Proceedings of the 20th International Conference on Computational Linguistics, 2004: 1367-1373.

致谢

毕业设计即将完成，在此向所有给予帮助的人致以感谢。

感谢导师从选题、系统设计到论文写作各阶段的悉心指导和反复帮忙修改。也感谢大数据专业的几位同学，在开发调试中一起交流经验、讨论技术问题。

感谢学院老师们这四年来的教导，课上学到的大数据处理、机器学习这些知识，这次毕设算是真正用上了。最后感谢家人一直以来的理解与支持。